

Probabilidade e estatística - Aula 14

Estimação pontual de parâmetros

Dr. Giannini Italino Alves Vieira

Universidade Federal do Ceará - Campus de Crateús

2024

1 Estimação pontual - Conceitos iniciais

2 Estimador não viesado (não tendencioso)

Objetivo da inferência estatística

Motivação

- A ideia da inferência estatística consiste em estudar uma população através de evidências fornecidas por uma amostra de observações selecionadas a partir dessa população de interesse.
- Por exemplo, suponha que nosso interesse consiste em modelar a distribuição de alturas de brasileiros adultos.
 - É razoável supor, neste caso, que essa distribuição das alturas pode ser modelada por uma normal.
 - Contudo, note que o modelo só ficará completamente especificado se soubermos os valores dos parâmetros μ e σ^2 .
 - Uma forma de se obter μ e σ^2 é medir as alturas de todos os brasileiros adultos o que é inviável.
 - Outra forma é selecionar, de maneira apropriada, uma amostra da população e, a partir dessa amostra, analisa-la e inferir propriedades para toda a população.

Objetivo da inferência estatística

Motivação

- A ideia da inferência estatística consiste em estudar uma população através de evidências fornecidas por uma amostra de observações selecionadas a partir dessa população de interesse.
- Por exemplo, suponha que nosso interesse consiste em modelar a distribuição de alturas de brasileiros adultos.
 - É razoável supor, neste caso, que essa distribuição das alturas pode ser modelada por uma normal.
 - Contudo, note que o modelo só ficará completamente especificado se soubermos os valores dos parâmetros μ e σ^2 .
 - Uma forma de se obter μ e σ^2 é medir as alturas de todos os brasileiros adultos o que é inviável.
 - Outra forma é selecionar, de maneira apropriada, uma amostra da população e, a partir dessa amostra, analisa-la e inferir propriedades para toda a população.

Objetivo da inferência estatística

Motivação

- A ideia da inferência estatística consiste em estudar uma população através de evidências fornecidas por uma amostra de observações selecionadas a partir dessa população de interesse.
- Por exemplo, suponha que nosso interesse consiste em modelar a distribuição de alturas de brasileiros adultos.
 - ▶ É razoável supor, neste caso, que essa distribuição das alturas pode ser modelada por uma normal.
 - ▶ Contudo, note que o modelo só ficará completamente especificado se soubermos os valores dos parâmetros μ e σ^2 .
 - ▶ Uma forma de se obter μ e σ^2 é medir as alturas de todos os brasileiros adultos o que é inviável.
 - ▶ Outra forma é selecionar, de maneira apropriada, uma amostra da população e, a partir dessa amostra, analisa-la e inferir propriedades para toda a população.

Objetivo da inferência estatística

Motivação

- A ideia da inferência estatística consiste em estudar uma população através de evidências fornecidas por uma amostra de observações selecionadas a partir dessa população de interesse.
- Por exemplo, suponha que nosso interesse consiste em modelar a distribuição de alturas de brasileiros adultos.
 - ▶ É razoável supor, neste caso, que essa distribuição das alturas pode ser modelada por uma normal.
 - ▶ Contudo, note que o modelo só ficará completamente especificado se soubermos os valores dos parâmetros μ e σ^2 .
 - ▶ Uma forma de se obter μ e σ^2 é medir as alturas de todos os brasileiros adultos o que é inviável.
 - ▶ Outra forma é selecionar, de maneira apropriada, uma amostra da população e, a partir dessa amostra, analisa-la e inferir propriedades para toda a população.

Objetivo da inferência estatística

Motivação

- A ideia da inferência estatística consiste em estudar uma população através de evidências fornecidas por uma amostra de observações selecionadas a partir dessa população de interesse.
- Por exemplo, suponha que nosso interesse consiste em modelar a distribuição de alturas de brasileiros adultos.
 - ▶ É razoável supor, neste caso, que essa distribuição das alturas pode ser modelada por uma normal.
 - ▶ Contudo, note que o modelo só ficará completamente especificado se soubermos os valores dos parâmetros μ e σ^2 .
 - ▶ Uma forma de se obter μ e σ^2 é medir as alturas de todos os brasileiros adultos o que é inviável.
 - ▶ Outra forma é selecionar, de maneira apropriada, uma amostra da população e, a partir dessa amostra, analisa-la e inferir propriedades para toda a população.

Objetivo da inferência estatística

Motivação

- A ideia da inferência estatística consiste em estudar uma população através de evidências fornecidas por uma amostra de observações selecionadas a partir dessa população de interesse.
- Por exemplo, suponha que nosso interesse consiste em modelar a distribuição de alturas de brasileiros adultos.
 - ▶ É razoável supor, neste caso, que essa distribuição das alturas pode ser modelada por uma normal.
 - ▶ Contudo, note que o modelo só ficará completamente especificado se soubermos os valores dos parâmetros μ e σ^2 .
 - ▶ Uma forma de se obter μ e σ^2 é medir as alturas de todos os brasileiros adultos o que é inviável.
 - ▶ Outra forma é selecionar, de maneira apropriada, uma amostra da população e, a partir dessa amostra, analisa-la e inferir propriedades para toda a população.

Relação entre população e amostra




Figure 1: Adaptado de: MONTGOMERY, D. C.; RUNGER, G. C. Estatística Aplicada e Probabilidade para Engenheiros. 2. ed. Rio de Janeiro: Livros Técnicos e Científico, 2003.

Conceitos iniciais

- Como dito acima, a inferência estatística está focada em tirar conclusões a respeito de parâmetros populacionais.
- Considere que estamos querendo estimar um certo parâmetro populacional. Então:
 - Antes dos dados serem coletados, as observações são consideradas variáveis aleatórias, isto é, X_1, X_2, \dots, X_n .

Estatística

Qualquer função das observações em uma amostra é chamada de estatística.

- Por exemplo, \bar{X} (média da amostra) e S^2 (variância da amostra) são exemplos de estatísticas e são, também variáveis aleatórias.

Conceitos iniciais

- Como dito acima, a inferência estatística está focada em tirar conclusões a respeito de parâmetros populacionais.
- Considere que estamos querendo estimar um certo parâmetro populacional. Então:
 - Antes dos dados serem coletados, as observações são consideradas variáveis aleatórias, isto é, X_1, X_2, \dots, X_n .

Estatística

Qualquer função das observações em uma amostra é chamada de estatística.

- Por exemplo, \bar{X} (média da amostra) e S^2 (variância da amostra) são exemplos de estatísticas e são, também variáveis aleatórias.

Conceitos iniciais

- Como dito acima, a inferência estatística está focada em tirar conclusões a respeito de parâmetros populacionais.
- Considere que estamos querendo estimar um certo parâmetro populacional. Então:
 - ▶ Antes dos dados serem coletados, as observações são consideradas variáveis aleatórias, isto é, X_1, X_2, \dots, X_n .

Estatística

Qualquer função das observações em uma amostra é chamada de estatística.

- Por exemplo, \bar{X} (média da amostra) e S^2 (variância da amostra) são exemplos de estatísticas e são, também variáveis aleatórias.

Conceitos iniciais

- Como dito acima, a inferência estatística está focada em tirar conclusões a respeito de parâmetros populacionais.
- Considere que estamos querendo estimar um certo parâmetro populacional. Então:
 - ▶ Antes dos dados serem coletados, as observações são consideradas variáveis aleatórias, isto é, X_1, X_2, \dots, X_n .

Estatística

Qualquer função das observações em uma amostra é chamada de estatística.

- Por exemplo, \bar{X} (média da amostra) e S^2 (variância da amostra) são exemplos de estatísticas e são, também variáveis aleatórias.

Conceitos iniciais

- Como dito acima, a inferência estatística está focada em tirar conclusões a respeito de parâmetros populacionais.
- Considere que estamos querendo estimar um certo parâmetro populacional. Então:
 - ▶ Antes dos dados serem coletados, as observações são consideradas variáveis aleatórias, isto é, X_1, X_2, \dots, X_n .

Estatística

Qualquer função das observações em uma amostra é chamada de estatística.

- Por exemplo, \bar{X} (média da amostra) e S^2 (variância da amostra) são exemplos de estatísticas e são, também variáveis aleatórias.

Estimador pontual

- Em inferência, o símbolo θ é usado para representar parâmetros populacionais, que podem ser por exemplo, a média μ , a variância s^2 ou qualquer outro parâmetro de interesse.
- O objetivo da estimação pontual é determinar, com base nas informações contidas na amostra, um único valor plausível para θ .

Estimador

Um estimador pontual, denotado por $\hat{\theta}$, do parâmetro populacional θ é qualquer função das observações da amostra, ou seja, $\hat{\theta} = h(X_1, X_2, \dots, X_n)$.

Um valor assumido por $\hat{\theta}$, para uma particular amostra observada (após a amostra ser selecionada), é chamado de estimativa pontual.

- Por exemplo, suponha que X seja normalmente distribuída com média μ desconhecida.
 - ▶ A média da amostra \bar{X} é um exemplo de um estimador pontual para μ , isto é, $\hat{\mu} = \bar{X}$.
 - ▶ Após a seleção da amostra, o valor \bar{x} é uma estimativa pontual para μ . Assim, se por exemplo, $x_1 = 30$, $x_2 = 29$, $x_3 = 34$ e $x_4 = 33$ então $\bar{x} = (30 + 29 + 34 + 33)/4$ é a estimativa pontual de μ .

Estimador pontual

- Em inferência, o símbolo θ é usado para representar parâmetros populacionais, que podem ser por exemplo, a média μ , a variância s^2 ou qualquer outro parâmetro de interesse.
- O objetivo da estimação pontual é determinar, com base nas informações contidas na amostra, um único valor plausível para θ .

Estimador

Um estimador pontual, denotado por $\hat{\theta}$, do parâmetro populacional θ é qualquer função das observações da amostra, ou seja, $\hat{\theta} = h(X_1, X_2, \dots, X_n)$.

Um valor assumido por $\hat{\theta}$, para uma particular amostra observada (após a amostra ser selecionada), é chamado de estimativa pontual.

- Por exemplo, suponha que X seja normalmente distribuída com média μ desconhecida.
 - ▶ A média da amostra \bar{X} é um exemplo de um estimador pontual para μ , isto é, $\hat{\mu} = \bar{X}$.
 - ▶ Após a seleção da amostra, o valor \bar{x} é uma estimativa pontual para μ . Assim, se por exemplo, $x_1 = 30$, $x_2 = 29$, $x_3 = 34$ e $x_4 = 33$ então $\bar{x} = (30 + 29 + 34 + 33)/4$ é a estimativa pontual de μ .

Estimador pontual

- Em inferência, o símbolo θ é usado para representar parâmetros populacionais, que podem ser por exemplo, a média μ , a variância s^2 ou qualquer outro parâmetro de interesse.
- O objetivo da estimação pontual é determinar, com base nas informações contidas na amostra, um único valor plausível para θ .

Estimador

Um estimador pontual, denotado por $\hat{\theta}$, do parâmetro populacional θ é qualquer função das observações da amostra, ou seja, $\hat{\theta} = h(X_1, X_2, \dots, X_n)$.

Um valor assumido por $\hat{\theta}$, para uma particular amostra observada (após a amostra ser selecionada), é chamado de estimativa pontual.

- Por exemplo, suponha que X seja normalmente distribuída com média μ desconhecida.
 - ▶ A média da amostra \bar{X} é um exemplo de um estimador pontual para μ , isto é, $\hat{\mu} = \bar{X}$.
 - ▶ Após a seleção da amostra, o valor \bar{x} é uma estimativa pontual para μ . Assim, se por exemplo, $x_1 = 30$, $x_2 = 29$, $x_3 = 34$ e $x_4 = 33$ então $\bar{x} = (30 + 29 + 34 + 33)/4$ é a estimativa pontual de μ .

Estimador pontual

- Em inferência, o símbolo θ é usado para representar parâmetros populacionais, que podem ser por exemplo, a média μ , a variância s^2 ou qualquer outro parâmetro de interesse.
- O objetivo da estimação pontual é determinar, com base nas informações contidas na amostra, um único valor plausível para θ .

Estimador

Um estimador pontual, denotado por $\hat{\theta}$, do parâmetro populacional θ é qualquer função das observações da amostra, ou seja, $\hat{\theta} = h(X_1, X_2, \dots, X_n)$.

Um valor assumido por $\hat{\theta}$, para uma particular amostra observada (após a amostra ser selecionada), é chamado de estimativa pontual.

- Por exemplo, suponha que X seja normalmente distribuída com média μ desconhecida.
 - ▶ A média da amostra \bar{X} é um exemplo de um estimador pontual para μ , isto é, $\hat{\mu} = \bar{X}$.
 - ▶ Após a seleção da amostra, o valor \bar{x} é uma estimativa pontual para μ . Assim, se por exemplo, $x_1 = 30$, $x_2 = 29$, $x_3 = 34$ e $x_4 = 33$ então $\bar{x} = (30 + 29 + 34 + 33)/4$ é a estimativa pontual de μ .

Estimador pontual

- Em inferência, o símbolo θ é usado para representar parâmetros populacionais, que podem ser por exemplo, a média μ , a variância s^2 ou qualquer outro parâmetro de interesse.
- O objetivo da estimação pontual é determinar, com base nas informações contidas na amostra, um único valor plausível para θ .

Estimador

Um estimador pontual, denotado por $\hat{\theta}$, do parâmetro populacional θ é qualquer função das observações da amostra, ou seja, $\hat{\theta} = h(X_1, X_2, \dots, X_n)$.

Um valor assumido por $\hat{\theta}$, para uma particular amostra observada (após a amostra ser selecionada), é chamado de estimativa pontual.

- Por exemplo, suponha que X seja normalmente distribuída com média μ desconhecida.
 - A média da amostra \bar{X} é um exemplo de um estimador pontual para μ , isto é, $\hat{\mu} = \bar{X}$.
 - Após a seleção da amostra, o valor \bar{x} é uma estimativa pontual para μ . Assim, se por exemplo, $x_1 = 30$, $x_2 = 29$, $x_3 = 34$ e $x_4 = 33$ então $\bar{x} = (30 + 29 + 34 + 33)/4$ é a estimativa pontual de μ .

Estimador pontual

- Em inferência, o símbolo θ é usado para representar parâmetros populacionais, que podem ser por exemplo, a média μ , a variância s^2 ou qualquer outro parâmetro de interesse.
- O objetivo da estimação pontual é determinar, com base nas informações contidas na amostra, um único valor plausível para θ .

Estimador

Um estimador pontual, denotado por $\hat{\theta}$, do parâmetro populacional θ é qualquer função das observações da amostra, ou seja, $\hat{\theta} = h(X_1, X_2, \dots, X_n)$.

Um valor assumido por $\hat{\theta}$, para uma particular amostra observada (após a amostra ser selecionada), é chamado de estimativa pontual.

- Por exemplo, suponha que X seja normalmente distribuída com média μ desconhecida.
 - ▶ A média da amostra \bar{X} é um exemplo de um estimador pontual para μ , isto é, $\hat{\mu} = \bar{X}$.
 - ▶ Após a seleção da amostra, o valor \bar{x} é uma estimativa pontual para μ . Assim, se por exemplo, $x_1 = 30$, $x_2 = 29$, $x_3 = 34$ e $x_4 = 33$ então $\bar{x} = (30 + 29 + 34 + 33)/4$ é a estimativa pontual de μ .

Estimador pontual

- Em inferência, o símbolo θ é usado para representar parâmetros populacionais, que podem ser por exemplo, a média μ , a variância s^2 ou qualquer outro parâmetro de interesse.
- O objetivo da estimação pontual é determinar, com base nas informações contidas na amostra, um único valor plausível para θ .

Estimador

Um estimador pontual, denotado por $\hat{\theta}$, do parâmetro populacional θ é qualquer função das observações da amostra, ou seja, $\hat{\theta} = h(X_1, X_2, \dots, X_n)$.

Um valor assumido por $\hat{\theta}$, para uma particular amostra observada (após a amostra ser selecionada), é chamado de estimativa pontual.

- Por exemplo, suponha que X seja normalmente distribuída com média μ desconhecida.
 - ▶ A média da amostra \bar{X} é um exemplo de um estimador pontual para μ , isto é, $\hat{\mu} = \bar{X}$.
 - ▶ Após a seleção da amostra, o valor \bar{x} é uma estimativa pontual para μ . Assim, se por exemplo, $x_1 = 30$, $x_2 = 29$, $x_3 = 34$ e $x_4 = 33$ então $\bar{x} = (30 + 29 + 34 + 33)/4$ é a estimativa pontual de μ .

Amostra aleatória

- Em nossos estudos a seguir, estaremos trabalhando com amostras aleatórias, ou seja, com um conjunto de variáveis aleatórias independentes e identicamente distribuídas.

Formalmente, as variáveis X_1, X_2, \dots, X_n são ditas serem amostra aleatória de tamanho n se:

- ▶ X_1, X_2, \dots, X_n forem variáveis aleatórias independentes;
- ▶ Cada X_i tiver a mesma distribuição de probabilidade.

- A suposição de amostra aleatória é de fundamental importância.
- Se a amostra considerada no estudo não for aleatória, então os métodos estatísticos não funcionarão de forma apropriada, podendo levar a decisões incorretas.

Amostra aleatória

Amostra aleatória

- Em nossos estudos a seguir, estaremos trabalhando com amostras aleatórias, ou seja, com um conjunto de variáveis aleatórias independentes e identicamente distribuídas.

Formalmente, as variáveis X_1, X_2, \dots, X_n são ditas serem amostra aleatória de tamanho n se:

- ▶ X_1, X_2, \dots, X_n forem variáveis aleatórias independentes;
 - ▶ Cada X_i tiver a mesma distribuição de probabilidade.
-
- A suposição de amostra aleatória é de fundamental importância.
 - Se a amostra considerada no estudo não for aleatória, então os métodos estatísticos não funcionarão de forma apropriada, podendo levar a decisões incorretas.

Amostra aleatória

Amostra aleatória

- Em nossos estudos a seguir, estaremos trabalhando com amostras aleatórias, ou seja, com um conjunto de variáveis aleatórias independentes e identicamente distribuídas.

Formalmente, as variáveis X_1, X_2, \dots, X_n são ditas serem amostra aleatória de tamanho n se:

- ▶ X_1, X_2, \dots, X_n forem variáveis aleatórias independentes;
 - ▶ Cada X_i tiver a mesma distribuição de probabilidade.
- A suposição de amostra aleatória é de fundamental importância.
 - Se a amostra considerada no estudo não for aleatória, então os métodos estatísticos não funcionarão de forma apropriada, podendo levar a decisões incorretas.

Amostra aleatória

Amostra aleatória

- Em nossos estudos a seguir, estaremos trabalhando com amostras aleatórias, ou seja, com um conjunto de variáveis aleatórias independentes e identicamente distribuídas.

Formalmente, as variáveis X_1, X_2, \dots, X_n são ditas serem amostra aleatória de tamanho n se:

- ▶ X_1, X_2, \dots, X_n forem variáveis aleatórias independentes;
 - ▶ Cada X_i tiver a mesma distribuição de probabilidade.
-
- A suposição de amostra aleatória é de fundamental importância.
 - Se a amostra considerada no estudo não for aleatória, então os métodos estatísticos não funcionarão de forma apropriada, podendo levar a decisões incorretas.

Amostra aleatória

Amostra aleatória

- Em nossos estudos a seguir, estaremos trabalhando com amostras aleatórias, ou seja, com um conjunto de variáveis aleatórias independentes e identicamente distribuídas.

Formalmente, as variáveis X_1, X_2, \dots, X_n são ditas serem amostra aleatória de tamanho n se:

- ▶ X_1, X_2, \dots, X_n forem variáveis aleatórias independentes;
 - ▶ Cada X_i tiver a mesma distribuição de probabilidade.
- A suposição de amostra aleatória é de fundamental importância.
 - Se a amostra considerada no estudo não for aleatória, então os métodos estatísticos não funcionarão de forma apropriada, podendo levar a decisões incorretas.

Amostra aleatória

Amostra aleatória

- Em nossos estudos a seguir, estaremos trabalhando com amostras aleatórias, ou seja, com um conjunto de variáveis aleatórias independentes e identicamente distribuídas.

Formalmente, as variáveis X_1, X_2, \dots, X_n são ditas serem amostra aleatória de tamanho n se:

- ▶ X_1, X_2, \dots, X_n forem variáveis aleatórias independentes;
 - ▶ Cada X_i tiver a mesma distribuição de probabilidade.
-
- A suposição de amostra aleatória é de fundamental importância.
 - Se a amostra considerada no estudo não for aleatória, então os métodos estatísticos não funcionarão de forma apropriada, podendo levar a decisões incorretas.

Estimador não viesado (não tendencioso)

- O problema da estimação pontual é, então, determinar uma função $\hat{\theta} = h(X_1, X_2, \dots, X_n)$ que deva estar "perto", de acordo com algum critério, do valor verdadeiro do parâmetro desconhecido θ .
- O primeiro critério que iremos estudar é o de estimadores não viesados.

Estimadores não viesados

Definição: O estimador $\hat{\theta}$ é um estimador não viesado (não tendencioso) para o parâmetro θ , se

$$E(\hat{\theta}) = \theta.$$

Se o estimador for viesado (tendencioso), então a diferença

$$E(\hat{\theta}) - \theta$$

é chamada de viés (ou tendência) do estimador.

- Note, na definição acima, que intuitivamente a identidade $E(\hat{\theta}) = \theta$ estabelece que a média da distribuição de probabilidade de $\hat{\theta}$ é igual a θ .

Estimador não viesado (não tendencioso)

- O problema da estimação pontual é, então, determinar uma função $\hat{\theta} = h(X_1, X_2, \dots, X_n)$ que deva estar "perto", de acordo com algum critério, do valor verdadeiro do parâmetro desconhecido θ .
- O primeiro critério que iremos estudar é o de estimadores não viesados.

Estimadores não viesados

Definição: O estimador $\hat{\theta}$ é um estimador não viesado (não tendencioso) para o parâmetro θ , se

$$E(\hat{\theta}) = \theta.$$

Se o estimador for viesado (tendencioso), então a diferença

$$E(\hat{\theta}) - \theta$$

é chamada de viés (ou tendência) do estimador.

- Note, na definição acima, que intuitivamente a identidade $E(\hat{\theta}) = \theta$ estabelece que a média da distribuição de probabilidade de $\hat{\theta}$ é igual a θ .

Estimador não viesado (não tendencioso)

- O problema da estimação pontual é, então, determinar uma função $\hat{\theta} = h(X_1, X_2, \dots, X_n)$ que deva estar "perto", de acordo com algum critério, do valor verdadeiro do parâmetro desconhecido θ .
- O primeiro critério que iremos estudar é o de estimadores não viesados.

Estimadores não viesados

Definição: O estimador $\hat{\theta}$ é um estimador não viesado (não tendencioso) para o parâmetro θ , se

$$E(\hat{\theta}) = \theta.$$

Se o estimador for viesado (tendencioso), então a diferença

$$E(\hat{\theta}) - \theta$$

é chamada de viés (ou tendência) do estimador.

- Note, na definição acima, que intuitivamente a identidade $E(\hat{\theta}) = \theta$ estabelece que a média da distribuição de probabilidade de $\hat{\theta}$ é igual a θ .

Estimador não viesado (não tendencioso)

- O problema da estimação pontual é, então, determinar uma função $\hat{\theta} = h(X_1, X_2, \dots, X_n)$ que deva estar "perto", de acordo com algum critério, do valor verdadeiro do parâmetro desconhecido θ .
- O primeiro critério que iremos estudar é o de estimadores não viesados.

Estimadores não viesados

Definição: O estimador $\hat{\theta}$ é um estimador não viesado (não tendencioso) para o parâmetro θ , se

$$E(\hat{\theta}) = \theta.$$

Se o estimador for viesado (tendencioso), então a diferença

$$E(\hat{\theta}) - \theta$$

é chamada de viés (ou tendência) do estimador.

- Note, na definição acima, que intuitivamente a identidade $E(\hat{\theta}) = \theta$ estabelece que a média da distribuição de probabilidade de $\hat{\theta}$ é igual a θ .

Estimador não viesado (não tendencioso)

- O problema da estimação pontual é, então, determinar uma função $\hat{\theta} = h(X_1, X_2, \dots, X_n)$ que deva estar "perto", de acordo com algum critério, do valor verdadeiro do parâmetro desconhecido θ .
- O primeiro critério que iremos estudar é o de estimadores não viesados.

Estimadores não viesados

Definição: O estimador $\hat{\theta}$ é um estimador não viesado (não tendencioso) para o parâmetro θ , se

$$E(\hat{\theta}) = \theta.$$

Se o estimador for viesado (tendencioso), então a diferença

$$E(\hat{\theta}) - \theta$$

é chamada de viés (ou tendência) do estimador.

- Note, na definição acima, que intuitivamente a identidade $E(\hat{\theta}) = \theta$ estabelece que a média da distribuição de probabilidade de $\hat{\theta}$ é igual a θ .

Estimador não viesado (não tendencioso)

- O problema da estimação pontual é, então, determinar uma função $\hat{\theta} = h(X_1, X_2, \dots, X_n)$ que deva estar "perto", de acordo com algum critério, do valor verdadeiro do parâmetro desconhecido θ .
- O primeiro critério que iremos estudar é o de estimadores não viesados.

Estimadores não viesados

Definição: O estimador $\hat{\theta}$ é um estimador não viesado (não tendencioso) para o parâmetro θ , se

$$E(\hat{\theta}) = \theta.$$

Se o estimador for viesado (tendencioso), então a diferença

$$E(\hat{\theta}) - \theta$$

é chamada de viés (ou tendência) do estimador.

- Note, na definição acima, que intuitivamente a identidade $E(\hat{\theta}) = \theta$ estabelece que a média da distribuição de probabilidade de $\hat{\theta}$ é igual a θ .

Exemplo

- O exemplo a seguir, ilustra a ideia de estimadores não viesados.

Exemplo: Seja X uma variável aleatória com média μ e variância σ^2 . Seja X_1, X_2, \dots, X_n uma amostra aleatória de tamanho n de uma população representada por X . Mostre que:

- (a) A média amostral \bar{X} é um estimador não viesado de μ ;
- (b) A variância amostral S^2 é não viesado para σ^2 .

Exemplo

- O exemplo a seguir, ilustra a ideia de estimadores não viesados.

Exemplo: Seja X uma variável aleatória com média μ e variância σ^2 . Seja X_1, X_2, \dots, X_n uma amostra aleatória de tamanho n de uma população representada por X . Mostre que:

- (a) A média amostral \bar{X} é um estimador não viesado de μ ;
- (b) A variância amostral S^2 é não viesado para σ^2 .

Exemplo

- O exemplo a seguir, ilustra a ideia de estimadores não viesados.

Exemplo: Seja X uma variável aleatória com média μ e variância σ^2 . Seja X_1, X_2, \dots, X_n uma amostra aleatória de tamanho n de uma população representada por X . Mostre que:

- (a) A média amostral \bar{X} é um estimador não viesado de μ ;
- (b) A variância amostral S^2 é não viesado para σ^2 .

Exemplo

- O exemplo a seguir, ilustra a ideia de estimadores não viesados.

Exemplo: Seja X uma variável aleatória com média μ e variância σ^2 . Seja X_1, X_2, \dots, X_n uma amostra aleatória de tamanho n de uma população representada por X . Mostre que:

- (a) A média amostral \bar{X} é um estimador não viesado de μ ;
- (b) A variância amostral S^2 é não viesado para σ^2 .

Alguns resultados importantes

Média e variância de combinação linear de variáveis aleatórias

Antes de solucionarmos esse exercício é importante ter em mente dos seguintes resultados que serão úteis:

- Se X_1, X_2, \dots, X_n são variáveis aleatórias e c_1, c_2, \dots, c_n são constantes então se $Y = c_1X_1 + c_2X_2 + \dots + c_nX_n$, então

$$E(Y) = c_1E(X_1) + c_2E(X_2) + \dots + c_nE(X_n).$$

E ainda, se X_1, X_2, \dots, X_n são variáveis aleatórias independentes, então

$$Var(Y) = c_1^2 Var(X_1) + c_2^2 Var(X_2) + \dots + c_n^2 Var(X_n).$$

- Recorde ainda que quando estudamos variância de variáveis aleatórias vimos que $Var(X) = \sum_{x_i} x_i^2 f(x_i) - \mu^2$ (X discreta) e $Var(X) = \int_{-\infty}^{\infty} x^2 f(x) dx - \mu^2$. (X contínua). Ou seja, a variância pode ser calculada da forma:

$$Var(X) = E(X^2) - E(X)^2$$

Alguns resultados importantes

Média e variância de combinação linear de variáveis aleatórias

Antes de solucionarmos esse exercício é importante ter em mente dos seguintes resultados que serão úteis:

- Se X_1, X_2, \dots, X_n são variáveis aleatórias e c_1, c_2, \dots, c_n são constantes então se $Y = c_1X_1 + c_2X_2 + \dots + c_nX_n$, então

$$E(Y) = c_1E(X_1) + c_2E(X_2) + \dots + c_nE(X_n).$$

E ainda, se X_1, X_2, \dots, X_n são variáveis aleatórias independentes, então

$$Var(Y) = c_1^2 Var(X_1) + c_2^2 Var(X_2) + \dots + c_n^2 Var(X_n).$$

- Recorde ainda que quando estudamos variância de variáveis aleatórias vimos que $Var(X) = \sum_{x_j} x_j^2 f(x_j) - \mu^2$ (X discreta) e $Var(X) = \int_{-\infty}^{\infty} x^2 f(x) dx - \mu^2$. (X contínua). Ou seja, a variância pode ser calculada da forma:

$$Var(X) = E(X^2) - E(X)^2$$

Alguns resultados importantes

Média e variância de combinação linear de variáveis aleatórias

Antes de solucionarmos esse exercício é importante ter em mente dos seguintes resultados que serão úteis:

- Se X_1, X_2, \dots, X_n são variáveis aleatórias e c_1, c_2, \dots, c_n são constantes então se $Y = c_1X_1 + c_2X_2 + \dots + c_nX_n$, então

$$E(Y) = c_1E(X_1) + c_2E(X_2) + \dots + c_nE(X_n).$$

E ainda, se X_1, X_2, \dots, X_n são variáveis aleatórias independentes, então

$$Var(Y) = c_1^2 Var(X_1) + c_2^2 Var(X_2) + \dots + c_n^2 Var(X_n).$$

- Recorde ainda que quando estudamos variância de variáveis aleatórias vimos que $Var(X) = \sum_{x_j} x_j^2 f(x_j) - \mu^2$ (X discreta) e $Var(X) = \int_{-\infty}^{\infty} x^2 f(x) dx - \mu^2$. (X contínua). Ou seja, a variância pode ser calculada da forma:

$$Var(X) = E(X^2) - E(X)^2$$

Alguns resultados importantes

Média e variância de combinação linear de variáveis aleatórias

Antes de solucionarmos esse exercício é importante ter em mente dos seguintes resultados que serão úteis:

- Se X_1, X_2, \dots, X_n são variáveis aleatórias e c_1, c_2, \dots, c_n são constantes então se $Y = c_1X_1 + c_2X_2 + \dots + c_nX_n$, então

$$E(Y) = c_1E(X_1) + c_2E(X_2) + \dots + c_nE(X_n).$$

E ainda, se X_1, X_2, \dots, X_n são variáveis aleatórias independentes, então

$$Var(Y) = c_1^2 Var(X_1) + c_2^2 Var(X_2) + \dots + c_n^2 Var(X_n).$$

- Recorde ainda que quando estudamos variância de variáveis aleatórias vimos que $Var(X) = \sum_{x_j} x_j^2 f(x_j) - \mu^2$ (X discreta) e $Var(X) = \int_{-\infty}^{\infty} x^2 f(x) dx - \mu^2$. (X contínua). Ou seja, a variância pode ser calculada da forma:

$$Var(X) = E(X^2) - E(X)^2$$

Alguns resultados importantes

Média e variância de combinação linear de variáveis aleatórias

Antes de solucionarmos esse exercício é importante ter em mente dos seguintes resultados que serão úteis:

- Se X_1, X_2, \dots, X_n são variáveis aleatórias e c_1, c_2, \dots, c_n são constantes então se $Y = c_1X_1 + c_2X_2 + \dots + c_nX_n$, então

$$E(Y) = c_1E(X_1) + c_2E(X_2) + \dots + c_nE(X_n).$$

E ainda, se X_1, X_2, \dots, X_n são variáveis aleatórias independentes, então

$$Var(Y) = c_1^2 Var(X_1) + c_2^2 Var(X_2) + \dots + c_n^2 Var(X_n).$$

- Recorde ainda que quando estudamos variância de variáveis aleatórias vimos que $Var(X) = \sum_{x_i} x_i^2 f(x_i) - \mu^2$ (X discreta) e $Var(X) = \int_{-\infty}^{\infty} x^2 f(x) dx - \mu^2$. (X contínua). Ou seja, a variância pode ser calculada da forma:

$$Var(X) = E(X^2) - E(X)^2$$

Solução do exercício

- Note que no item (a) do exercício acima queremos mostrar que \bar{X} é estimador não viesado de μ , ou seja, mostrar que

$$E(\bar{X}) = \mu.$$

Mas note que

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E(X_1 + X_2 + \dots + X_n) = \frac{1}{n} (E(X_1) + E(X_2) + \dots + E(X_n))$$

Como X_1, X_2, \dots, X_n é amostra aleatória de X com média μ , então $E(X_i) = \mu$, para $i = 1, 2, \dots, n$. Logo,

$$E(\bar{X}) = \frac{1}{n} (\mu + \mu + \dots + \mu) = \frac{1}{n} (n\mu) = \mu.$$

Portanto, \bar{X} é estimador não viesado de μ .

Solução do exercício

- Note que no item (a) do exercício acima queremos mostrar que \bar{X} é estimador não viesado de μ , ou seja, mostrar que

$$E(\bar{X}) = \mu.$$

Mas note que

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E(X_1 + X_2 + \dots + X_n) = \frac{1}{n} (E(X_1) + E(X_2) + \dots + E(X_n))$$

Como X_1, X_2, \dots, X_n é amostra aleatória de X com média μ , então $E(X_i) = \mu$, para $i = 1, 2, \dots, n$. Logo,

$$E(\bar{X}) = \frac{1}{n} (\mu + \mu + \dots + \mu) = \frac{1}{n} (n\mu) = \mu.$$

Portanto, \bar{X} é estimador não viesado de μ .

Solução do exercício

- Note que no item (a) do exercício acima queremos mostrar que \bar{X} é estimador não viesado de μ , ou seja, mostrar que

$$E(\bar{X}) = \mu.$$

Mas note que

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E(X_1 + X_2 + \dots + X_n) = \frac{1}{n} (E(X_1) + E(X_2) + \dots + E(X_n))$$

Como X_1, X_2, \dots, X_n é amostra aleatória de X com média μ , então $E(X_i) = \mu$, para $i = 1, 2, \dots, n$. Logo,

$$E(\bar{X}) = \frac{1}{n} (\mu + \mu + \dots + \mu) = \frac{1}{n} (n\mu) = \mu.$$

Portanto, \bar{X} é estimador não viesado de μ .

Solução do exercício

- Note que no item (a) do exercício acima queremos mostrar que \bar{X} é estimador não viesado de μ , ou seja, mostrar que

$$E(\bar{X}) = \mu.$$

Mas note que

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E(X_1 + X_2 + \dots + X_n) = \frac{1}{n} (E(X_1) + E(X_2) + \dots + E(X_n))$$

Como X_1, X_2, \dots, X_n é amostra aleatória de X com média μ , então $E(X_i) = \mu$, para $i = 1, 2, \dots, n$. Logo,

$$E(\bar{X}) = \frac{1}{n} (\mu + \mu + \dots + \mu) = \frac{1}{n} (n\mu) = \mu.$$

Portanto, \bar{X} é estimador não viesado de μ .

Solução do exercício

- Note que no item (a) do exercício acima queremos mostrar que \bar{X} é estimador não viesado de μ , ou seja, mostrar que

$$E(\bar{X}) = \mu.$$

Mas note que

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E(X_1 + X_2 + \dots + X_n) = \frac{1}{n} (E(X_1) + E(X_2) + \dots + E(X_n))$$

Como X_1, X_2, \dots, X_n é amostra aleatória de X com média μ , então $E(X_i) = \mu$, para $i = 1, 2, \dots, n$. Logo,

$$E(\bar{X}) = \frac{1}{n} (\mu + \mu + \dots + \mu) = \frac{1}{n} (n\mu) = \mu.$$

Portanto, \bar{X} é estimador não viesado de μ .

Solução do exercício

- Note que no item (a) do exercício acima queremos mostrar que \bar{X} é estimador não viesado de μ , ou seja, mostrar que

$$E(\bar{X}) = \mu.$$

Mas note que

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E(X_1 + X_2 + \dots + X_n) = \frac{1}{n} (E(X_1) + E(X_2) + \dots + E(X_n))$$

Como X_1, X_2, \dots, X_n é amostra aleatória de X com média μ , então $E(X_i) = \mu$, para $i = 1, 2, \dots, n$. Logo,

$$E(\bar{X}) = \frac{1}{n} (\mu + \mu + \dots + \mu) = \frac{1}{n} (n\mu) = \mu.$$

Portanto, \bar{X} é estimador não viesado de μ .

Solução do exercício

- Note que no item (a) do exercício acima queremos mostrar que \bar{X} é estimador não viesado de μ , ou seja, mostrar que

$$E(\bar{X}) = \mu.$$

Mas note que

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E(X_1 + X_2 + \dots + X_n) = \frac{1}{n} (E(X_1) + E(X_2) + \dots + E(X_n))$$

Como X_1, X_2, \dots, X_n é amostra aleatória de X com média μ , então $E(X_i) = \mu$, para $i = 1, 2, \dots, n$. Logo,

$$E(\bar{X}) = \frac{1}{n} (\mu + \mu + \dots + \mu) = \frac{1}{n} (n\mu) = \mu.$$

Portanto, \bar{X} é estimador não viesado de μ .

Solução do exercício

- Note que no item (a) do exercício acima queremos mostrar que \bar{X} é estimador não viesado de μ , ou seja, mostrar que

$$E(\bar{X}) = \mu.$$

Mas note que

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E(X_1 + X_2 + \dots + X_n) = \frac{1}{n} (E(X_1) + E(X_2) + \dots + E(X_n))$$

Como X_1, X_2, \dots, X_n é amostra aleatória de X com média μ , então $E(X_i) = \mu$, para $i = 1, 2, \dots, n$. Logo,

$$E(\bar{X}) = \frac{1}{n} (\mu + \mu + \dots + \mu) = \frac{1}{n} (n\mu) = \mu.$$

Portanto, \bar{X} é estimador não viesado de μ .

Solução do exercício

- Note que no item (a) do exercício acima queremos mostrar que \bar{X} é estimador não viesado de μ , ou seja, mostrar que

$$E(\bar{X}) = \mu.$$

Mas note que

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E(X_1 + X_2 + \dots + X_n) = \frac{1}{n} (E(X_1) + E(X_2) + \dots + E(X_n))$$

Como X_1, X_2, \dots, X_n é amostra aleatória de X com média μ , então $E(X_i) = \mu$, para $i = 1, 2, \dots, n$. Logo,

$$E(\bar{X}) = \frac{1}{n} (\mu + \mu + \dots + \mu) = \frac{1}{n} (n\mu) = \mu.$$

Portanto, \bar{X} é estimador não viesado de μ .

Solução do exercício

- Note que no item (a) do exercício acima queremos mostrar que \bar{X} é estimador não viesado de μ , ou seja, mostrar que

$$E(\bar{X}) = \mu.$$

Mas note que

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E(X_1 + X_2 + \dots + X_n) = \frac{1}{n} (E(X_1) + E(X_2) + \dots + E(X_n))$$

Como X_1, X_2, \dots, X_n é amostra aleatória de X com média μ , então $E(X_i) = \mu$, para $i = 1, 2, \dots, n$. Logo,

$$E(\bar{X}) = \frac{1}{n} (\mu + \mu + \dots + \mu) = \frac{1}{n} (n\mu) = \mu.$$

Portanto, \bar{X} é estimador não viesado de μ .

Cont. do exercício

- No item (b) queremos mostrar que S^2 é estimador não viesado de σ^2 , ou seja, mostrar que $E(S^2) = \sigma^2$. Note que

$$E(S^2) = E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)\right)$$

ou seja

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2\right)$$

ou ainda

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)$$

Usando a linearidade da média, temos

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2) \right)$$

Cont. do exercício

- No item (b) queremos mostrar que S^2 é estimador não viesado de σ^2 , ou seja, mostrar que $E(S^2) = \sigma^2$. Note que

$$E(S^2) = E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)\right)$$

ou seja

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2\right)$$

ou ainda

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)$$

Usando a linearidade da média, temos

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2) \right)$$

Cont. do exercício

- No item (b) queremos mostrar que S^2 é estimador não viesado de σ^2 , ou seja, mostrar que $E(S^2) = \sigma^2$. Note que

$$E(S^2) = E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)\right)$$

ou seja

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2\right)$$

ou ainda

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)$$

Usando a linearidade da média, temos

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2)\right)$$

Cont. do exercício

- No item (b) queremos mostrar que S^2 é estimador não viesado de σ^2 , ou seja, mostrar que $E(S^2) = \sigma^2$. Note que

$$E(S^2) = E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)\right)$$

ou seja

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2\right)$$

ou ainda

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)$$

Usando a linearidade da média, temos

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2) \right)$$

Cont. do exercício

- No item (b) queremos mostrar que S^2 é estimador não viesado de σ^2 , ou seja, mostrar que $E(S^2) = \sigma^2$. Note que

$$E(S^2) = E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)\right)$$

ou seja

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2\right)$$

ou ainda

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)$$

Usando a linearidade da média, temos

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2) \right)$$

Cont. do exercício

- No item (b) queremos mostrar que S^2 é estimador não viesado de σ^2 , ou seja, mostrar que $E(S^2) = \sigma^2$. Note que

$$E(S^2) = E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)\right)$$

ou seja

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2\right)$$

ou ainda

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)$$

Usando a linearidade da média, temos

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2) \right)$$

Cont. do exercício

- No item (b) queremos mostrar que S^2 é estimador não viesado de σ^2 , ou seja, mostrar que $E(S^2) = \sigma^2$. Note que

$$E(S^2) = E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)\right)$$

ou seja

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2\right)$$

ou ainda

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)$$

Usando a linearidade da média, temos

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2) \right)$$

Cont. do exercício

Temos que $E(S^2) = \frac{1}{n-1} (\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2))$.

- Note que precisamos obter $E(X_i^2)$ e $E(\bar{X}^2)$. Contudo, usando o fato de que $Var(X) = E(X^2) - E(X)^2$ temos que:

$$E(X_i^2) = Var(X_i) + E(X_i)^2 = \sigma^2 + \mu^2.$$

e ainda

$$E(\bar{X}^2) = Var(\bar{X}) + E(\bar{X})^2 = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) + \mu^2$$

Observe ainda que $Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} (\sum_{i=1}^n Var(X_i)) = \frac{1}{n^2} (\sum_{i=1}^n \sigma^2) = \frac{\sigma^2}{n}$.

- Ou seja, $E(X_i^2) = \sigma^2 + \mu^2$ e $E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$. Voltando para o cálculo de $E(S^2)$, temos que

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right) = \frac{1}{n-1} (n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2)$$

Ou seja,

$$E(S^2) = \frac{1}{n-1} (n\sigma^2 - \sigma^2) = \frac{1}{n-1} (n-1)\sigma^2 = \sigma^2.$$

Portanto, S^2 é não viesado para σ^2 .

Cont. do exercício

Temos que $E(S^2) = \frac{1}{n-1} (\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2))$.

- Note que precisamos obter $E(X_i^2)$ e $E(\bar{X}^2)$. Contudo, usando o fato de que $Var(X) = E(X^2) - E(X)^2$ temos que:

$$E(X_i^2) = Var(X_i) + E(X_i)^2 = \sigma^2 + \mu^2.$$

e ainda

$$E(\bar{X}^2) = Var(\bar{X}) + E(\bar{X})^2 = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) + \mu^2$$

Observe ainda que $Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} (\sum_{i=1}^n Var(X_i)) = \frac{1}{n^2} (\sum_{i=1}^n \sigma^2) = \frac{\sigma^2}{n}$.

- Ou seja, $E(X_i^2) = \sigma^2 + \mu^2$ e $E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$. Voltando para o cálculo de $E(S^2)$, temos que

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right) = \frac{1}{n-1} (n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2)$$

Ou seja,

$$E(S^2) = \frac{1}{n-1} (n\sigma^2 - \sigma^2) = \frac{1}{n-1} (n-1)\sigma^2 = \sigma^2.$$

Portanto, S^2 é não viesado para σ^2 .

Cont. do exercício

Temos que $E(S^2) = \frac{1}{n-1} (\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2))$.

- Note que precisamos obter $E(X_i^2)$ e $E(\bar{X}^2)$. Contudo, usando o fato de que $Var(X) = E(X^2) - E(X)^2$ temos que:

$$E(X_i^2) = Var(X_i) + E(X_i)^2 = \sigma^2 + \mu^2.$$

e ainda

$$E(\bar{X}^2) = Var(\bar{X}) + E(\bar{X})^2 = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) + \mu^2$$

Observe ainda que $Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} (\sum_{i=1}^n Var(X_i)) = \frac{1}{n^2} (\sum_{i=1}^n \sigma^2) = \frac{\sigma^2}{n}$.

- Ou seja, $E(X_i^2) = \sigma^2 + \mu^2$ e $E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$. Voltando para o cálculo de $E(S^2)$, temos que

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right) = \frac{1}{n-1} (n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2)$$

Ou seja,

$$E(S^2) = \frac{1}{n-1} (n\sigma^2 - \sigma^2) = \frac{1}{n-1} (n-1)\sigma^2 = \sigma^2.$$

Portanto, S^2 é não viesado para σ^2 .

Cont. do exercício

Temos que $E(S^2) = \frac{1}{n-1} (\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2))$.

- Note que precisamos obter $E(X_i^2)$ e $E(\bar{X}^2)$. Contudo, usando o fato de que $Var(X) = E(X^2) - E(X)^2$ temos que:

$$E(X_i^2) = Var(X_i) + E(X_i)^2 = \sigma^2 + \mu^2.$$

e ainda

$$E(\bar{X}^2) = Var(\bar{X}) + E(\bar{X})^2 = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) + \mu^2$$

Observe ainda que $Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} (\sum_{i=1}^n Var(X_i)) = \frac{1}{n^2} (\sum_{i=1}^n \sigma^2) = \frac{\sigma^2}{n}$.

- Ou seja, $E(X_i^2) = \sigma^2 + \mu^2$ e $E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$. Voltando para o cálculo de $E(S^2)$, temos que

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right) = \frac{1}{n-1} (n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2)$$

Ou seja,

$$E(S^2) = \frac{1}{n-1} (n\sigma^2 - \sigma^2) = \frac{1}{n-1} (n-1)\sigma^2 = \sigma^2.$$

Portanto, S^2 é não viesado para σ^2 .

Cont. do exercício

Temos que $E(S^2) = \frac{1}{n-1} (\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2))$.

- Note que precisamos obter $E(X_i^2)$ e $E(\bar{X}^2)$. Contudo, usando o fato de que $Var(X) = E(X^2) - E(X)^2$ temos que:

$$E(X_i^2) = Var(X_i) + E(X_i)^2 = \sigma^2 + \mu^2.$$

e ainda

$$E(\bar{X}^2) = Var(\bar{X}) + E(\bar{X})^2 = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) + \mu^2$$

Observe ainda que $Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} (\sum_{i=1}^n Var(X_i)) = \frac{1}{n^2} (\sum_{i=1}^n \sigma^2) = \frac{\sigma^2}{n}$.

- Ou seja, $E(X_i^2) = \sigma^2 + \mu^2$ e $E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$. Voltando para o cálculo de $E(S^2)$, temos que

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right) = \frac{1}{n-1} (n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2)$$

Ou seja,

$$E(S^2) = \frac{1}{n-1} (n\sigma^2 - \sigma^2) = \frac{1}{n-1} (n-1)\sigma^2 = \sigma^2.$$

Portanto, S^2 é não viesado para σ^2 .

Cont. do exercício

Temos que $E(S^2) = \frac{1}{n-1} (\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2))$.

- Note que precisamos obter $E(X_i^2)$ e $E(\bar{X}^2)$. Contudo, usando o fato de que $Var(X) = E(X^2) - E(X)^2$ temos que:

$$E(X_i^2) = Var(X_i) + E(X_i)^2 = \sigma^2 + \mu^2.$$

e ainda

$$E(\bar{X}^2) = Var(\bar{X}) + E(\bar{X})^2 = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) + \mu^2$$

Observe ainda que $Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} (\sum_{i=1}^n Var(X_i)) = \frac{1}{n^2} (\sum_{i=1}^n \sigma^2) = \frac{\sigma^2}{n}$.

- Ou seja, $E(X_i^2) = \sigma^2 + \mu^2$ e $E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$. Voltando para o cálculo de $E(S^2)$, temos que

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right) = \frac{1}{n-1} (n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2)$$

Ou seja,

$$E(S^2) = \frac{1}{n-1} (n\sigma^2 - \sigma^2) = \frac{1}{n-1} (n-1)\sigma^2 = \sigma^2.$$

Portanto, S^2 é não viesado para σ^2 .

Cont. do exercício

Temos que $E(S^2) = \frac{1}{n-1} (\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2))$.

- Note que precisamos obter $E(X_i^2)$ e $E(\bar{X}^2)$. Contudo, usando o fato de que $Var(X) = E(X^2) - E(X)^2$ temos que:

$$E(X_i^2) = Var(X_i) + E(X_i)^2 = \sigma^2 + \mu^2.$$

e ainda

$$E(\bar{X}^2) = Var(\bar{X}) + E(\bar{X})^2 = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) + \mu^2$$

Observe ainda que $Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} (\sum_{i=1}^n Var(X_i)) = \frac{1}{n^2} (\sum_{i=1}^n \sigma^2) = \frac{\sigma^2}{n}$.

- Ou seja, $E(X_i^2) = \sigma^2 + \mu^2$ e $E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$. Voltando para o cálculo de $E(S^2)$, temos que

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right) = \frac{1}{n-1} (n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2)$$

Ou seja,

$$E(S^2) = \frac{1}{n-1} (n\sigma^2 - \sigma^2) = \frac{1}{n-1} (n-1)\sigma^2 = \sigma^2.$$

Portanto, S^2 é não viesado para σ^2 .

Cont. do exercício

Temos que $E(S^2) = \frac{1}{n-1} (\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2))$.

- Note que precisamos obter $E(X_i^2)$ e $E(\bar{X}^2)$. Contudo, usando o fato de que $Var(X) = E(X^2) - E(X)^2$ temos que:

$$E(X_i^2) = Var(X_i) + E(X_i)^2 = \sigma^2 + \mu^2.$$

e ainda

$$E(\bar{X}^2) = Var(\bar{X}) + E(\bar{X})^2 = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) + \mu^2$$

Observe ainda que $Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} (\sum_{i=1}^n Var(X_i)) = \frac{1}{n^2} (\sum_{i=1}^n \sigma^2) = \frac{\sigma^2}{n}$.

- Ou seja, $E(X_i^2) = \sigma^2 + \mu^2$ e $E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$. Voltando para o cálculo de $E(S^2)$, temos que

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right) = \frac{1}{n-1} (n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2)$$

Ou seja,

$$E(S^2) = \frac{1}{n-1} (n\sigma^2 - \sigma^2) = \frac{1}{n-1} (n-1)\sigma^2 = \sigma^2.$$

Portanto, S^2 é não viesado para σ^2 .

Cont. do exercício

Temos que $E(S^2) = \frac{1}{n-1} (\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2))$.

- Note que precisamos obter $E(X_i^2)$ e $E(\bar{X}^2)$. Contudo, usando o fato de que $Var(X) = E(X^2) - E(X)^2$ temos que:

$$E(X_i^2) = Var(X_i) + E(X_i)^2 = \sigma^2 + \mu^2.$$

e ainda

$$E(\bar{X}^2) = Var(\bar{X}) + E(\bar{X})^2 = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) + \mu^2$$

Observe ainda que $Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} (\sum_{i=1}^n Var(X_i)) = \frac{1}{n^2} (\sum_{i=1}^n \sigma^2) = \frac{\sigma^2}{n}$.

- Ou seja, $E(X_i^2) = \sigma^2 + \mu^2$ e $E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$. Voltando para o cálculo de $E(S^2)$, temos que

$$E(S^2) = \frac{1}{n-1} \left(\sum_{i=1}^n (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right) = \frac{1}{n-1} (n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2)$$

Ou seja,

$$E(S^2) = \frac{1}{n-1} (n\sigma^2 - \sigma^2) = \frac{1}{n-1} (n-1)\sigma^2 = \sigma^2.$$

Portanto, S^2 é não viesado para σ^2 .

Estimador não viesado de variância mínima

- Suponha que θ é um parâmetro populacional e $\hat{\theta}_1$ e $\hat{\theta}_2$ são dois estimadores não viesados de θ , ou seja,

$$E(\hat{\theta}_1) = E(\hat{\theta}_2) = \theta.$$

Note que esses dois estimadores são indiferentes se o critério adotado for não vies.

- Contudo, suponha que $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$. Então, naturalmente, na seleção dos dois estimadores o estimador $\hat{\theta}_1$ é mais adequado, uma vez que possui menor variância.
- Um princípio lógico de estimação, ao selecionar um entre vários estimadores, é escolher o estimador com menor variância.

Estimador não viesado de variância mínima

Se consideramos todos os estimadores não viesados de um parâmetro θ , aquele com a menor variância será chamado de estimador não viesado de variância mínima - ENVVM.

Estimador não viesado de variância mínima

- Suponha que θ é um parâmetro populacional e $\hat{\theta}_1$ e $\hat{\theta}_2$ são dois estimadores não viesados de θ , ou seja,

$$E(\hat{\theta}_1) = E(\hat{\theta}_2) = \theta.$$

Note que esses dois estimadores são indiferentes se o critério adotado for não vies.

- Contudo, suponha que $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$. Então, naturalmente, na seleção dos dois estimadores o estimador $\hat{\theta}_1$ é mais adequado, uma vez que possui menor variância.
- Um princípio lógico de estimação, ao selecionar um entre vários estimadores, é escolher o estimador com menor variância.

Estimador não viesado de variância mínima

Se consideramos todos os estimadores não viesados de um parâmetro θ , aquele com a menor variância será chamado de estimador não viesado de variância mínima - ENVVM.

Estimador não viesado de variância mínima

- Suponha que θ é um parâmetro populacional e $\hat{\theta}_1$ e $\hat{\theta}_2$ são dois estimadores não viesados de θ , ou seja,

$$E(\hat{\theta}_1) = E(\hat{\theta}_2) = \theta.$$

Note que esses dois estimadores são indiferentes se o critério adotado for não vies.

- Contudo, suponha que $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$. Então, naturalmente, na seleção dos dois estimadores o estimador $\hat{\theta}_1$ é mais adequado, uma vez que possui menor variância.
- Um princípio lógico de estimação, ao selecionar um entre vários estimadores, é escolher o estimador com menor variância.

Estimador não viesado de variância mínima

Se consideramos todos os estimadores não viesados de um parâmetro θ , aquele com a menor variância será chamado de estimador não viesado de variância mínima - ENVVM.

Estimador não viesado de variância mínima

- Suponha que θ é um parâmetro populacional e $\hat{\theta}_1$ e $\hat{\theta}_2$ são dois estimadores não viesados de θ , ou seja,

$$E(\hat{\theta}_1) = E(\hat{\theta}_2) = \theta.$$

Note que esses dois estimadores são indiferentes se o critério adotado for não vies.

- Contudo, suponha que $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$. Então, naturalmente, na seleção dos dois estimadores o estimador $\hat{\theta}_1$ é mais adequado, uma vez que possui menor variância.
- Um princípio lógico de estimação, ao selecionar um entre vários estimadores, é escolher o estimador com menor variância.

Estimador não viesado de variância mínima

Se consideramos todos os estimadores não viesados de um parâmetro θ , aquele com a menor variância será chamado de estimador não viesado de variância mínima - ENVVM.

Estimador não viesado de variância mínima

- Suponha que θ é um parâmetro populacional e $\hat{\theta}_1$ e $\hat{\theta}_2$ são dois estimadores não viesados de θ , ou seja,

$$E(\hat{\theta}_1) = E(\hat{\theta}_2) = \theta.$$

Note que esses dois estimadores são indiferentes se o critério adotado for não vies.

- Contudo, suponha que $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$. Então, naturalmente, na seleção dos dois estimadores o estimador $\hat{\theta}_1$ é mais adequado, uma vez que possui menor variância.
- Um princípio lógico de estimação, ao selecionar um entre vários estimadores, é escolher o estimador com menor variância.

Estimador não viesado de variância mínima

Se consideramos todos os estimadores não viesados de um parâmetro θ , aquele com a menor variância será chamado de estimador não viesado de variância mínima - ENVVM.

Estimador não viesado de variância mínima

- Suponha que θ é um parâmetro populacional e $\hat{\theta}_1$ e $\hat{\theta}_2$ são dois estimadores não viesados de θ , ou seja,

$$E(\hat{\theta}_1) = E(\hat{\theta}_2) = \theta.$$

Note que esses dois estimadores são indiferentes se o critério adotado for não vies.

- Contudo, suponha que $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$. Então, naturalmente, na seleção dos dois estimadores o estimador $\hat{\theta}_1$ é mais adequado, uma vez que possui menor variância.
- Um princípio lógico de estimação, ao selecionar um entre vários estimadores, é escolher o estimador com menor variância.

Estimador não viesado de variância mínima

Se consideramos todos os estimadores não viesados de um parâmetro θ , aquele com a menor variância será chamado de estimador não viesado de variância mínima - ENVVM.

Exemplo

- É possível obter o estimador não viesado de variância mínima em muitas situações práticas. Contudo, essa metodologia de identificação está fora do escopo desse curso.
- Mas, por exemplo, se X_1, X_2, \dots, X_n for uma amostra aleatória de uma normal de média μ e variância σ^2 então é possível mostrar que \bar{X} será o estimador não viesado de variância mínima para μ .
- Em situações que não sabemos se existe um ENVVM, mesmo assim podemos usar o princípio da variância mínima para comparar estimadores.
 - Por exemplo, suponha que X_1, X_2, \dots, X_n seja uma amostra aleatória de uma população não normal de média μ e variância σ^2 . Considere que estamos querendo comparar os dois estimadores abaixo:

$$\hat{\theta}_1 = (\bar{X}) \text{ e } \hat{\theta}_2 = X_i$$

Note que ambos os estimadores são não viesados para μ . Contudo, $\text{Var}(\hat{\theta}_1) = \frac{\sigma^2}{n}$, enquanto que $\text{Var}(\hat{\theta}_2) = \sigma^2$.

- Logo, se $n \geq 2$, como $\text{Var}(\hat{\theta}_1) < \text{Var}(\hat{\theta}_2)$, então o estimador $(\hat{\theta}_1)$ seria um melhor estimador de μ do que uma única observação X_i .

Exemplo

- É possível obter o estimador não viesado de variância mínima em muitas situações práticas. Contudo, essa metodologia de identificação está fora do escopo desse curso.
- Mas, por exemplo, se X_1, X_2, \dots, X_n for uma amostra aleatória de uma normal de média μ e variância σ^2 então é possível mostrar que \bar{X} será o estimador não viesado de variância mínima para μ .
- Em situações que não sabemos se existe um ENVVM, mesmo assim podemos usar o princípio da variância mínima para comparar estimadores.
 - Por exemplo, suponha que X_1, X_2, \dots, X_n seja uma amostra aleatória de uma população não normal de média μ e variância σ^2 . Considere que estamos querendo comparar os dois estimadores abaixo:

$$\hat{\theta}_1 = (\bar{X}) \text{ e } \hat{\theta}_2 = X_i$$

Note que ambos os estimadores são não viesados para μ . Contudo, $Var(\hat{\theta}_1) = \frac{\sigma^2}{n}$, enquanto que $Var(\hat{\theta}_2) = \sigma^2$.

- Logo, se $n \geq 2$, como $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$, então o estimador $(\hat{\theta}_1)$ seria um melhor estimador de μ do que uma única observação X_i .

Exemplo

- É possível obter o estimador não viesado de variância mínima em muitas situações práticas. Contudo, essa metodologia de identificação está fora do escopo desse curso.
- Mas, por exemplo, se X_1, X_2, \dots, X_n for uma amostra aleatória de uma normal de média μ e variância σ^2 então é possível mostrar que \bar{X} será o estimador não viesado de variância mínima para μ .
- Em situações que não sabemos se existe um ENVVM, mesmo assim podemos usar o princípio da variância mínima para comparar estimadores.
 - Por exemplo, suponha que X_1, X_2, \dots, X_n seja uma amostra aleatória de uma população não normal de média μ e variância σ^2 . Considere que estamos querendo comparar os dois estimadores abaixo:

$$\hat{\theta}_1 = (\bar{X}) \text{ e } \hat{\theta}_2 = X_i$$

Note que ambos os estimadores são não viesados para μ . Contudo, $Var(\hat{\theta}_1) = \frac{\sigma^2}{n}$, enquanto que $Var(\hat{\theta}_2) = \sigma^2$.

- Logo, se $n \geq 2$, como $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$, então o estimador $(\hat{\theta}_1)$ seria um melhor estimador de μ do que uma única observação X_i .

Exemplo

- É possível obter o estimador não viesado de variância mínima em muitas situações práticas. Contudo, essa metodologia de identificação está fora do escopo desse curso.
- Mas, por exemplo, se X_1, X_2, \dots, X_n for uma amostra aleatória de uma normal de média μ e variância σ^2 então é possível mostrar que \bar{X} será o estimador não viesado de variância mínima para μ .
- Em situações que não sabemos se existe um ENVVM, mesmo assim podemos usar o princípio da variância mínima para comparar estimadores.
 - ▶ Por exemplo, suponha que X_1, X_2, \dots, X_n seja uma amostra aleatória de uma população não normal de média μ e variância σ^2 . Considere que estamos querendo comparar os dois estimadores abaixo:

$$\hat{\theta}_1 = (\bar{X}) \text{ e } \hat{\theta}_2 = X_i$$

Note que ambos os estimadores são não viesados para μ . Contudo, $\text{Var}(\hat{\theta}_1) = \frac{\sigma^2}{n}$, enquanto que $\text{Var}(\hat{\theta}_2) = \sigma^2$.

- ▶ Logo, se $n \geq 2$, como $\text{Var}(\hat{\theta}_1) < \text{Var}(\hat{\theta}_2)$, então o estimador $(\hat{\theta}_1)$ seria um melhor estimador de μ do que uma única observação X_i .

Exemplo

- É possível obter o estimador não viesado de variância mínima em muitas situações práticas. Contudo, essa metodologia de identificação está fora do escopo desse curso.
- Mas, por exemplo, se X_1, X_2, \dots, X_n for uma amostra aleatória de uma normal de média μ e variância σ^2 então é possível mostrar que \bar{X} será o estimador não viesado de variância mínima para μ .
- Em situações que não sabemos se existe um ENVVM, mesmo assim podemos usar o princípio da variância mínima para comparar estimadores.
 - ▶ Por exemplo, suponha que X_1, X_2, \dots, X_n seja uma amostra aleatória de uma população não normal de média μ e variância σ^2 . Considere que estamos querendo comparar os dois estimadores abaixo:

$$\hat{\theta}_1 = (\bar{X}) \text{ e } \hat{\theta}_2 = X_i$$

Note que ambos os estimadores são não viesados para μ . Contudo, $Var(\hat{\theta}_1) = \frac{\sigma^2}{n}$, enquanto que $Var(\hat{\theta}_2) = \sigma^2$.

- ▶ Logo, se $n \geq 2$, como $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$, então o estimador $(\hat{\theta}_1)$ seria um melhor estimador de μ do que uma única observação X_i .