

# Probabilidade e estatística - Aula 15

## Estimação pontual de parâmetros - Continuação

Dr. Giannini Italino Alves Vieira

Universidade Federal do Ceará - Campus de Crateús

2024

1 Erro quadrático médio

2 Método de momentos

## Recordando

- Na aula passada vimos a ideia geral da estimação de parâmetros e vimos alguns conceitos iniciais importantes.
- Fizemos também um estudo sobre estimadores não viesados;
- Na aula de hoje vamos ver um outro importante conceito da estimação pontual, chamado de erro quadrático médio.
- Adicionalmente, veremos o primeiro método de obtenção de estimadores que iremos estudar, chamado de método de momentos.

## Recordando

- Na aula passada vimos a ideia geral da estimação de parâmetros e vimos alguns conceitos iniciais importantes.
- Fizemos também um estudo sobre estimadores não viesados;
- Na aula de hoje vamos ver um outro importante conceito da estimação pontual, chamado de erro quadrático médio.
- Adicionalmente, veremos o primeiro método de obtenção de estimadores que iremos estudar, chamado de método de momentos.

## Recordando

- Na aula passada vimos a ideia geral da estimação de parâmetros e vimos alguns conceitos iniciais importantes.
- Fizemos também um estudo sobre estimadores não viesados;
- Na aula de hoje vamos ver um outro importante conceito da estimação pontual, chamado de erro quadrático médio.
- Adicionalmente, veremos o primeiro método de obtenção de estimadores que iremos estudar, chamado de método de momentos.

## Recordando

- Na aula passada vimos a ideia geral da estimação de parâmetros e vimos alguns conceitos iniciais importantes.
- Fizemos também um estudo sobre estimadores não viesados;
- Na aula de hoje vamos ver um outro importante conceito da estimação pontual, chamado de erro quadrático médio.
- Adicionalmente, veremos o primeiro método de obtenção de estimadores que iremos estudar, chamado de método de momentos.

# Erro quadrático médio

- Intuitivamente, o erro quadrático médio de um estimador pode ser pensado como sendo uma medida de qualidade do estimador, sendo composta por outras duas medidas, a saber: a variância e o viés do estimador.
- O erro quadrático médio pode ser um critério importante para comparar dois estimadores.
- Formalmente, erro quadrático médio de um estimador, denotado por EQM, é definido da seguinte forma:

## Erro quadrático médio - EQM

**Definição:** Seja  $\hat{\theta}$  um estimador do parâmetro  $\theta$ . O erro quadrático médio de  $\hat{\theta}$  é definido como

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

Ou seja, o EQM do estimador  $\hat{\theta}$  é o valor esperado do quadrado da diferença entre  $\hat{\theta}$  e  $\theta$ .

# Erro quadrático médio

- Intuitivamente, o erro quadrático médio de um estimador pode ser pensado como sendo uma medida de qualidade do estimador, sendo composta por outras duas medidas, a saber: a variância e o viés do estimador.
- O erro quadrático médio pode ser um critério importante para comparar dois estimadores.
- Formalmente, erro quadrático médio de um estimador, denotado por EQM, é definido da seguinte forma:

## Erro quadrático médio - EQM

**Definição:** Seja  $\hat{\theta}$  um estimador do parâmetro  $\theta$ . O erro quadrático médio de  $\hat{\theta}$  é definido como

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

Ou seja, o EQM do estimador  $\hat{\theta}$  é o valor esperado do quadrado da diferença entre  $\hat{\theta}$  e  $\theta$ .



# Erro quadrático médio

- Intuitivamente, o erro quadrático médio de um estimador pode ser pensado como sendo uma medida de qualidade do estimador, sendo composta por outras duas medidas, a saber: a variância e o viés do estimador.
- O erro quadrático médio pode ser um critério importante para comparar dois estimadores.
- Formalmente, erro quadrático médio de um estimador, denotado por EQM, é definido da seguinte forma:

## Erro quadrático médio - EQM

**Definição:** Seja  $\hat{\theta}$  um estimador do parâmetro  $\theta$ . O erro quadrático médio de  $\hat{\theta}$  é definido como

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

Ou seja, o EQM do estimador  $\hat{\theta}$  é o valor esperado do quadrado da diferença entre  $\hat{\theta}$  e  $\theta$ .

# Erro quadrático médio

- Intuitivamente, o erro quadrático médio de um estimador pode ser pensado como sendo uma medida de qualidade do estimador, sendo composta por outras duas medidas, a saber: a variância e o viés do estimador.
- O erro quadrático médio pode ser um critério importante para comparar dois estimadores.
- Formalmente, erro quadrático médio de um estimador, denotado por EQM, é definido da seguinte forma:

## Erro quadrático médio - EQM

**Definição:** Seja  $\hat{\theta}$  um estimador do parâmetro  $\theta$ . O erro quadrático médio de  $\hat{\theta}$  é definido como

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

Ou seja, o EQM do estimador  $\hat{\theta}$  é o valor esperado do quadrado da diferença entre  $\hat{\theta}$  e  $\theta$ .

# Erro quadrático médio

- Intuitivamente, o erro quadrático médio de um estimador pode ser pensado como sendo uma medida de qualidade do estimador, sendo composta por outras duas medidas, a saber: a variância e o viés do estimador.
- O erro quadrático médio pode ser um critério importante para comparar dois estimadores.
- Formalmente, erro quadrático médio de um estimador, denotado por EQM, é definido da seguinte forma:

## Erro quadrático médio - EQM

**Definição:** Seja  $\hat{\theta}$  um estimador do parâmetro  $\theta$ . O erro quadrático médio de  $\hat{\theta}$  é definido como

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

Ou seja, o EQM do estimador  $\hat{\theta}$  é o valor esperado do quadrado da diferença entre  $\hat{\theta}$  e  $\theta$ .

## EQM

Note ainda que o EQM pode ser calculado da seguinte forma:

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2].$$

Note ainda que

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2 + 2(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta) + (E(\hat{\theta}) - \theta)^2].$$

E ainda,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2E[(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta)] + E[(E(\hat{\theta}) - \theta)^2].$$

Note que  $E(\hat{\theta}) - \theta$  é uma constante, então a identidade acima se reduz a

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)E(\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou ainda

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)(E(\hat{\theta}) - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou seja,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2,$$

## EQM

Note ainda que o EQM pode ser calculado da seguinte forma:

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2].$$

Note ainda que

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2 + 2(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta) + (E(\hat{\theta}) - \theta)^2].$$

E ainda,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2E[(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta)] + E[(E(\hat{\theta}) - \theta)^2].$$

Note que  $E(\hat{\theta}) - \theta$  é uma constante, então a identidade acima se reduz a

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)E(\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou ainda

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)(E(\hat{\theta}) - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou seja,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2,$$

## EQM

Note ainda que o EQM pode ser calculado da seguinte forma:

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2].$$

Note ainda que

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2 + 2(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta) + (E(\hat{\theta}) - \theta)^2].$$

E ainda,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2E[(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta)] + E[(E(\hat{\theta}) - \theta)^2].$$

Note que  $E(\hat{\theta}) - \theta$  é uma constante, então a identidade acima se reduz a

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)E(\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou ainda

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)(E(\hat{\theta}) - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou seja,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2,$$

## EQM

Note ainda que o EQM pode ser calculado da seguinte forma:

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2].$$

Note ainda que

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2 + 2(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta) + (E(\hat{\theta}) - \theta)^2].$$

E ainda,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2E[(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta)] + E[(E(\hat{\theta}) - \theta)^2].$$

Note que  $E(\hat{\theta}) - \theta$  é uma constante, então a identidade acima se reduz a

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)E(\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou ainda

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)(E(\hat{\theta}) - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou seja,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2,$$

## EQM

Note ainda que o EQM pode ser calculado da seguinte forma:

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2].$$

Note ainda que

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2 + 2(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta) + (E(\hat{\theta}) - \theta)^2].$$

E ainda,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2E[(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta)] + E[(E(\hat{\theta}) - \theta)^2].$$

Note que  $E(\hat{\theta}) - \theta$  é uma constante, então a identidade acima se reduz a

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)E(\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou ainda

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)(E(\hat{\theta}) - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou seja,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2,$$



## EQM

Note ainda que o EQM pode ser calculado da seguinte forma:

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2].$$

Note ainda que

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2 + 2(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta) + (E(\hat{\theta}) - \theta)^2].$$

E ainda,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2E[(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta)] + E[(E(\hat{\theta}) - \theta)^2].$$

Note que  $E(\hat{\theta}) - \theta$  é uma constante, então a identidade acima se reduz a

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)E(\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou ainda

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)(E(\hat{\theta}) - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou seja,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2,$$

## EQM

Note ainda que o EQM pode ser calculado da seguinte forma:

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2].$$

Note ainda que

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2 + 2(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta) + (E(\hat{\theta}) - \theta)^2].$$

E ainda,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2E[(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta)] + E[(E(\hat{\theta}) - \theta)^2].$$

Note que  $E(\hat{\theta}) - \theta$  é uma constante, então a identidade acima se reduz a

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)E(\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou ainda

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)(E(\hat{\theta}) - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou seja,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2,$$

## EQM

Note ainda que o EQM pode ser calculado da seguinte forma:

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2].$$

Note ainda que

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2 + 2(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta) + (E(\hat{\theta}) - \theta)^2].$$

E ainda,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2E[(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta)] + E[(E(\hat{\theta}) - \theta)^2].$$

Note que  $E(\hat{\theta}) - \theta$  é uma constante, então a identidade acima se reduz a

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)E(\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou ainda

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)(E(\hat{\theta}) - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou seja,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2,$$

## EQM

Note ainda que o EQM pode ser calculado da seguinte forma:

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2].$$

Note ainda que

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2 + 2(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta) + (E(\hat{\theta}) - \theta)^2].$$

E ainda,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2E[(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta)] + E[(E(\hat{\theta}) - \theta)^2].$$

Note que  $E(\hat{\theta}) - \theta$  é uma constante, então a identidade acima se reduz a

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)E(\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou ainda

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + 2(E(\hat{\theta}) - \theta)(E(\hat{\theta}) - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)^2,$$

ou seja,

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2,$$

## EQM

Ou seja, chegamos que o EQM do estimador  $\hat{\theta}$  é dado por

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2.$$

Recorde que  $\text{Var}(X) = E(X - E(X))^2$  e que a diferença  $E(\hat{\theta}) - \theta$  é o viés do estimador. Logo,

$$\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta}) + B(\hat{\theta})^2.$$

em que  $B(\hat{\theta}) = E(\hat{\theta}) - \theta$  é o viés do estimador  $\hat{\theta}$ .

- Portanto, o EQM de um estimador  $\hat{\theta}$  é pode ser calculado como sendo a soma da variância do estimador com o quadrado do viés do estimador.
- Note ainda que para estimadores não viesados o EQM é simplesmente a variância do estimador, ou seja,  $\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta})$ .

## EQM

Ou seja, chegamos que o EQM do estimador  $\hat{\theta}$  é dado por

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2.$$

Recorde que  $\text{Var}(X) = E(X - E(X))^2$  e que a diferença  $E(\hat{\theta}) - \theta$  é o viés do estimador. Logo,

$$\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta}) + B(\hat{\theta})^2.$$

em que  $B(\hat{\theta}) = E(\hat{\theta}) - \theta$  é o viés do estimador  $\hat{\theta}$ .

- Portanto, o EQM de um estimador  $\hat{\theta}$  é pode ser calculado como sendo a soma da variância do estimador com o quadrado do viés do estimador.
- Note ainda que para estimadores não viesados o EQM é simplesmente a variância do estimador, ou seja,  $\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta})$ .

## EQM

Ou seja, chegamos que o EQM do estimador  $\hat{\theta}$  é dado por

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2.$$

Recorde que  $\text{Var}(X) = E(X - E(X))^2$  e que a diferença  $E(\hat{\theta}) - \theta$  é o viés do estimador. Logo,

$$\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta}) + B(\hat{\theta})^2.$$

em que  $B(\hat{\theta}) = E(\hat{\theta}) - \theta$  é o viés do estimador  $\hat{\theta}$ .

- Portanto, o EQM de um estimador  $\hat{\theta}$  é pode ser calculado como sendo a soma da variância do estimador com o quadrado do viés do estimador.
- Note ainda que para estimadores não viesados o EQM é simplesmente a variância do estimador, ou seja,  $\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta})$ .

## EQM

Ou seja, chegamos que o EQM do estimador  $\hat{\theta}$  é dado por

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2.$$

Recorde que  $\text{Var}(X) = E(X - E(X))^2$  e que a diferença  $E(\hat{\theta}) - \theta$  é o viés do estimador. Logo,

$$\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta}) + B(\hat{\theta})^2.$$

em que  $B(\hat{\theta}) = E(\hat{\theta}) - \theta$  é o viés do estimador  $\hat{\theta}$ .

- Portanto, o EQM de um estimador  $\hat{\theta}$  é pode ser calculado como sendo a soma da variância do estimador com o quadrado do viés do estimador.
- Note ainda que para estimadores não viesados o EQM é simplesmente a variância do estimador, ou seja,  $\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta})$ .



## EQM

Ou seja, chegamos que o EQM do estimador  $\hat{\theta}$  é dado por

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2.$$

Recorde que  $\text{Var}(X) = E(X - E(X))^2$  e que a diferença  $E(\hat{\theta}) - \theta$  é o viés do estimador. Logo,

$$\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta}) + B(\hat{\theta})^2.$$

em que  $B(\hat{\theta}) = E(\hat{\theta}) - \theta$  é o viés do estimador  $\hat{\theta}$ .

- Portanto, o EQM de um estimador  $\hat{\theta}$  é pode ser calculado como sendo a soma da variância do estimador com o quadrado do viés do estimador.
- Note ainda que para estimadores não viesados o EQM é simplesmente a variância do estimador, ou seja,  $\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta})$ .

## EQM

Ou seja, chegamos que o EQM do estimador  $\hat{\theta}$  é dado por

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2.$$

Recorde que  $\text{Var}(X) = E(X - E(X))^2$  e que a diferença  $E(\hat{\theta}) - \theta$  é o viés do estimador. Logo,

$$\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta}) + B(\hat{\theta})^2.$$

em que  $B(\hat{\theta}) = E(\hat{\theta}) - \theta$  é o viés do estimador  $\hat{\theta}$ .

- Portanto, o EQM de um estimador  $\hat{\theta}$  é pode ser calculado como sendo a soma da variância do estimador com o quadrado do viés do estimador.
- Note ainda que para estimadores não viesados o EQM é simplesmente a variância do estimador, ou seja,  $\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta})$ .

## EQM

Ou seja, chegamos que o EQM do estimador  $\hat{\theta}$  é dado por

$$\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2.$$

Recorde que  $\text{Var}(X) = E(X - E(X))^2$  e que a diferença  $E(\hat{\theta}) - \theta$  é o viés do estimador. Logo,

$$\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta}) + B(\hat{\theta})^2.$$

em que  $B(\hat{\theta}) = E(\hat{\theta}) - \theta$  é o viés do estimador  $\hat{\theta}$ .

- Portanto, o EQM de um estimador  $\hat{\theta}$  é pode ser calculado como sendo a soma da variância do estimador com o quadrado do viés do estimador.
- Note ainda que para estimadores não viesados o EQM é simplesmente a variância do estimador, ou seja,  $\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta})$ .

# Eficiência relativa

- Como dito anteriormente, o EQM é um critério importante para comparar dois estimadores.

## Eficiência relativa

Se  $\hat{\theta}_1$  e  $\hat{\theta}_2$  são dois estimadores não viesados para um parâmetro  $\theta$  e sejam  $\text{EQM}(\hat{\theta}_1)$  e  $\text{EQM}(\hat{\theta}_2)$  os EQM's de  $\hat{\theta}_1$  e  $\hat{\theta}_2$ , respectivamente. Então, a eficiência relativa de  $\hat{\theta}_2$  em relação a  $\hat{\theta}_1$  é definida como a razão

$$\frac{\text{EQM}(\hat{\theta}_1)}{\text{EQM}(\hat{\theta}_2)}$$

- Se essa eficiência relativa for menor que 1, então o estimador  $\hat{\theta}_1$  é um estimador mais eficiente do que  $\hat{\theta}_2$ , caso contrário  $\hat{\theta}_2$  é mais eficiente que  $\hat{\theta}_1$ .
- Em algumas situações, pode ser preferível trabalhar com um estimador viesado do que com um não viesado, pois o estimador viesado pode ter um menor EQM.

# Eficiência relativa

- Como dito anteriormente, o EQM é um critério importante para comparar dois estimadores.

## Eficiência relativa

Se  $\hat{\theta}_1$  e  $\hat{\theta}_2$  são dois estimadores não viesados para um parâmetro  $\theta$  e sejam  $\text{EQM}(\hat{\theta}_1)$  e  $\text{EQM}(\hat{\theta}_2)$  os EQM's de  $\hat{\theta}_1$  e  $\hat{\theta}_2$ , respectivamente. Então, a eficiência relativa de  $\hat{\theta}_2$  em relação a  $\hat{\theta}_1$  é definida como a razão

$$\frac{\text{EQM}(\hat{\theta}_1)}{\text{EQM}(\hat{\theta}_2)}$$

- Se essa eficiência relativa for menor que 1, então o estimador  $\hat{\theta}_1$  é um estimador mais eficiente do que  $\hat{\theta}_2$ , caso contrário  $\hat{\theta}_2$  é mais eficiente que  $\hat{\theta}_1$ .
- Em algumas situações, pode ser preferível trabalhar com um estimador viesado do que com um não viesado, pois o estimador viesado pode ter um menor EQM.

# Eficiência relativa

- Como dito anteriormente, o EQM é um critério importante para comparar dois estimadores.

## Eficiência relativa

Se  $\hat{\theta}_1$  e  $\hat{\theta}_2$  são dois estimadores não viesados para um parâmetro  $\theta$  e sejam  $\text{EQM}(\hat{\theta}_1)$  e  $\text{EQM}(\hat{\theta}_2)$  os EQM's de  $\hat{\theta}_1$  e  $\hat{\theta}_2$ , respectivamente. Então, a eficiência relativa de  $\hat{\theta}_2$  em relação a  $\hat{\theta}_1$  é definida como a razão

$$\frac{\text{EQM}(\hat{\theta}_1)}{\text{EQM}(\hat{\theta}_2)}$$

- Se essa eficiência relativa for menor que 1, então o estimador  $\hat{\theta}_1$  é um estimador mais eficiente do que  $\hat{\theta}_2$ , caso contrário  $\hat{\theta}_2$  é mais eficiente que  $\hat{\theta}_1$ .
- Em algumas situações, pode ser preferível trabalhar com um estimador viesado do que com um não viesado, pois o estimador viesado pode ter um menor EQM.

# Eficiência relativa

- Como dito anteriormente, o EQM é um critério importante para comparar dois estimadores.

## Eficiência relativa

Se  $\hat{\theta}_1$  e  $\hat{\theta}_2$  são dois estimadores não viesados para um parâmetro  $\theta$  e sejam  $\text{EQM}(\hat{\theta}_1)$  e  $\text{EQM}(\hat{\theta}_2)$  os EQM's de  $\hat{\theta}_1$  e  $\hat{\theta}_2$ , respectivamente. Então, a eficiência relativa de  $\hat{\theta}_2$  em relação a  $\hat{\theta}_1$  é definida como a razão

$$\frac{\text{EQM}(\hat{\theta}_1)}{\text{EQM}(\hat{\theta}_2)}$$

- Se essa eficiência relativa for menor que 1, então o estimador  $\hat{\theta}_1$  é um estimador mais eficiente do que  $\hat{\theta}_2$ , caso contrário  $\hat{\theta}_2$  é mais eficiente que  $\hat{\theta}_1$ .
- Em algumas situações, pode ser preferível trabalhar com um estimador viesado do que com um não viesado, pois o estimador viesado pode ter um menor EQM.

## Exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_7$  uma amostra aleatória proveniente de uma população com média  $\mu$  e variância  $\sigma^2$ . Considere os seguintes estimadores:

$$\hat{\theta}_1 = \frac{X_1 + X_2 + \dots + X_7}{7} \quad \text{e} \quad \hat{\theta}_2 = \frac{2X_1 - X_6 + X_4}{2}$$

- (a) Os dois estimadores são não viesados para  $\mu$ ?
  - (b) Qual o melhor estimador? Em qual sentido ele é melhor? Calcule a eficiência relativa dos dois estimadores.
- Sol.(a):  $\hat{\theta}_1$  é não viesado para  $\mu$ , uma vez que é a média da amostra. Note ainda que

$$E(\hat{\theta}_2) = E\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{2}E(2X_1 - X_6 + X_4)$$

ou seja,

$$E(\hat{\theta}_2) = \frac{1}{2}(2E(X_1) - E(X_6) + E(X_4)) = \frac{1}{2}(2\mu - \mu + \mu) = \mu.$$

Portanto,  $\hat{\theta}_1$  e  $\hat{\theta}_2$  são não viesados para  $\mu$ .



## Exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_7$  uma amostra aleatória proveniente de uma população com média  $\mu$  e variância  $\sigma^2$ . Considere os seguintes estimadores:

$$\hat{\theta}_1 = \frac{X_1 + X_2 + \dots + X_7}{7} \quad \text{e} \quad \hat{\theta}_2 = \frac{2X_1 - X_6 + X_4}{2}$$

- (a) Os dois estimadores são não viesados para  $\mu$ ?
  - (b) Qual o melhor estimador? Em qual sentido ele é melhor? Calcule a eficiência relativa dos dois estimadores.
- Sol.(a):  $\hat{\theta}_1$  é não viesado para  $\mu$ , uma vez que é a média da amostra. Note ainda que

$$E(\hat{\theta}_2) = E\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{2}E(2X_1 - X_6 + X_4)$$

ou seja,

$$E(\hat{\theta}_2) = \frac{1}{2}(2E(X_1) - E(X_6) + E(X_4)) = \frac{1}{2}(2\mu - \mu + \mu) = \mu.$$

Portanto,  $\hat{\theta}_1$  e  $\hat{\theta}_2$  são não viesados para  $\mu$ .

## Exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_7$  uma amostra aleatória proveniente de uma população com média  $\mu$  e variância  $\sigma^2$ . Considere os seguintes estimadores:

$$\hat{\theta}_1 = \frac{X_1 + X_2 + \dots + X_7}{7} \quad \text{e} \quad \hat{\theta}_2 = \frac{2X_1 - X_6 + X_4}{2}$$

- (a) Os dois estimadores são não viesados para  $\mu$ ?
  - (b) Qual o melhor estimador? Em qual sentido ele é melhor? Calcule a eficiência relativa dos dois estimadores.
- Sol.(a):  $\hat{\theta}_1$  é não viesado para  $\mu$ , uma vez que é a média da amostra. Note ainda que

$$E(\hat{\theta}_2) = E\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{2}E(2X_1 - X_6 + X_4)$$

ou seja,

$$E(\hat{\theta}_2) = \frac{1}{2}(2E(X_1) - E(X_6) + E(X_4)) = \frac{1}{2}(2\mu - \mu + \mu) = \mu.$$

Portanto,  $\hat{\theta}_1$  e  $\hat{\theta}_2$  são não viesados para  $\mu$ .

## Exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_7$  uma amostra aleatória proveniente de uma população com média  $\mu$  e variância  $\sigma^2$ . Considere os seguintes estimadores:

$$\hat{\theta}_1 = \frac{X_1 + X_2 + \dots + X_7}{7} \quad \text{e} \quad \hat{\theta}_2 = \frac{2X_1 - X_6 + X_4}{2}$$

- (a) Os dois estimadores são não viesados para  $\mu$ ?
  - (b) Qual o melhor estimador? Em qual sentido ele é melhor? Calcule a eficiência relativa dos dois estimadores.
- Sol.(a):  $\hat{\theta}_1$  é não viesado para  $\mu$ , uma vez que é a média da amostra. Note ainda que

$$E(\hat{\theta}_2) = E\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{2}E(2X_1 - X_6 + X_4)$$

ou seja,

$$E(\hat{\theta}_2) = \frac{1}{2}(2E(X_1) - E(X_6) + E(X_4)) = \frac{1}{2}(2\mu - \mu + \mu) = \mu.$$

Portanto,  $\hat{\theta}_1$  e  $\hat{\theta}_2$  são não viesados para  $\mu$ .

## Exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_7$  uma amostra aleatória proveniente de uma população com média  $\mu$  e variância  $\sigma^2$ . Considere os seguintes estimadores:

$$\hat{\theta}_1 = \frac{X_1 + X_2 + \dots + X_7}{7} \quad \text{e} \quad \hat{\theta}_2 = \frac{2X_1 - X_6 + X_4}{2}$$

- (a) Os dois estimadores são não viesados para  $\mu$ ?
  - (b) Qual o melhor estimador? Em qual sentido ele é melhor? Calcule a eficiência relativa dos dois estimadores.
- Sol.(a):  $\hat{\theta}_1$  é não viesado para  $\mu$ , uma vez que é a média da amostra. Note ainda que

$$E(\hat{\theta}_2) = E\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{2}E(2X_1 - X_6 + X_4)$$

ou seja,

$$E(\hat{\theta}_2) = \frac{1}{2}(2E(X_1) - E(X_6) + E(X_4)) = \frac{1}{2}(2\mu - \mu + \mu) = \mu.$$

Portanto,  $\hat{\theta}_1$  e  $\hat{\theta}_2$  são não viesados para  $\mu$ .

## Exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_7$  uma amostra aleatória proveniente de uma população com média  $\mu$  e variância  $\sigma^2$ . Considere os seguintes estimadores:

$$\hat{\theta}_1 = \frac{X_1 + X_2 + \dots + X_7}{7} \quad \text{e} \quad \hat{\theta}_2 = \frac{2X_1 - X_6 + X_4}{2}$$

- (a) Os dois estimadores são não viesados para  $\mu$ ?
  - (b) Qual o melhor estimador? Em qual sentido ele é melhor? Calcule a eficiência relativa dos dois estimadores.
- Sol.(a):  $\hat{\theta}_1$  é não viesado para  $\mu$ , uma vez que é a média da amostra. Note ainda que

$$E(\hat{\theta}_2) = E\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{2}E(2X_1 - X_6 + X_4)$$

ou seja,

$$E(\hat{\theta}_2) = \frac{1}{2}(2E(X_1) - E(X_6) + E(X_4)) = \frac{1}{2}(2\mu - \mu + \mu) = \mu.$$

Portanto,  $\hat{\theta}_1$  e  $\hat{\theta}_2$  são não viesados para  $\mu$ .

## Cont. do exercício

- Sol. (b): Vamos calcular agora o EQM dos dois estimadores. Note que como ambos são não viesados, então o EQM se reduz a variância dos estimadores. Ou seja,

$$\text{EQM}(\hat{\theta}_1) = \text{Var}(\hat{\theta}_1) = \text{Var}\left(\frac{X_1 + X_2 + \dots + X_7}{7}\right),$$

isto é

$$\text{EQM}(\hat{\theta}_1) = \frac{1}{49}(\text{Var}(X_1) + \text{Var}(X_2) + \dots + \text{Var}(X_7)) = \frac{1}{49}(\sigma^2 + \sigma^2 + \dots + \sigma^2) = \frac{\sigma^2}{7}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_1) = \frac{\sigma^2}{7}$ .

## Cont. do exercício

- Sol. (b): Vamos calcular agora o EQM dos dois estimadores. Note que como ambos são não viesados, então o EQM se reduz a variância dos estimadores. Ou seja,

$$\text{EQM}(\hat{\theta}_1) = \text{Var}(\hat{\theta}_1) = \text{Var}\left(\frac{X_1 + X_2 + \dots + X_7}{7}\right),$$

isto é

$$\text{EQM}(\hat{\theta}_1) = \frac{1}{49}(\text{Var}(X_1) + \text{Var}(X_2) + \dots + \text{Var}(X_7)) = \frac{1}{49}(\sigma^2 + \sigma^2 + \dots + \sigma^2) = \frac{\sigma^2}{7}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_1) = \frac{\sigma^2}{7}$ .

## Cont. do exercício

- Sol. (b): Vamos calcular agora o EQM dos dois estimadores. Note que como ambos são não viesados, então o EQM se reduz a variância dos estimadores. Ou seja,

$$\text{EQM}(\hat{\theta}_1) = \text{Var}(\hat{\theta}_1) = \text{Var}\left(\frac{X_1 + X_2 + \dots + X_7}{7}\right),$$

isto é

$$\text{EQM}(\hat{\theta}_1) = \frac{1}{49}(\text{Var}(X_1) + \text{Var}(X_2) + \dots + \text{Var}(X_7)) = \frac{1}{49}(\sigma^2 + \sigma^2 + \dots + \sigma^2) = \frac{\sigma^2}{7}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_1) = \frac{\sigma^2}{7}$ .



## Cont. do exercício

- Sol. (b): Vamos calcular agora o EQM dos dois estimadores. Note que como ambos são não viesados, então o EQM se reduz a variância dos estimadores. Ou seja,

$$\text{EQM}(\hat{\theta}_1) = \text{Var}(\hat{\theta}_1) = \text{Var}\left(\frac{X_1 + X_2 + \dots + X_7}{7}\right),$$

isto é

$$\text{EQM}(\hat{\theta}_1) = \frac{1}{49}(\text{Var}(X_1) + \text{Var}(X_2) + \dots + \text{Var}(X_7)) = \frac{1}{49}(\sigma^2 + \sigma^2 + \dots + \sigma^2) = \frac{\sigma^2}{7}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_1) = \frac{\sigma^2}{7}$ .

## Cont. do exercício

- Sol. (b): Vamos calcular agora o EQM dos dois estimadores. Note que como ambos são não viesados, então o EQM se reduz a variância dos estimadores. Ou seja,

$$\text{EQM}(\hat{\theta}_1) = \text{Var}(\hat{\theta}_1) = \text{Var}\left(\frac{X_1 + X_2 + \dots + X_7}{7}\right),$$

isto é

$$\text{EQM}(\hat{\theta}_1) = \frac{1}{49}(\text{Var}(X_1) + \text{Var}(X_2) + \dots + \text{Var}(X_7)) = \frac{1}{49}(\sigma^2 + \sigma^2 + \dots + \sigma^2) = \frac{\sigma^2}{7}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_1) = \frac{\sigma^2}{7}$ .

## Cont. do exercício

- Sol. (b): Vamos calcular agora o EQM dos dois estimadores. Note que como ambos são não viesados, então o EQM se reduz a variância dos estimadores. Ou seja,

$$\text{EQM}(\hat{\theta}_1) = \text{Var}(\hat{\theta}_1) = \text{Var}\left(\frac{X_1 + X_2 + \dots + X_7}{7}\right),$$

isto é

$$\text{EQM}(\hat{\theta}_1) = \frac{1}{49}(\text{Var}(X_1) + \text{Var}(X_2) + \dots + \text{Var}(X_7)) = \frac{1}{49}(\sigma^2 + \sigma^2 + \dots + \sigma^2) = \frac{\sigma^2}{7}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_1) = \frac{\sigma^2}{7}$ .

## Cont. do exercício

- Sol. (b): Vamos calcular agora o EQM dos dois estimadores. Note que como ambos são não viesados, então o EQM se reduz a variância dos estimadores. Ou seja,

$$\text{EQM}(\hat{\theta}_1) = \text{Var}(\hat{\theta}_1) = \text{Var}\left(\frac{X_1 + X_2 + \dots + X_7}{7}\right),$$

isto é

$$\text{EQM}(\hat{\theta}_1) = \frac{1}{49} (\text{Var}(X_1) + \text{Var}(X_2) + \dots + \text{Var}(X_7)) = \frac{1}{49} (\sigma^2 + \sigma^2 + \dots + \sigma^2) = \frac{\sigma^2}{7}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_1) = \frac{\sigma^2}{7}$ .

## Cont. do exercício

- Sol. (b): Note ainda que

$$\text{EQM}(\hat{\theta}_2) = \text{Var}(\hat{\theta}_2) = \text{Var}\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{4} \text{Var}(2X_1 + (-X_6) + X_4)$$

isto é

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(\text{Var}(2X_1) + \text{Var}(-X_6) + \text{Var}(X_4))$$

ou seja,

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(4\text{Var}(X_1) + \text{Var}(X_6) + \text{Var}(X_4)) = \frac{1}{4}(4\sigma^2 + \sigma^2 + \sigma^2) = \frac{3\sigma^2}{2}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_2) = \frac{3\sigma^2}{2}$ .

## Cont. do exercício

- Sol. (b): Note ainda que

$$\text{EQM}(\hat{\theta}_2) = \text{Var}(\hat{\theta}_2) = \text{Var}\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{4} \text{Var}(2X_1 + (-X_6) + X_4)$$

isto é

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(\text{Var}(2X_1) + \text{Var}(-X_6) + \text{Var}(X_4))$$

ou seja,

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(4\text{Var}(X_1) + \text{Var}(X_6) + \text{Var}(X_4)) = \frac{1}{4}(4\sigma^2 + \sigma^2 + \sigma^2) = \frac{3\sigma^2}{2}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_2) = \frac{3\sigma^2}{2}$ .

## Cont. do exercício

- Sol. (b): Note ainda que

$$\text{EQM}(\hat{\theta}_2) = \text{Var}(\hat{\theta}_2) = \text{Var}\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{4} \text{Var}(2X_1 + (-X_6) + X_4)$$

isto é

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4} (\text{Var}(2X_1) + \text{Var}(-X_6) + \text{Var}(X_4))$$

ou seja,

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4} (4\text{Var}(X_1) + \text{Var}(X_6) + \text{Var}(X_4)) = \frac{1}{4} (4\sigma^2 + \sigma^2 + \sigma^2) = \frac{3\sigma^2}{2}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_2) = \frac{3\sigma^2}{2}$ .

## Cont. do exercício

- Sol. (b): Note ainda que

$$\text{EQM}(\hat{\theta}_2) = \text{Var}(\hat{\theta}_2) = \text{Var}\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{4} \text{Var}(2X_1 + (-X_6) + X_4)$$

isto é

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4} (\text{Var}(2X_1) + \text{Var}(-X_6) + \text{Var}(X_4))$$

ou seja,

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4} (4\text{Var}(X_1) + \text{Var}(X_6) + \text{Var}(X_4)) = \frac{1}{4} (4\sigma^2 + \sigma^2 + \sigma^2) = \frac{3\sigma^2}{2}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_2) = \frac{3\sigma^2}{2}$ .



## Cont. do exercício

- Sol. (b): Note ainda que

$$\text{EQM}(\hat{\theta}_2) = \text{Var}(\hat{\theta}_2) = \text{Var}\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{4} \text{Var}(2X_1 + (-X_6) + X_4)$$

isto é

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4} (\text{Var}(2X_1) + \text{Var}(-X_6) + \text{Var}(X_4))$$

ou seja,

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4} (4\text{Var}(X_1) + \text{Var}(X_6) + \text{Var}(X_4)) = \frac{1}{4} (4\sigma^2 + \sigma^2 + \sigma^2) = \frac{3\sigma^2}{2}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_2) = \frac{3\sigma^2}{2}$ .

## Cont. do exercício

- Sol. (b): Note ainda que

$$\text{EQM}(\hat{\theta}_2) = \text{Var}(\hat{\theta}_2) = \text{Var}\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{4} \text{Var}(2X_1 + (-X_6) + X_4)$$

isto é

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(\text{Var}(2X_1) + \text{Var}(-X_6) + \text{Var}(X_4))$$

ou seja,

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(4\text{Var}(X_1) + \text{Var}(X_6) + \text{Var}(X_4)) = \frac{1}{4}(4\sigma^2 + \sigma^2 + \sigma^2) = \frac{3\sigma^2}{2}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_2) = \frac{3\sigma^2}{2}$ .

## Cont. do exercício

- Sol. (b): Note ainda que

$$\text{EQM}(\hat{\theta}_2) = \text{Var}(\hat{\theta}_2) = \text{Var}\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{4} \text{Var}(2X_1 + (-X_6) + X_4)$$

isto é

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(\text{Var}(2X_1) + \text{Var}(-X_6) + \text{Var}(X_4))$$

ou seja,

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(4\text{Var}(X_1) + \text{Var}(X_6) + \text{Var}(X_4)) = \frac{1}{4}(4\sigma^2 + \sigma^2 + \sigma^2) = \frac{3\sigma^2}{2}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_2) = \frac{3\sigma^2}{2}$ .

## Cont. do exercício

- Sol. (b): Note ainda que

$$\text{EQM}(\hat{\theta}_2) = \text{Var}(\hat{\theta}_2) = \text{Var}\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{4} \text{Var}(2X_1 + (-X_6) + X_4)$$

isto é

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(\text{Var}(2X_1) + \text{Var}(-X_6) + \text{Var}(X_4))$$

ou seja,

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(4\text{Var}(X_1) + \text{Var}(X_6) + \text{Var}(X_4)) = \frac{1}{4}(4\sigma^2 + \sigma^2 + \sigma^2) = \frac{3\sigma^2}{2}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_2) = \frac{3\sigma^2}{2}$ .

## Cont. do exercício

- Sol. (b): Note ainda que

$$\text{EQM}(\hat{\theta}_2) = \text{Var}(\hat{\theta}_2) = \text{Var}\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{4} \text{Var}(2X_1 + (-X_6) + X_4)$$

isto é

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(\text{Var}(2X_1) + \text{Var}(-X_6) + \text{Var}(X_4))$$

ou seja,

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(4\text{Var}(X_1) + \text{Var}(X_6) + \text{Var}(X_4)) = \frac{1}{4}(4\sigma^2 + \sigma^2 + \sigma^2) = \frac{3\sigma^2}{2}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_2) = \frac{3\sigma^2}{2}$ .

## Cont. do exercício

- Sol. (b): Note ainda que

$$\text{EQM}(\hat{\theta}_2) = \text{Var}(\hat{\theta}_2) = \text{Var}\left(\frac{2X_1 - X_6 + X_4}{2}\right) = \frac{1}{4} \text{Var}(2X_1 + (-X_6) + X_4)$$

isto é

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(\text{Var}(2X_1) + \text{Var}(-X_6) + \text{Var}(X_4))$$

ou seja,

$$\text{EQM}(\hat{\theta}_2) = \frac{1}{4}(4\text{Var}(X_1) + \text{Var}(X_6) + \text{Var}(X_4)) = \frac{1}{4}(4\sigma^2 + \sigma^2 + \sigma^2) = \frac{3\sigma^2}{2}.$$

Portanto, o  $\text{EQM}(\hat{\theta}_2) = \frac{3\sigma^2}{2}$ .

## Cont. do exercício

- Sol. (b): Dessa forma, note que obtivemos que:

- ▶  $\text{EQM}(\hat{\theta}_1) = \text{Var}(\hat{\theta}_1) = \frac{\sigma^2}{7},$
- ▶  $\text{EQM}(\hat{\theta}_2) = \text{Var}(\hat{\theta}_2) = \frac{3\sigma^2}{2}.$

Logo, como  $\text{Var}(\hat{\theta}_1) < \text{Var}(\hat{\theta}_2)$  temos que  $\hat{\theta}_1$  é preferível a  $\hat{\theta}_2$  na estimação de  $\mu$ .

- Note ainda que a eficiência relativa de  $\hat{\theta}_2$  em relação a  $\hat{\theta}_1$  é dada por

$$\frac{\text{EQM}(\hat{\theta}_1)}{\text{EQM}(\hat{\theta}_2)} = \frac{\frac{\sigma^2}{7}}{\frac{3\sigma^2}{2}} = \frac{2}{21} < 1.$$

Portanto,  $\hat{\theta}_1$  é mais eficiente do que  $\hat{\theta}_2$ .

## Cont. do exercício

- Sol. (b): Dessa forma, note que obtivemos que:

- ▶  $EQM(\hat{\theta}_1) = Var(\hat{\theta}_1) = \frac{\sigma^2}{7},$
- ▶  $EQM(\hat{\theta}_2) = Var(\hat{\theta}_2) = \frac{3\sigma^2}{2}.$

Logo, como  $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$  temos que  $\hat{\theta}_1$  é preferível a  $\hat{\theta}_2$  na estimação de  $\mu$ .

- Note ainda que a eficiência relativa de  $\hat{\theta}_2$  em relação a  $\hat{\theta}_1$  é dada por

$$\frac{EQM(\hat{\theta}_1)}{EQM(\hat{\theta}_2)} = \frac{\frac{\sigma^2}{7}}{\frac{3\sigma^2}{2}} = \frac{2}{21} < 1.$$

Portanto,  $\hat{\theta}_1$  é mais eficiente do que  $\hat{\theta}_2$ .



## Cont. do exercício

- Sol. (b): Dessa forma, note que obtivemos que:

- ▶  $EQM(\hat{\theta}_1) = Var(\hat{\theta}_1) = \frac{\sigma^2}{7},$
- ▶  $EQM(\hat{\theta}_2) = Var(\hat{\theta}_2) = \frac{3\sigma^2}{2}.$

Logo, como  $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$  temos que  $\hat{\theta}_1$  é preferível a  $\hat{\theta}_2$  na estimação de  $\mu$ .

- Note ainda que a eficiência relativa de  $\hat{\theta}_2$  em relação a  $\hat{\theta}_1$  é dada por

$$\frac{EQM(\hat{\theta}_1)}{EQM(\hat{\theta}_2)} = \frac{\frac{\sigma^2}{7}}{\frac{3\sigma^2}{2}} = \frac{2}{21} < 1.$$

Portanto,  $\hat{\theta}_1$  é mais eficiente do que  $\hat{\theta}_2$ .

## Cont. do exercício

- Sol. (b): Dessa forma, note que obtivemos que:

- ▶  $EQM(\hat{\theta}_1) = Var(\hat{\theta}_1) = \frac{\sigma^2}{7},$
- ▶  $EQM(\hat{\theta}_2) = Var(\hat{\theta}_2) = \frac{3\sigma^2}{2}.$

Logo, como  $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$  temos que  $\hat{\theta}_1$  é preferível a  $\hat{\theta}_2$  na estimação de  $\mu$ .

- Note ainda que a eficiência relativa de  $\hat{\theta}_2$  em relação a  $\hat{\theta}_1$  é dada por

$$\frac{EQM(\hat{\theta}_1)}{EQM(\hat{\theta}_2)} = \frac{\frac{\sigma^2}{7}}{\frac{3\sigma^2}{2}} = \frac{2}{21} < 1.$$

Portanto,  $\hat{\theta}_1$  é mais eficiente do que  $\hat{\theta}_2$ .

## Cont. do exercício

- Sol. (b): Dessa forma, note que obtivemos que:

- ▶  $EQM(\hat{\theta}_1) = Var(\hat{\theta}_1) = \frac{\sigma^2}{7},$
- ▶  $EQM(\hat{\theta}_2) = Var(\hat{\theta}_2) = \frac{3\sigma^2}{2}.$

Logo, como  $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$  temos que  $\hat{\theta}_1$  é preferível a  $\hat{\theta}_2$  na estimação de  $\mu$ .

- Note ainda que a eficiência relativa de  $\hat{\theta}_2$  em relação a  $\hat{\theta}_1$  é dada por

$$\frac{EQM(\hat{\theta}_1)}{EQM(\hat{\theta}_2)} = \frac{\frac{\sigma^2}{7}}{\frac{3\sigma^2}{2}} = \frac{2}{21} < 1.$$

Portanto,  $\hat{\theta}_1$  é mais eficiente do que  $\hat{\theta}_2$ .

# Métodos de estimação - Método de momentos

- Até agora vimos alguns critérios de avaliação de estimadores.
- Veremos, neste curso, alguns métodos para obter estimadores pontuais, a saber: método de momentos e o método de máxima verossimilhança.
- O método que veremos agora (método de momentos) fornece estimadores que, na maioria dos casos, são bem simples de serem obtidos.
- Veremos, que a ideia da obtenção de estimadores por meio do método de momentos é bem simples e intuitiva, consistindo em obter estimadores igualando-se momentos populacionais aos seus respectivos momentos amostrais.

# Métodos de estimação - Método de momentos

- Até agora vimos alguns critérios de avaliação de estimadores.
- Veremos, neste curso, alguns métodos para obter estimadores pontuais, a saber: método de momentos e o método de máxima verossimilhança.
- O método que veremos agora (método de momentos) fornece estimadores que, na maioria dos casos, são bem simples de serem obtidos.
- Veremos, que a ideia da obtenção de estimadores por meio do método de momentos é bem simples e intuitiva, consistindo em obter estimadores igualando-se momentos populacionais aos seus respectivos momentos amostrais.

# Métodos de estimação - Método de momentos

- Até agora vimos alguns critérios de avaliação de estimadores.
- Veremos, neste curso, alguns métodos para obter estimadores pontuais, a saber: método de momentos e o método de máxima verossimilhança.
- O método que veremos agora (método de momentos) fornece estimadores que, na maioria dos casos, são bem simples de serem obtidos.
- Veremos, que a ideia da obtenção de estimadores por meio do método de momentos é bem simples e intuitiva, consistindo em obter estimadores igualando-se momentos populacionais aos seus respectivos momentos amostrais.

# Métodos de estimação - Método de momentos

- Até agora vimos alguns critérios de avaliação de estimadores.
- Veremos, neste curso, alguns métodos para obter estimadores pontuais, a saber: método de momentos e o método de máxima verossimilhança.
- O método que veremos agora (método de momentos) fornece estimadores que, na maioria dos casos, são bem simples de serem obtidos.
- Veremos, que a ideia da obtenção de estimadores por meio do método de momentos é bem simples e intuitiva, consistindo em obter estimadores igualando-se momentos populacionais aos seus respectivos momentos amostrais.

# Método de momentos

- Antes de estudarmos o método de momentos é importante ter em mente os conceitos a seguir:

## Momentos

Seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população com função de probabilidade (ou densidade)  $f(x)$ . O  $k$ -ésimo momento populacional é definido como

$$E(X^k), \quad k = 1, 2, 3, \dots$$

O correspondente  $k$ -ésimo momento amostral é definido como

$$\frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, 3, \dots$$

- Por exemplo, o primeiro momento da população é  $E(X)$  (média da população), enquanto que o primeiro momento da amostra é  $\frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$  (média da amostra).



# Método de momentos

- Antes de estudarmos o método de momentos é importante ter em mente os conceitos a seguir:

## Momentos

Seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população com função de probabilidade (ou densidade)  $f(x)$ . O  $k$ -ésimo momento populacional é definido como

$$E(X^k), \quad k = 1, 2, 3, \dots$$

O correspondente  $k$ -ésimo momento amostral é definido como

$$\frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, 3, \dots$$

- Por exemplo, o primeiro momento da população é  $E(X)$  (média da população), enquanto que o primeiro momento da amostra é  $\frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$  (média da amostra).

# Método de momentos

- Antes de estudarmos o método de momentos é importante ter em mente os conceitos a seguir:

## Momentos

Seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população com função de probabilidade (ou densidade)  $f(x)$ . O  $k$ -ésimo momento populacional é definido como

$$E(X^k), \quad k = 1, 2, 3, \dots$$

O correspondente  $k$ -ésimo momento amostral é definido como

$$\frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, 3, \dots$$

- Por exemplo, o primeiro momento da população é  $E(X)$  (média da população), enquanto que o primeiro momento da amostra é  $\frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$  (média da amostra).

# Método de momentos

- Antes de estudarmos o método de momentos é importante ter em mente os conceitos a seguir:

## Momentos

Seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população com função de probabilidade (ou densidade)  $f(x)$ . O  $k$ -ésimo momento populacional é definido como

$$E(X^k), \quad k = 1, 2, 3, \dots$$

O correspondente  $k$ -ésimo momento amostral é definido como

$$\frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, 3, \dots$$

- Por exemplo, o primeiro momento da população é  $E(X)$  (média da população), enquanto que o primeiro momento da amostra é  $\frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$  (média da amostra).

# Método de momentos

- Antes de estudarmos o método de momentos é importante ter em mente os conceitos a seguir:

## Momentos

Seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população com função de probabilidade (ou densidade)  $f(x)$ . O  $k$ -ésimo momento populacional é definido como

$$E(X^k), \quad k = 1, 2, 3, \dots$$

O correspondente  $k$ -ésimo momento amostral é definido como

$$\frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, 3, \dots$$

- Por exemplo, o primeiro momento da população é  $E(X)$  (média da população), enquanto que o primeiro momento da amostra é  $\frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$  (média da amostra).

# Método de momentos

- Antes de estudarmos o método de momentos é importante ter em mente os conceitos a seguir:

## Momentos

Seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população com função de probabilidade (ou densidade)  $f(x)$ . O  $k$ -ésimo momento populacional é definido como

$$E(X^k), \quad k = 1, 2, 3, \dots$$

O correspondente  $k$ -ésimo momento amostral é definido como

$$\frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, 3, \dots$$

- Por exemplo, o primeiro momento da população é  $E(X)$  (média da população), enquanto que o primeiro momento da amostra é  $\frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$  (média da amostra).

# Método de momentos

- Antes de estudarmos o método de momentos é importante ter em mente os conceitos a seguir:

## Momentos

Seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população com função de probabilidade (ou densidade)  $f(x)$ . O  $k$ -ésimo momento populacional é definido como

$$E(X^k), \quad k = 1, 2, 3, \dots$$

O correspondente  $k$ -ésimo momento amostral é definido como

$$\frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, 3, \dots$$

- Por exemplo, o primeiro momento da população é  $E(X)$  (média da população), enquanto que o primeiro momento da amostra é  $\frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$  (média da amostra).

# Método de momentos

## Método de momentos

Os estimadores de momentos são obtidos da seguinte forma:

## Método de momentos

Seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população com função de probabilidade (ou densidade)  $f(x)$  dependendo de  $m$  parâmetros desconhecidos, digamos  $\theta_1, \theta_2, \dots, \theta_m$ . Os estimadores de momentos, denotados por  $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ , são obtidos igualando os  $m$  primeiros momentos populacionais aos seus respectivos  $m$  primeiros momentos amostrais e resolvendo as equações resultantes em termos dos parâmetros desconhecidos.

# Método de momentos

## Método de momentos

Os estimadores de momentos são obtidos da seguinte forma:

## Método de momentos

Seja  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população com função de probabilidade (ou densidade)  $f(x)$  dependendo de  $m$  parâmetros desconhecidos, digamos  $\theta_1, \theta_2, \dots, \theta_m$ . Os estimadores de momentos, denotados por  $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ , são obtidos igualando os  $m$  primeiros momentos populacionais aos seus respectivos  $m$  primeiros momentos amostrais e resolvendo as equações resultantes em termos dos parâmetros desconhecidos.



## Exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população  $X$  com distribuição exponencial de parâmetro  $\lambda$ . Vamos obter o estimador de momentos do parâmetro desconhecido  $\lambda$ .

- Note que nesse caso, como só temos um único parâmetro ( $\lambda$ ), então o estimador de momentos de  $\lambda$  é obtido resolvendo a equação

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i.$$

Recorde que se  $X$  é exponencial de parâmetro  $\lambda$  então sua média é  $E(X) = \frac{1}{\lambda}$ . Logo, substituindo na equação acima temos que

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i \Leftrightarrow \frac{1}{\lambda} = \bar{X},$$

ou seja,

$$\hat{\lambda} = \bar{X}^{-1}.$$

Portanto, temos que  $\hat{\lambda} = \bar{X}^{-1}$  é o estimador de momentos do parâmetro  $\lambda$  da exponencial.

## Exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população  $X$  com distribuição exponencial de parâmetro  $\lambda$ . Vamos obter o estimador de momentos do parâmetro desconhecido  $\lambda$ .

- Note que nesse caso, como só temos um único parâmetro ( $\lambda$ ), então o estimador de momentos de  $\lambda$  é obtido resolvendo a equação

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i.$$

Recorde que se  $X$  é exponencial de parâmetro  $\lambda$  então sua média é  $E(X) = \frac{1}{\lambda}$ . Logo, substituindo na equação acima temos que

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i \Leftrightarrow \frac{1}{\lambda} = \bar{X},$$

ou seja,

$$\hat{\lambda} = \bar{X}^{-1}.$$

Portanto, temos que  $\hat{\lambda} = \bar{X}^{-1}$  é o estimador de momentos do parâmetro  $\lambda$  da exponencial.

## Exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população  $X$  com distribuição exponencial de parâmetro  $\lambda$ . Vamos obter o estimador de momentos do parâmetro desconhecido  $\lambda$ .

- Note que nesse caso, como só temos um único parâmetro ( $\lambda$ ), então o estimador de momentos de  $\lambda$  é obtido resolvendo a equação

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i.$$

Recorde que se  $X$  é exponencial de parâmetro  $\lambda$  então sua média é  $E(X) = \frac{1}{\lambda}$ . Logo, substituindo na equação acima temos que

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i \Leftrightarrow \frac{1}{\lambda} = \bar{X},$$

ou seja,

$$\hat{\lambda} = \bar{X}^{-1}.$$

Portanto, temos que  $\hat{\lambda} = \bar{X}^{-1}$  é o estimador de momentos do parâmetro  $\lambda$  da exponencial.

## Exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população  $X$  com distribuição exponencial de parâmetro  $\lambda$ . Vamos obter o estimador de momentos do parâmetro desconhecido  $\lambda$ .

- Note que nesse caso, como só temos um único parâmetro ( $\lambda$ ), então o estimador de momentos de  $\lambda$  é obtido resolvendo a equação

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i.$$

Recorde que se  $X$  é exponencial de parâmetro  $\lambda$  então sua média é  $E(X) = \frac{1}{\lambda}$ .

Logo, substituindo na equação acima temos que

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i \Leftrightarrow \frac{1}{\lambda} = \bar{X},$$

ou seja,

$$\hat{\lambda} = \bar{X}^{-1}.$$

Portanto, temos que  $\hat{\lambda} = \bar{X}^{-1}$  é o estimador de momentos do parâmetro  $\lambda$  da exponencial.

## Exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população  $X$  com distribuição exponencial de parâmetro  $\lambda$ . Vamos obter o estimador de momentos do parâmetro desconhecido  $\lambda$ .

- Note que nesse caso, como só temos um único parâmetro ( $\lambda$ ), então o estimador de momentos de  $\lambda$  é obtido resolvendo a equação

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i.$$

Recorde que se  $X$  é exponencial de parâmetro  $\lambda$  então sua média é  $E(X) = \frac{1}{\lambda}$ . Logo, substituindo na equação acima temos que

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i \Leftrightarrow \frac{1}{\lambda} = \bar{X},$$

ou seja,

$$\hat{\lambda} = \bar{X}^{-1}.$$

Portanto, temos que  $\hat{\lambda} = \bar{X}^{-1}$  é o estimador de momentos do parâmetro  $\lambda$  da exponencial.

## Exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população  $X$  com distribuição exponencial de parâmetro  $\lambda$ . Vamos obter o estimador de momentos do parâmetro desconhecido  $\lambda$ .

- Note que nesse caso, como só temos um único parâmetro ( $\lambda$ ), então o estimador de momentos de  $\lambda$  é obtido resolvendo a equação

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i.$$

Recorde que se  $X$  é exponencial de parâmetro  $\lambda$  então sua média é  $E(X) = \frac{1}{\lambda}$ . Logo, substituindo na equação acima temos que

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i \Leftrightarrow \frac{1}{\lambda} = \bar{X},$$

ou seja,

$$\hat{\lambda} = \bar{X}^{-1}.$$

Portanto, temos que  $\hat{\lambda} = \bar{X}^{-1}$  é o estimador de momentos do parâmetro  $\lambda$  da exponencial.

## Outro exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população  $X$  com distribuição normal de média  $\mu$  e variância  $\sigma^2$ .

- Note que nesse caso, como temos dois parâmetros, então os estimadores de momentos de  $\mu$  e  $\sigma^2$  são obtidos resolvendo as equações

$$\begin{cases} E(X) = \frac{1}{n} \sum_{i=1}^n X_i \\ E(X^2) = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases}$$

Note que da primeira equação, como  $E(X) = \mu$ , resulta que

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

Observe ainda que  $E(X^2) = \text{Var}(X) + E(X)^2 = \sigma^2 + \mu^2$ . Logo, substituindo na segunda equação temos que

$$\sigma^2 + \mu^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \Leftrightarrow \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2$$

## Outro exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população  $X$  com distribuição normal de média  $\mu$  e variância  $\sigma^2$ .

- Note que nesse caso, como temos dois parâmetros, então os estimadores de momentos de  $\mu$  e  $\sigma^2$  são obtidos resolvendo as equações

$$\begin{cases} E(X) = \frac{1}{n} \sum_{i=1}^n X_i \\ E(X^2) = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases}$$

Note que da primeira equação, como  $E(X) = \mu$ , resulta que

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

Observe ainda que  $E(X^2) = \text{Var}(X) + E(X)^2 = \sigma^2 + \mu^2$ . Logo, substituindo na segunda equação temos que

$$\sigma^2 + \mu^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \Leftrightarrow \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2$$



## Outro exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população  $X$  com distribuição normal de média  $\mu$  e variância  $\sigma^2$ .

- Note que nesse caso, como temos dois parâmetros, então os estimadores de momentos de  $\mu$  e  $\sigma^2$  são obtidos resolvendo as equações

$$\begin{cases} E(X) = \frac{1}{n} \sum_{i=1}^n X_i \\ E(X^2) = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases}$$

Note que da primeira equação, como  $E(X) = \mu$ , resulta que

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

Observe ainda que  $E(X^2) = \text{Var}(X) + E(X)^2 = \sigma^2 + \mu^2$ . Logo, substituindo na segunda equação temos que

$$\sigma^2 + \mu^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \Leftrightarrow \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2$$

## Outro exemplo

Exemplo: Sejam  $X_1, X_2, \dots, X_n$  uma amostra aleatória proveniente de uma população  $X$  com distribuição normal de média  $\mu$  e variância  $\sigma^2$ .

- Note que nesse caso, como temos dois parâmetros, então os estimadores de momentos de  $\mu$  e  $\sigma^2$  são obtidos resolvendo as equações

$$\begin{cases} E(X) = \frac{1}{n} \sum_{i=1}^n X_i \\ E(X^2) = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases}$$

Note que da primeira equação, como  $E(X) = \mu$ , resulta que

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

Observe ainda que  $E(X^2) = \text{Var}(X) + E(X)^2 = \sigma^2 + \mu^2$ . Logo, substituindo na segunda equação temos que

$$\sigma^2 + \mu^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \Leftrightarrow \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2$$

## Cont. do exemplo

- Como temos que

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2,$$

então

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \hat{\mu}^2,$$

ou seja,

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

- Portanto, temos que  $\hat{\mu} = \bar{X}$  e  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  são estimadores de momentos dos parâmetros  $\mu$  e  $\sigma^2$ , respectivamente.
- Note que o estimador de momentos de  $\sigma^2$  é viesado.

## Cont. do exemplo

- Como temos que

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2,$$

então

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \hat{\mu}^2,$$

ou seja,

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

- Portanto, temos que  $\hat{\mu} = \bar{X}$  e  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  são estimadores de momentos dos parâmetros  $\mu$  e  $\sigma^2$ , respectivamente.
- Note que o estimador de momentos de  $\sigma^2$  é viesado.

## Cont. do exemplo

- Como temos que

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2,$$

então

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \hat{\mu}^2,$$

ou seja,

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

- Portanto, temos que  $\hat{\mu} = \bar{X}$  e  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  são estimadores de momentos dos parâmetros  $\mu$  e  $\sigma^2$ , respectivamente.
- Note que o estimador de momentos de  $\sigma^2$  é viesado.

## Cont. do exemplo

- Como temos que

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2,$$

então

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \hat{\mu}^2,$$

ou seja,

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

- Portanto, temos que  $\hat{\mu} = \bar{X}$  e  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  são estimadores de momentos dos parâmetros  $\mu$  e  $\sigma^2$ , respectivamente.
- Note que o estimador de momentos de  $\sigma^2$  é viesado.

## Cont. do exemplo

- Como temos que

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2,$$

então

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \hat{\mu}^2,$$

ou seja,

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

- Portanto, temos que  $\hat{\mu} = \bar{X}$  e  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  são estimadores de momentos dos parâmetros  $\mu$  e  $\sigma^2$ , respectivamente.
- Note que o estimador de momentos de  $\sigma^2$  é viesado.

## Cont. do exemplo

- Como temos que

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2,$$

então

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \hat{\mu}^2,$$

ou seja,

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

- Portanto, temos que  $\hat{\mu} = \bar{X}$  e  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  são estimadores de momentos dos parâmetros  $\mu$  e  $\sigma^2$ , respectivamente.
- Note que o estimador de momentos de  $\sigma^2$  é viesado.



## Cont. do exemplo

- Como temos que

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2,$$

então

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \hat{\mu}^2,$$

ou seja,

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

- Portanto, temos que  $\hat{\mu} = \bar{X}$  e  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  são estimadores de momentos dos parâmetros  $\mu$  e  $\sigma^2$ , respectivamente.
- Note que o estimador de momentos de  $\sigma^2$  é viesado.

## Cont. do exemplo

- Como temos que

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2,$$

então

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \hat{\mu}^2,$$

ou seja,

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

- Portanto, temos que  $\hat{\mu} = \bar{X}$  e  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  são estimadores de momentos dos parâmetros  $\mu$  e  $\sigma^2$ , respectivamente.
- Note que o estimador de momentos de  $\sigma^2$  é viesado.