

Probabilidade e estatística - Aula 21

Regressão linear simples - Aula 1

Dr. Giannini Italino Alves Vieira

Universidade Federal do Ceará - Campus de Crateús

2024

1 Regressão linear simples

Regressão linear simples

- Muitos problemas em engenharia envolvem explorar relações entre duas ou mais variáveis.
- Por exemplo:
 - A pressão de um gás em um recipiente está relacionada à temperatura;
 - A velocidade da água em um canal aberto está relacionada à largura do canal;
 - O deslocamento de uma partícula, em certo tempo, está relacionada à sua velocidade.
- Note que no último exemplo, temos que se d_0 for o deslocamento da partícula a partir da origem no tempo $t = 0$ e v for a velocidade, então o deslocamento d_t no tempo t é $d_t = d_0 + vt$.
 - Esse é um exemplo de relação linear determinística, porque o modelo prevê perfeitamente o deslocamento (sem considerar erros).

Regressão linear simples

- Muitos problemas em engenharia envolvem explorar relações entre duas ou mais variáveis.
- Por exemplo:
 - A pressão de um gás em um recipiente está relacionada à temperatura;
 - A velocidade da água em um canal aberto está relacionada à largura do canal;
 - O deslocamento de uma partícula, em certo tempo, está relacionada à sua velocidade.
- Note que no último exemplo, temos que se d_0 for o deslocamento da partícula a partir da origem no tempo $t = 0$ e v for a velocidade, então o deslocamento d_t no tempo t é $d_t = d_0 + vt$.
 - Esse é um exemplo de relação linear determinística, porque o modelo prevê perfeitamente o deslocamento (sem considerar erros).

Regressão linear simples

- Muitos problemas em engenharia envolvem explorar relações entre duas ou mais variáveis.
- Por exemplo:
 - ▶ A pressão de um gás em um recipiente está relacionada à temperatura;
 - ▶ A velocidade da água em um canal aberto está relacionada à largura do canal;
 - ▶ O deslocamento de uma partícula, em certo tempo, está relacionada à sua velocidade.
- Note que no último exemplo, temos que se d_0 for o deslocamento da partícula a partir da origem no tempo $t = 0$ e v for a velocidade, então o deslocamento d_t no tempo t é $d_t = d_0 + vt$.
 - ▶ Esse é um exemplo de relação linear determinística, porque o modelo prevê perfeitamente o deslocamento (sem considerar erros).

Regressão linear simples

- Muitos problemas em engenharia envolvem explorar relações entre duas ou mais variáveis.
- Por exemplo:
 - ▶ A pressão de um gás em um recipiente está relacionada à temperatura;
 - ▶ A velocidade da água em um canal aberto está relacionada à largura do canal;
 - ▶ O deslocamento de uma partícula, em certo tempo, está relacionada à sua velocidade.
- Note que no último exemplo, temos que se d_0 for o deslocamento da partícula a partir da origem no tempo $t = 0$ e v for a velocidade, então o deslocamento d_t no tempo t é $d_t = d_0 + vt$.
 - ▶ Esse é um exemplo de relação linear determinística, porque o modelo prevê perfeitamente o deslocamento (sem considerar erros).

Regressão linear simples

- Muitos problemas em engenharia envolvem explorar relações entre duas ou mais variáveis.
- Por exemplo:
 - ▶ A pressão de um gás em um recipiente está relacionada à temperatura;
 - ▶ A velocidade da água em um canal aberto está relacionada à largura do canal;
 - ▶ O deslocamento de uma partícula, em certo tempo, está relacionada à sua velocidade.
- Note que no último exemplo, temos que se d_0 for o deslocamento da partícula a partir da origem no tempo $t = 0$ e v for a velocidade, então o deslocamento d_t no tempo t é $d_t = d_0 + vt$.
 - ▶ Esse é um exemplo de relação linear determinística, porque o modelo prevê perfeitamente o deslocamento (sem considerar erros).

Regressão linear simples

- Muitos problemas em engenharia envolvem explorar relações entre duas ou mais variáveis.
- Por exemplo:
 - ▶ A pressão de um gás em um recipiente está relacionada à temperatura;
 - ▶ A velocidade da água em um canal aberto está relacionada à largura do canal;
 - ▶ O deslocamento de uma partícula, em certo tempo, está relacionada à sua velocidade.
- Note que no último exemplo, temos que se d_0 for o deslocamento da partícula a partir da origem no tempo $t = 0$ e v for a velocidade, então o deslocamento d_t no tempo t é $d_t = d_0 + vt$.
 - ▶ Esse é um exemplo de relação linear determinística, porque o modelo prevê perfeitamente o deslocamento (sem considerar erros).

Regressão linear simples

- Muitos problemas em engenharia envolvem explorar relações entre duas ou mais variáveis.
- Por exemplo:
 - ▶ A pressão de um gás em um recipiente está relacionada à temperatura;
 - ▶ A velocidade da água em um canal aberto está relacionada à largura do canal;
 - ▶ O deslocamento de uma partícula, em certo tempo, está relacionada à sua velocidade.
- Note que no último exemplo, temos que se d_0 for o deslocamento da partícula a partir da origem no tempo $t = 0$ e v for a velocidade, então o deslocamento d_t no tempo t é $d_t = d_0 + vt$.
 - ▶ Esse é um exemplo de relação linear determinística, porque o modelo prevê perfeitamente o deslocamento (sem considerar erros).

Regressão linear simples

- Contudo, existem situações em que a relação entre as variáveis é não determinística.
- Por exemplo
 - ▶ O consumo de energia (y) em uma casa está relacionado com o tamanho (x) da casa.
- Note que no exemplo anterior, y não pode ser previsto perfeitamente a partir do conhecimento de x correspondente.
- A coleção de ferramentas estatísticas que são usadas para modelar e explorar relações entre variáveis que estão relacionadas de maneira não determinística é chamada de análise de regressão.
- Veremos que a ideia da regressão linear simples consiste em estudar a relação entre uma variável, chamada de variável dependente, e uma única variável independente.

Regressão linear simples

- Contudo, existem situações em que a relação entre as variáveis é não determinística.
- Por exemplo
 - ▶ O consumo de energia (y) em uma casa está relacionado com o tamanho (x) da casa.
- Note que no exemplo anterior, y não pode ser previsto perfeitamente a partir do conhecimento de x correspondente.
- A coleção de ferramentas estatísticas que são usadas para modelar e explorar relações entre variáveis que estão relacionadas de maneira não determinística é chamada de análise de regressão.
- Veremos que a ideia da regressão linear simples consiste em estudar a relação entre uma variável, chamada de variável dependente, e uma única variável independente.

Regressão linear simples

- Contudo, existem situações em que a relação entre as variáveis é não determinística.
- Por exemplo
 - ▶ O consumo de energia (y) em uma casa está relacionado com o tamanho (x) da casa.
- Note que no exemplo anterior, y não pode ser previsto perfeitamente a partir do conhecimento de x correspondente.
- A coleção de ferramentas estatísticas que são usadas para modelar e explorar relações entre variáveis que estão relacionadas de maneira não determinística é chamada de análise de regressão.
- Veremos que a ideia da regressão linear simples consiste em estudar a relação entre uma variável, chamada de variável dependente, e uma única variável independente.

Regressão linear simples

- Contudo, existem situações em que a relação entre as variáveis é não determinística.
- Por exemplo
 - ▶ O consumo de energia (y) em uma casa está relacionado com o tamanho (x) da casa.
- Note que no exemplo anterior, y não pode ser previsto perfeitamente a partir do conhecimento de x correspondente.
- A coleção de ferramentas estatísticas que são usadas para modelar e explorar relações entre variáveis que estão relacionadas de maneira não determinística é chamada de análise de regressão.
- Veremos que a ideia da regressão linear simples consiste em estudar a relação entre uma variável, chamada de variável dependente, e uma única variável independente.

Regressão linear simples

- Contudo, existem situações em que a relação entre as variáveis é não determinística.
- Por exemplo
 - ▶ O consumo de energia (y) em uma casa está relacionado com o tamanho (x) da casa.
- Note que no exemplo anterior, y não pode ser previsto perfeitamente a partir do conhecimento de x correspondente.
- A coleção de ferramentas estatísticas que são usadas para modelar e explorar relações entre variáveis que estão relacionadas de maneira não determinística é chamada de análise de regressão.
- Veremos que a ideia da regressão linear simples consiste em estudar a relação entre uma variável, chamada de variável dependente, e uma única variável independente.

Regressão linear simples

- Contudo, existem situações em que a relação entre as variáveis é não determinística.
- Por exemplo
 - ▶ O consumo de energia (y) em uma casa está relacionado com o tamanho (x) da casa.
- Note que no exemplo anterior, y não pode ser previsto perfeitamente a partir do conhecimento de x correspondente.
- A coleção de ferramentas estatísticas que são usadas para modelar e explorar relações entre variáveis que estão relacionadas de maneira não determinística é chamada de análise de regressão.
- Veremos que a ideia da regressão linear simples consiste em estudar a relação entre uma variável, chamada de variável dependente, e uma única variável independente.

Regressão linear simples

Motivação

- A fim de motivar a ideia considere o exemplo a seguir:

Exemplo: Considere que um laboratório está interessado em medir o efeito da temperatura sobre a potência de um medicamento. Dez amostras de 50g cada foram guardadas a diferentes temperaturas, e após 15 dias mediu-se a potência. Os resultados estão no quadro abaixo:

Temperatura (x)	30°	50°	70°	90°
Potência (y)	38 43	32 26 33	19 27 23	14 21

- A figura abaixo apresenta o diagrama de dispersão dos dados do exercício.
- Cada par (x_i, y_i) é representado como um ponto plotado em um sistema bidimensional de coordenadas.

Regressão linear simples

Motivação

- A fim de motivar a ideia considere o exemplo a seguir:

Exemplo: Considere que um laboratório está interessado em medir o efeito da temperatura sobre a potência de um medicamento. Dez amostras de 50g cada foram guardadas a diferentes temperaturas, e após 15 dias mediu-se a potência. Os resultados estão no quadro abaixo:

Temperatura (x)	30°	50°	70°	90°
Potência (y)	38 43	32 26 33	19 27 23	14 21

- A figura abaixo apresenta o diagrama de dispersão dos dados do exercício.
- Cada par (x_i, y_i) é representado como um ponto plotado em um sistema bidimensional de coordenadas.

Regressão linear simples

Motivação

- A fim de motivar a ideia considere o exemplo a seguir:

Exemplo: Considere que um laboratório está interessado em medir o efeito da temperatura sobre a potência de um medicamento. Dez amostras de 50g cada foram guardadas a diferentes temperaturas, e após 15 dias mediu-se a potência. Os resultados estão no quadro abaixo:

Temperatura (x)	30°	50°	70°	90°
Potência (y)	38 43	32 26 33	19 27 23	14 21

- A figura abaixo apresenta o diagrama de dispersão dos dados do exercício.
- Cada par (x_i, y_i) é representado como um ponto plotado em um sistema bidimensional de coordenadas.

Regressão linear simples

Motivação

- A fim de motivar a ideia considere o exemplo a seguir:

Exemplo: Considere que um laboratório está interessado em medir o efeito da temperatura sobre a potência de um medicamento. Dez amostras de 50g cada foram guardadas a diferentes temperaturas, e após 15 dias mediu-se a potência. Os resultados estão no quadro abaixo:

Temperatura (x)	30°	50°	70°	90°
Potência (y)	38 43	32 26 33	19 27 23	14 21

- A figura abaixo apresenta o diagrama de dispersão dos dados do exercício.
- Cada par (x_i, y_i) é representado como um ponto plotado em um sistema bidimensional de coordenadas.

Regressão linear simples

Motivação

- A fim de motivar a ideia considere o exemplo a seguir:

Exemplo: Considere que um laboratório está interessado em medir o efeito da temperatura sobre a potência de um medicamento. Dez amostras de 50g cada foram guardadas a diferentes temperaturas, e após 15 dias mediu-se a potência. Os resultados estão no quadro abaixo:

Temperatura (x)	30°	50°	70°	90°
Potência (y)	38 43	32 26 33	19 27 23	14 21

- A figura abaixo apresenta o diagrama de dispersão dos dados do exercício.
- Cada par (x_i, y_i) é representado como um ponto plotado em um sistema bidimensional de coordenadas.




Figure 1: Dados do problema anterior. X: Temperatura, Y: Potência

Motivação

- Note que embora nenhuma curva simples passe através de todos os pontos, há uma forte indicação de que os pontos repousam, dispersos de maneira aleatória, em torno de uma reta.
- Logo, é razoável considerar que para um valor fixo de x o valor real de Y seja determinado da forma

$$Y = \beta_0 + \beta_1 x + \epsilon$$

- Em que ϵ é o termo de erro aleatório.
- Veremos que o modelo acima será chamado de regressão de regressão linear simples, porque ele só tem somente um regressor (variável independente).

Motivação

- Note que embora nenhuma curva simples passe através de todos os pontos, há uma forte indicação de que os pontos repousam, dispersos de maneira aleatória, em torno de uma reta.
- Logo, é razoável considerar que para um valor fixo de x o valor real de Y seja determinado da forma

$$Y = \beta_0 + \beta_1 x + \epsilon$$

- Em que ϵ é o termo de erro aleatório.
- Veremos que o modelo acima será chamado de regressão de regressão linear simples, porque ele só tem somente um regressor (variável independente).

Motivação

- Note que embora nenhuma curva simples passe através de todos os pontos, há uma forte indicação de que os pontos repousam, dispersos de maneira aleatória, em torno de uma reta.
- Logo, é razoável considerar que para um valor fixo de x o valor real de Y seja determinado da forma

$$Y = \beta_0 + \beta_1 x + \epsilon$$

- Em que ϵ é o termo de erro aleatório.
- Veremos que o modelo acima será chamado de regressão de regressão linear simples, porque ele só tem somente um regressor (variável independente).

Motivação

- Note que embora nenhuma curva simples passe através de todos os pontos, há uma forte indicação de que os pontos repousam, dispersos de maneira aleatória, em torno de uma reta.
- Logo, é razoável considerar que para um valor fixo de x o valor real de Y seja determinado da forma

$$Y = \beta_0 + \beta_1 x + \epsilon$$

- Em que ϵ é o termo de erro aleatório.
- Veremos que o modelo acima será chamado de regressão de regressão linear simples, porque ele só tem somente um regressor (variável independente).

Motivação

- Note que embora nenhuma curva simples passe através de todos os pontos, há uma forte indicação de que os pontos repousam, dispersos de maneira aleatória, em torno de uma reta.
- Logo, é razoável considerar que para um valor fixo de x o valor real de Y seja determinado da forma

$$Y = \beta_0 + \beta_1 x + \epsilon$$

- Em que ϵ é o termo de erro aleatório.
- Veremos que o modelo acima será chamado de regressão de regressão linear simples, porque ele só tem somente um regressor (variável independente).

Regressão linear simples

- O caso de regressão linear simples considera um único regressor (ou preditor) x e uma variável dependente (ou variável resposta) Y .
- Suponha que a relação verdadeira entre Y e x seja uma linha reta e que a observação Y em cada nível de x seja uma variável aleatória.
- O modelo de regressão linear simples considera que cada observação, Y , possa ser descrita pelo seguinte modelo

$$Y = \beta_0 + \beta_1 x + \epsilon$$

em que β_0 é chamado de o intercepto, β_1 é chamado de inclinação e ϵ é um erro aleatório com média zero e variância σ^2 (desconhecida).

Regressão linear simples

- O caso de regressão linear simples considera um único regressor (ou preditor) x e uma variável dependente (ou variável resposta) Y .
- Suponha que a relação verdadeira entre Y e x seja uma linha reta e que a observação Y em cada nível de x seja uma variável aleatória.
- O modelo de regressão linear simples considera que cada observação, Y , possa ser descrita pelo seguinte modelo

$$Y = \beta_0 + \beta_1 x + \epsilon$$

em que β_0 é chamado de o intercepto, β_1 é chamado de inclinação e ϵ é um erro aleatório com média zero e variância σ^2 (desconhecida).

Regressão linear simples

- O caso de regressão linear simples considera um único regressor (ou preditor) x e uma variável dependente (ou variável resposta) Y .
- Suponha que a relação verdadeira entre Y e x seja uma linha reta e que a observação Y em cada nível de x seja uma variável aleatória.
- O modelo de regressão linear simples considera que cada observação, Y , possa ser descrita pelo seguinte modelo

$$Y = \beta_0 + \beta_1 x + \epsilon$$

em que β_0 é chamado de o intercepto, β_1 é chamado de inclinação e ϵ é um erro aleatório com média zero e variância σ^2 (desconhecida).

Regressão linear simples

- O caso de regressão linear simples considera um único regressor (ou preditor) x e uma variável dependente (ou variável resposta) Y .
- Suponha que a relação verdadeira entre Y e x seja uma linha reta e que a observação Y em cada nível de x seja uma variável aleatória.
- O modelo de regressão linear simples considera que cada observação, Y , possa ser descrita pelo seguinte modelo

$$Y = \beta_0 + \beta_1 x + \epsilon$$

em que β_0 é chamado de o intercepto, β_1 é chamado de inclinação e ϵ é um erro aleatório com média zero e variância σ^2 (desconhecida).

Regressão linear simples

- O caso de regressão linear simples considera um único regressor (ou preditor) x e uma variável dependente (ou variável resposta) Y .
- Suponha que a relação verdadeira entre Y e x seja uma linha reta e que a observação Y em cada nível de x seja uma variável aleatória.
- O modelo de regressão linear simples considera que cada observação, Y , possa ser descrita pelo seguinte modelo

$$Y = \beta_0 + \beta_1 x + \epsilon$$

em que β_0 é chamado de o intercepto, β_1 é chamado de inclinação e ϵ é um erro aleatório com média zero e variância σ^2 (desconhecida).

- Dadas n observações da variável X , digamos, x_1, x_2, \dots, x_n , então teremos n variáveis Y_1, Y_2, \dots, Y_n satisfazendo a equação,

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i = 1, 2, \dots, n$$

- Note que uma amostra de tamanho n consiste de n pares de valores (x_i, y_i) com $i = 1, 2, \dots, n$ que devem satisfazer o seguinte modelo, $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, $i = 1, 2, \dots, n$.
- Suponha que tenhamos n pares de observações, digamos

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

- A figura abaixo ilustra um diagrama de dispersão dos dados observados e uma candidata para a linha estimada de regressão.

- Dadas n observações da variável X , digamos, x_1, x_2, \dots, x_n , então teremos n variáveis Y_1, Y_2, \dots, Y_n satisfazendo a equação,

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i = 1, 2, \dots, n$$

- Note que uma amostra de tamanho n consiste de n pares de valores (x_i, y_i) com $i = 1, 2, \dots, n$ que devem satisfazer o seguinte modelo, $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, $i = 1, 2, \dots, n$.
- Suponha que tenhamos n pares de observações, digamos

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

- A figura abaixo ilustra um diagrama de dispersão dos dados observados e uma candidata para a linha estimada de regressão.

- Dadas n observações da variável X , digamos, x_1, x_2, \dots, x_n , então teremos n variáveis Y_1, Y_2, \dots, Y_n satisfazendo a equação,

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i = 1, 2, \dots, n$$

- Note que uma amostra de tamanho n consiste de n pares de valores (x_i, y_i) com $i = 1, 2, \dots, n$ que devem satisfazer o seguinte modelo, $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, $i = 1, 2, \dots, n$.
- Suponha que tenhamos n pares de observações, digamos

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

- A figura abaixo ilustra um diagrama de dispersão dos dados observados e uma candidata para a linha estimada de regressão.

- Dadas n observações da variável X , digamos, x_1, x_2, \dots, x_n , então teremos n variáveis Y_1, Y_2, \dots, Y_n satisfazendo a equação,

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i = 1, 2, \dots, n$$

- Note que uma amostra de tamanho n consiste de n pares de valores (x_i, y_i) com $i = 1, 2, \dots, n$ que devem satisfazer o seguinte modelo, $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, $i = 1, 2, \dots, n$.
- Suponha que tenhamos n pares de observações, digamos

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

- A figura abaixo ilustra um diagrama de dispersão dos dados observados e uma candidata para a linha estimada de regressão.

- Dadas n observações da variável X , digamos, x_1, x_2, \dots, x_n , então teremos n variáveis Y_1, Y_2, \dots, Y_n satisfazendo a equação,

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i = 1, 2, \dots, n$$

- Note que uma amostra de tamanho n consiste de n pares de valores (x_i, y_i) com $i = 1, 2, \dots, n$ que devem satisfazer o seguinte modelo, $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, $i = 1, 2, \dots, n$.
- Suponha que tenhamos n pares de observações, digamos

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

- A figura abaixo ilustra um diagrama de dispersão dos dados observados e uma candidata para a linha estimada de regressão.

- Dadas n observações da variável X , digamos, x_1, x_2, \dots, x_n , então teremos n variáveis Y_1, Y_2, \dots, Y_n satisfazendo a equação,

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i = 1, 2, \dots, n$$

- Note que uma amostra de tamanho n consiste de n pares de valores (x_i, y_i) com $i = 1, 2, \dots, n$ que devem satisfazer o seguinte modelo, $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, $i = 1, 2, \dots, n$.
- Suponha que tenhamos n pares de observações, digamos

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

- A figura abaixo ilustra um diagrama de dispersão dos dados observados e uma candidata para a linha estimada de regressão.




Figure 2: Desvios dos dados em relação ao modelo estimado de regressão

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- Logo, o problema consiste em encontrar a linha que seja, em algum sentido, o "melhor ajuste", para os dados.
- Uma ideia, comumente usada na estimação dos parâmetros do modelo de regressão é estimar β_0 e β_1 de maneira a minimizar a soma dos quadrados dos desvios, ou seja, minimizar a soma

$$L(\beta_0, \beta_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

- Temos então um problema de encontrar o mínimo de uma função de duas variáveis β_0 e β_1 .

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- Logo, o problema consiste em encontrar a linha que seja, em algum sentido, o "melhor ajuste", para os dados.
- Uma ideia, comumente usada na estimação dos parâmetros do modelo de regressão é estimar β_0 e β_1 de maneira a minimizar a soma dos quadrados dos desvios, ou seja, minimizar a soma

$$L(\beta_0, \beta_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

- Temos então um problema de encontrar o mínimo de uma função de duas variáveis β_0 e β_1 .

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- Logo, o problema consiste em encontrar a linha que seja, em algum sentido, o "melhor ajuste", para os dados.
- Uma ideia, comumente usada na estimação dos parâmetros do modelo de regressão é estimar β_0 e β_1 de maneira a minimizar a soma dos quadrados dos desvios, ou seja, minimizar a soma

$$L(\beta_0, \beta_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

- Temos então um problema de encontrar o mínimo de uma função de duas variáveis β_0 e β_1 .

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- Logo, o problema consiste em encontrar a linha que seja, em algum sentido, o "melhor ajuste", para os dados.
- Uma ideia, comumente usada na estimação dos parâmetros do modelo de regressão é estimar β_0 e β_1 de maneira a minimizar a soma dos quadrados dos desvios, ou seja, minimizar a soma

$$L(\beta_0, \beta_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

- Temos então um problema de encontrar o mínimo de uma função de duas variáveis β_0 e β_1 .

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- Derivando $L(\beta_0, \beta_1)$ com respeito a β_0 e β_1 , igualando a zero, e simplificando temos que as soluções $\hat{\beta}_0$ e $\hat{\beta}_1$ devem satisfazer as equações

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i$$

$$\hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n y_i x_i$$

- As soluções dessas equações, para $\hat{\beta}_0$ e $\hat{\beta}_1$, resultam nos estimadores de mínimos quadrados de β_0 e β_1 .

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- Derivando $L(\beta_0, \beta_1)$ com respeito a β_0 e β_1 , igualando a zero, e simplificando temos que as soluções $\hat{\beta}_0$ e $\hat{\beta}_1$ devem satisfazer as equações

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i$$

$$\hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n y_i x_i$$

- As soluções dessas equações, para $\hat{\beta}_0$ e $\hat{\beta}_1$, resultam nos estimadores de mínimos quadrados de β_0 e β_1 .

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- Derivando $L(\beta_0, \beta_1)$ com respeito a β_0 e β_1 , igualando a zero, e simplificando temos que as soluções $\hat{\beta}_0$ e $\hat{\beta}_1$ devem satisfazer as equações

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i$$

$$\hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n y_i x_i$$

- As soluções dessas equações, para $\hat{\beta}_0$ e $\hat{\beta}_1$, resultam nos estimadores de mínimos quadrados de β_0 e β_1 .

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- Derivando $L(\beta_0, \beta_1)$ com respeito a β_0 e β_1 , igualando a zero, e simplificando temos que as soluções $\hat{\beta}_0$ e $\hat{\beta}_1$ devem satisfazer as equações

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i$$

$$\hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n y_i x_i$$

- As soluções dessas equações, para $\hat{\beta}_0$ e $\hat{\beta}_1$, resultam nos estimadores de mínimos quadrados de β_0 e β_1 .

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- As estimativas de mínimos quadrados do intercepto e da inclinação no modelo de regressão linear simples são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

em que $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ e $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.

- Dessa forma, temos que a linha de regressão ajustada (modelo ajustado ou estimado) é consequentemente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- As estimativas de mínimos quadrados do intercepto e da inclinação no modelo de regressão linear simples são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

em que $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ e $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.

- Dessa forma, temos que a linha de regressão ajustada (modelo ajustado ou estimado) é consequentemente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- As estimativas de mínimos quadrados do intercepto e da inclinação no modelo de regressão linear simples são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

em que $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ e $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.

- Dessa forma, temos que a linha de regressão ajustada (modelo ajustado ou estimado) é consequentemente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- As estimativas de mínimos quadrados do intercepto e da inclinação no modelo de regressão linear simples são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

em que $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ e $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.

- Dessa forma, temos que a linha de regressão ajustada (modelo ajustado ou estimado) é consequentemente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- As estimativas de mínimos quadrados do intercepto e da inclinação no modelo de regressão linear simples são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

em que $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ e $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.

- Dessa forma, temos que a linha de regressão ajustada (modelo ajustado ou estimado) é consequentemente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Estimando β_0 e β_1 - Método dos mínimos Quadrados

- As estimativas de mínimos quadrados do intercepto e da inclinação no modelo de regressão linear simples são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

em que $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ e $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.

- Dessa forma, temos que a linha de regressão ajustada (modelo ajustado ou estimado) é consequentemente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Exemplo

Exemplo: Vamos voltar ao exemplo inicial dessa aula, ou seja, ao problema de medir o efeito da temperatura sobre a potência de um medicamento. Recorde que nossos dados são:

Temperatura (x)	30°	50°	70°	90°
Potência (y)	38 43	32 26 33	19 27 23	14 21

- Vamos ajustar um modelo de regressão para esses dados.
- Recorde que para ajustar o modelo precisamos obter $\hat{\beta}_0$ e $\hat{\beta}_1$
- Note que nossos dados são:

(30, 38), (30, 43), (50, 32), (50, 26), (50, 33)

(70, 19), (70, 27), (70, 23), (90, 14), (90, 21)

Exemplo

Exemplo: Vamos voltar ao exemplo inicial dessa aula, ou seja, ao problema de medir o efeito da temperatura sobre a potência de um medicamento. Recorde que nossos dados são:

Temperatura (x)	30°	50°	70°	90°
Potência (y)	38 43	32 26 33	19 27 23	14 21

- Vamos ajustar um modelo de regressão para esses dados.
- Recorde que para ajustar o modelo precisamos obter $\hat{\beta}_0$ e $\hat{\beta}_1$
- Note que nossos dados são:

(30, 38), (30, 43), (50, 32), (50, 26), (50, 33)

(70, 19), (70, 27), (70, 23), (90, 14), (90, 21)

Exemplo

Exemplo: Vamos voltar ao exemplo inicial dessa aula, ou seja, ao problema de medir o efeito da temperatura sobre a potência de um medicamento. Recorde que nossos dados são:

Temperatura (x)	30°	50°	70°	90°
Potência (y)	38 43	32 26 33	19 27 23	14 21

- Vamos ajustar um modelo de regressão para esses dados.
- Recorde que para ajustar o modelo precisamos obter $\hat{\beta}_0$ e $\hat{\beta}_1$
- Note que nossos dados são:

(30, 38), (30, 43), (50, 32), (50, 26), (50, 33)

(70, 19), (70, 27), (70, 23), (90, 14), (90, 21)

Exemplo

Exemplo: Vamos voltar ao exemplo inicial dessa aula, ou seja, ao problema de medir o efeito da temperatura sobre a potência de um medicamento. Recorde que nossos dados são:

Temperatura (x)	30°	50°	70°	90°
Potência (y)	38 43	32 26 33	19 27 23	14 21

- Vamos ajustar um modelo de regressão para esses dados.
- Recorde que para ajustar o modelo precisamos obter $\hat{\beta}_0$ e $\hat{\beta}_1$
- Note que nossos dados são:

(30, 38), (30, 43), (50, 32), (50, 26), (50, 33)

(70, 19), (70, 27), (70, 23), (90, 14), (90, 21)

Exemplo

Exemplo: Vamos voltar ao exemplo inicial dessa aula, ou seja, ao problema de medir o efeito da temperatura sobre a potência de um medicamento. Recorde que nossos dados são:

Temperatura (x)	30°	50°	70°	90°
Potência (y)	38 43	32 26 33	19 27 23	14 21

- Vamos ajustar um modelo de regressão para esses dados.
- Recorde que para ajustar o modelo precisamos obter $\hat{\beta}_0$ e $\hat{\beta}_1$
- Note que nossos dados são:

(30, 38), (30, 43), (50, 32), (50, 26), (50, 33)

(70, 19), (70, 27), (70, 23), (90, 14), (90, 21)

Exemplo

Exemplo: Vamos voltar ao exemplo inicial dessa aula, ou seja, ao problema de medir o efeito da temperatura sobre a potência de um medicamento. Recorde que nossos dados são:

Temperatura (x)	30°	50°	70°	90°
Potência (y)	38 43	32 26 33	19 27 23	14 21

- Vamos ajustar um modelo de regressão para esses dados.
- Recorde que para ajustar o modelo precisamos obter $\hat{\beta}_0$ e $\hat{\beta}_1$
- Note que nossos dados são:

(30, 38), (30, 43), (50, 32), (50, 26), (50, 33)

(70, 19), (70, 27), (70, 23), (90, 14), (90, 21)

Cont. do exemplo

- Temos que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ e $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}$.

- Temos ainda que

- $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{30+30+50+50+50+70+70+70+90+90}{10} = 60;$
- $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{38+43+32+26+33+19+27+23+14+21}{10} = 27.6;$
- $\sum_{i=1}^n y_i x_i = (38 \cdot 30) + (43 \cdot 30) + (32 \cdot 50) + (26 \cdot 50) + (33 \cdot 50) + (19 \cdot 70) + (27 \cdot 70) + (23 \cdot 70) + (14 \cdot 90) + (21 \cdot 90) = 14960;$
- $\sum_{i=1}^n x_i^2 = 30^2 + 30^2 + 50^2 + 50^2 + 50^2 + 70^2 + 70^2 + 70^2 + 90^2 + 90^2 = 40200.$

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{14960 - 10(60)(27.6)}{40200 - 10(60)^2} \approx -0.38095$$

e

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (27.6) - (-0.38095)(60) \approx 50.457.$$

- Portanto, o modelo ajustado é $\hat{y}_i = 50.457 - 0.38095x_i$

Cont. do exemplo

- Temos que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ e $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$.

- Temos ainda que

- ▶ $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{30+30+50+50+50+70+70+70+90+90}{10} = 60$;
- ▶ $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{38+43+32+26+33+19+27+23+14+21}{10} = 27.6$;
- ▶ $\sum_{i=1}^n y_i x_i = (38 \cdot 30) + (43 \cdot 30) + (32 \cdot 50) + (26 \cdot 50) + (33 \cdot 50) + (19 \cdot 70) + (27 \cdot 70) + (23 \cdot 70) + (14 \cdot 90) + (21 \cdot 90) = 14960$;
- ▶ $\sum_{i=1}^n x_i^2 = 30^2 + 30^2 + 50^2 + 50^2 + 50^2 + 70^2 + 70^2 + 70^2 + 90^2 + 90^2 = 40200$.

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{14960 - 10(60)(27.6)}{40200 - 10(60)^2} \approx -0.38095$$

e

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (27.6) - (-0.38095)(60) \approx 50.457.$$

- Portanto, o modelo ajustado é $\hat{y}_i = 50.457 - 0.38095x_i$

Cont. do exemplo

- Temos que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ e $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}$.

- Temos ainda que

- ▶ $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{30+30+50+50+50+70+70+70+90+90}{10} = 60;$

- ▶ $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{38+43+32+26+33+19+27+23+14+21}{10} = 27.6;$

- ▶ $\sum_{i=1}^n y_i x_i = (38 \cdot 30) + (43 \cdot 30) + (32 \cdot 50) + (26 \cdot 50) + (33 \cdot 50) + (19 \cdot 70) + (27 \cdot 70) + (23 \cdot 70) + (14 \cdot 90) + (21 \cdot 90) = 14960;$

- ▶ $\sum_{i=1}^n x_i^2 = 30^2 + 30^2 + 50^2 + 50^2 + 50^2 + 70^2 + 70^2 + 70^2 + 90^2 + 90^2 = 40200.$

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{14960 - 10(60)(27.6)}{40200 - 10(60)^2} \approx -0.38095$$

e

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (27.6) - (-0.38095)(60) \approx 50.457.$$

- Portanto, o modelo ajustado é $\hat{y}_i = 50.457 - 0.38095x_i$

Cont. do exemplo

- Temos que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ e $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$.

- Temos ainda que

- ▶ $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{30+30+50+50+50+70+70+70+90+90}{10} = 60;$

- ▶ $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{38+43+32+26+33+19+27+23+14+21}{10} = 27.6;$

- ▶ $\sum_{i=1}^n y_i x_i = (38 \cdot 30) + (43 \cdot 30) + (32 \cdot 50) + (26 \cdot 50) + (33 \cdot 50) + (19 \cdot 70) + (27 \cdot 70) + (23 \cdot 70) + (14 \cdot 90) + (21 \cdot 90) = 14960;$

- ▶ $\sum_{i=1}^n x_i^2 = 30^2 + 30^2 + 50^2 + 50^2 + 50^2 + 70^2 + 70^2 + 70^2 + 90^2 + 90^2 = 40200.$

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{14960 - 10(60)(27.6)}{40200 - 10(60)^2} \approx -0.38095$$

e

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (27.6) - (-0.38095)(60) \approx 50.457.$$

- Portanto, o modelo ajustado é $\hat{y}_i = 50.457 - 0.38095x_i$

Cont. do exemplo

- Temos que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ e $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}$.

- Temos ainda que

- ▶ $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{30+30+50+50+50+70+70+70+90+90}{10} = 60;$
- ▶ $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{38+43+32+26+33+19+27+23+14+21}{10} = 27.6;$
- ▶ $\sum_{i=1}^n y_i x_i = (38 \cdot 30) + (43 \cdot 30) + (32 \cdot 50) + (26 \cdot 50) + (33 \cdot 50) + (19 \cdot 70) + (27 \cdot 70) + (23 \cdot 70) + (14 \cdot 90) + (21 \cdot 90) = 14960;$
- ▶ $\sum_{i=1}^n x_i^2 = 30^2 + 30^2 + 50^2 + 50^2 + 50^2 + 70^2 + 70^2 + 70^2 + 90^2 + 90^2 = 40200.$

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{14960 - 10(60)(27.6)}{40200 - 10(60)^2} \approx -0.38095$$

e

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (27.6) - (-0.38095)(60) \approx 50.457.$$

- Portanto, o modelo ajustado é $\hat{y}_i = 50.457 - 0.38095x_i$

Cont. do exemplo

- Temos que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ e $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}$.

- Temos ainda que

- ▶ $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{30+30+50+50+50+70+70+70+90+90}{10} = 60$;
- ▶ $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{38+43+32+26+33+19+27+23+14+21}{10} = 27.6$;
- ▶ $\sum_{i=1}^n y_i x_i = (38 \cdot 30) + (43 \cdot 30) + (32 \cdot 50) + (26 \cdot 50) + (33 \cdot 50) + (19 \cdot 70) + (27 \cdot 70) + (23 \cdot 70) + (14 \cdot 90) + (21 \cdot 90) = 14960$;
- ▶ $\sum_{i=1}^n x_i^2 = 30^2 + 30^2 + 50^2 + 50^2 + 50^2 + 70^2 + 70^2 + 70^2 + 90^2 + 90^2 = 40200$.

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{14960 - 10(60)(27.6)}{40200 - 10(60)^2} \approx -0.38095$$

e

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (27.6) - (-0.38095)(60) \approx 50.457.$$

- Portanto, o modelo ajustado é $\hat{y}_i = 50.457 - 0.38095x_i$

Cont. do exemplo

- Temos que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ e $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$.

- Temos ainda que

- ▶ $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{30+30+50+50+50+70+70+70+90+90}{10} = 60$;
- ▶ $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{38+43+32+26+33+19+27+23+14+21}{10} = 27.6$;
- ▶ $\sum_{i=1}^n y_i x_i = (38 \cdot 30) + (43 \cdot 30) + (32 \cdot 50) + (26 \cdot 50) + (33 \cdot 50) + (19 \cdot 70) + (27 \cdot 70) + (23 \cdot 70) + (14 \cdot 90) + (21 \cdot 90) = 14960$;
- ▶ $\sum_{i=1}^n x_i^2 = 30^2 + 30^2 + 50^2 + 50^2 + 50^2 + 70^2 + 70^2 + 70^2 + 90^2 + 90^2 = 40200$.

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{14960 - 10(60)(27.6)}{40200 - 10(60)^2} \approx -0.38095$$

e

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (27.6) - (-0.38095)(60) \approx 50.457.$$

- Portanto, o modelo ajustado é $\hat{y}_i = 50.457 - 0.38095x_i$

Cont. do exemplo

- Temos que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ e $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$.

- Temos ainda que

- ▶ $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{30+30+50+50+50+70+70+70+90+90}{10} = 60$;
- ▶ $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{38+43+32+26+33+19+27+23+14+21}{10} = 27.6$;
- ▶ $\sum_{i=1}^n y_i x_i = (38 \cdot 30) + (43 \cdot 30) + (32 \cdot 50) + (26 \cdot 50) + (33 \cdot 50) + (19 \cdot 70) + (27 \cdot 70) + (23 \cdot 70) + (14 \cdot 90) + (21 \cdot 90) = 14960$;
- ▶ $\sum_{i=1}^n x_i^2 = 30^2 + 30^2 + 50^2 + 50^2 + 50^2 + 70^2 + 70^2 + 70^2 + 90^2 + 90^2 = 40200$.

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{14960 - 10(60)(27.6)}{40200 - 10(60)^2} \approx -0.38095$$

e

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (27.6) - (-0.38095)(60) \approx 50.457.$$

- Portanto, o modelo ajustado é $\hat{y}_i = 50.457 - 0.38095x_i$

Cont. do exemplo

- Temos que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ e $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$.

- Temos ainda que

- ▶ $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{30+30+50+50+50+70+70+70+90+90}{10} = 60$;
- ▶ $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{38+43+32+26+33+19+27+23+14+21}{10} = 27.6$;
- ▶ $\sum_{i=1}^n y_i x_i = (38 \cdot 30) + (43 \cdot 30) + (32 \cdot 50) + (26 \cdot 50) + (33 \cdot 50) + (19 \cdot 70) + (27 \cdot 70) + (23 \cdot 70) + (14 \cdot 90) + (21 \cdot 90) = 14960$;
- ▶ $\sum_{i=1}^n x_i^2 = 30^2 + 30^2 + 50^2 + 50^2 + 50^2 + 70^2 + 70^2 + 70^2 + 90^2 + 90^2 = 40200$.

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{14960 - 10(60)(27.6)}{40200 - 10(60)^2} \approx -0.38095$$

e

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (27.6) - (-0.38095)(60) \approx 50.457.$$

- Portanto, o modelo ajustado é $\hat{y}_i = 50.457 - 0.38095x_i$

Cont. do exemplo

- Temos que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ e $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$.

- Temos ainda que

- ▶ $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{30+30+50+50+50+70+70+70+90+90}{10} = 60$;
- ▶ $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{38+43+32+26+33+19+27+23+14+21}{10} = 27.6$;
- ▶ $\sum_{i=1}^n y_i x_i = (38 \cdot 30) + (43 \cdot 30) + (32 \cdot 50) + (26 \cdot 50) + (33 \cdot 50) + (19 \cdot 70) + (27 \cdot 70) + (23 \cdot 70) + (14 \cdot 90) + (21 \cdot 90) = 14960$;
- ▶ $\sum_{i=1}^n x_i^2 = 30^2 + 30^2 + 50^2 + 50^2 + 50^2 + 70^2 + 70^2 + 70^2 + 90^2 + 90^2 = 40200$.

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{14960 - 10(60)(27.6)}{40200 - 10(60)^2} \approx -0.38095$$

e

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (27.6) - (-0.38095)(60) \approx 50.457.$$

- Portanto, o modelo ajustado é $\hat{y}_i = 50.457 - 0.38095x_i$




Figure 3: Dados do problema anterior. X: Temperatura, Y: Potência