

# Probabilidade e estatística - Aula 22

## Regressão linear simples: Aula 2 - Testes de hipóteses e intervalos de confiança em regressão linear simples

Dr. Giannini Italino Alves Vieira

Universidade Federal do Ceará - Campus de Crateús

2024

1 Testes de hipóteses na regressão linear simples

2 IC para o intercepto e a inclinação

# Regressão linear simples

- Recorde que na aula passada vimos o modelo de regressão linear simples.
- Ou seja, vimos que o modelo considera que cada observação  $Y$  possa ser descrita pelo modelo

$$Y = \beta_0 + \beta_1 x + \epsilon$$

em que  $\beta_0$  é chamado de o intercepto,  $\beta_1$  é chamado de inclinação e  $\epsilon$  é um erro aleatório com média zero e variância  $\sigma^2$  (desconhecida).

- Vimos que a estimação de  $\beta_0$  e  $\beta_1$  pode ser feita por meio do método de mínimos quadrados, ou seja, minimizando a soma dos quadrados dos desvios.

# Regressão linear simples

- Recorde que na aula passada vimos o modelo de regressão linear simples.
- Ou seja, vimos que o modelo considera que cada observação  $Y$  possa ser descrita pelo modelo

$$Y = \beta_0 + \beta_1 x + \epsilon$$

em que  $\beta_0$  é chamado de o intercepto,  $\beta_1$  é chamado de inclinação e  $\epsilon$  é um erro aleatório com média zero e variância  $\sigma^2$  (desconhecida).

- Vimos que a estimação de  $\beta_0$  e  $\beta_1$  pode ser feita por meio do método de mínimos quadrados, ou seja, minimizando a soma dos quadrados dos desvios.

# Regressão linear simples

- Recorde que na aula passada vimos o modelo de regressão linear simples.
- Ou seja, vimos que o modelo considera que cada observação  $Y$  possa ser descrita pelo modelo

$$Y = \beta_0 + \beta_1 x + \epsilon$$

em que  $\beta_0$  é chamado de o intercepto,  $\beta_1$  é chamado de inclinação e  $\epsilon$  é um erro aleatório com média zero e variância  $\sigma^2$  (desconhecida).

- Vimos que a estimação de  $\beta_0$  e  $\beta_1$  pode ser feita por meio do método de mínimos quadrados, ou seja, minimizando a soma dos quadrados dos desvios.

# Regressão linear simples

- Recorde que na aula passada vimos o modelo de regressão linear simples.
- Ou seja, vimos que o modelo considera que cada observação  $Y$  possa ser descrita pelo modelo

$$Y = \beta_0 + \beta_1 x + \epsilon$$

em que  $\beta_0$  é chamado de o intercepto,  $\beta_1$  é chamado de inclinação e  $\epsilon$  é um erro aleatório com média zero e variância  $\sigma^2$  (desconhecida).

- Vimos que a estimação de  $\beta_0$  e  $\beta_1$  pode ser feita por meio do método de mínimos quadrados, ou seja, minimizando a soma dos quadrados dos desvios.

# Regressão linear simples

- Recorde que na aula passada vimos o modelo de regressão linear simples.
- Ou seja, vimos que o modelo considera que cada observação  $Y$  possa ser descrita pelo modelo

$$Y = \beta_0 + \beta_1 x + \epsilon$$

em que  $\beta_0$  é chamado de o intercepto,  $\beta_1$  é chamado de inclinação e  $\epsilon$  é um erro aleatório com média zero e variância  $\sigma^2$  (desconhecida).

- Vimos que a estimação de  $\beta_0$  e  $\beta_1$  pode ser feita por meio do método de mínimos quadrados, ou seja, minimizando a soma dos quadrados dos desvios.

## Estimadores de $\beta_0$ e $\beta_1$ - Método dos mínimos Quadrados

- Vimos que as estimativas de mínimos quadrados do intercepto e da inclinação no modelo de regressão linear simples são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

em que  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$  e  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ .

- Dessa forma, a linha de regressão ajustada (modelo ajustado ou estimado) é consequentemente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$



## Estimadores de $\beta_0$ e $\beta_1$ - Método dos mínimos Quadrados

- Vimos que as estimativas de mínimos quadrados do intercepto e da inclinação no modelo de regressão linear simples são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

em que  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$  e  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ .

- Dessa forma, a linha de regressão ajustada (modelo ajustado ou estimado) é consequentemente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

## Estimadores de $\beta_0$ e $\beta_1$ - Método dos mínimos Quadrados

- Vimos que as estimativas de mínimos quadrados do intercepto e da inclinação no modelo de regressão linear simples são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

em que  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$  e  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ .

- Dessa forma, a linha de regressão ajustada (modelo ajustado ou estimado) é consequentemente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

## Estimadores de $\beta_0$ e $\beta_1$ - Método dos mínimos Quadrados

- Vimos que as estimativas de mínimos quadrados do intercepto e da inclinação no modelo de regressão linear simples são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

em que  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$  e  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ .

- Dessa forma, a linha de regressão ajustada (modelo ajustado ou estimado) é consequentemente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

## Estimadores de $\beta_0$ e $\beta_1$ - Método dos mínimos Quadrados

- Vimos que as estimativas de mínimos quadrados do intercepto e da inclinação no modelo de regressão linear simples são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

em que  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$  e  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ .

- Dessa forma, a linha de regressão ajustada (modelo ajustado ou estimado) é consequentemente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

## Estimadores de $\beta_0$ e $\beta_1$ - Método dos mínimos Quadrados

- Vimos que as estimativas de mínimos quadrados do intercepto e da inclinação no modelo de regressão linear simples são

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

e

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

em que  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$  e  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ .

- Dessa forma, a linha de regressão ajustada (modelo ajustado ou estimado) é consequentemente

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

# Regressão linear simples

## Um outro parâmetro

- Note que em regressão linear simples há ainda um outro parâmetro desconhecido, que é a variância do termo de erro  $\epsilon$ , ou seja,  $\sigma^2$ .
- Para obter uma estimativa para  $\sigma^2$  usamos os resíduos  $e_i = y_i - \hat{y}_i$  (note que o resíduo descreve o erro no ajuste do modelo para a  $i$ -ésima observação  $y_i$ ).
- Temos que a soma dos quadrados dos resíduos é

$$SQ_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Pode-se mostrar que  $E(SQ_E) = (n - 2)\sigma^2$ . Logo, um estimador não viesado para  $\sigma^2$  é

$$\hat{\sigma}^2 = \frac{SQ_E}{n - 2}$$

# Regressão linear simples

## Um outro parâmetro

- Note que em regressão linear simples há ainda um outro parâmetro desconhecido, que é a variância do termo de erro  $\epsilon$ , ou seja,  $\sigma^2$ .
- Para obter uma estimativa para  $\sigma^2$  usamos os resíduos  $e_i = y_i - \hat{y}_i$  (note que o resíduo descreve o erro no ajuste do modelo para a  $i$ -ésima observação  $y_i$ ).
- Temos que a soma dos quadrados dos resíduos é

$$SQ_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Pode-se mostrar que  $E(SQ_E) = (n - 2)\sigma^2$ . Logo, um estimador não viesado para  $\sigma^2$  é

$$\hat{\sigma}^2 = \frac{SQ_E}{n - 2}$$

# Regressão linear simples

## Um outro parâmetro

- Note que em regressão linear simples há ainda um outro parâmetro desconhecido, que é a variância do termo de erro  $\epsilon$ , ou seja,  $\sigma^2$ .
- Para obter uma estimativa para  $\sigma^2$  usamos os resíduos  $e_i = y_i - \hat{y}_i$  (note que o resíduo descreve o erro no ajuste do modelo para a  $i$ -ésima observação  $y_i$ ).
- Temos que a soma dos quadrados dos resíduos é

$$SQ_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Pode-se mostrar que  $E(SQ_E) = (n - 2)\sigma^2$ . Logo, um estimador não viesado para  $\sigma^2$  é

$$\hat{\sigma}^2 = \frac{SQ_E}{n - 2}$$



# Regressão linear simples

## Um outro parâmetro

- Note que em regressão linear simples há ainda um outro parâmetro desconhecido, que é a variância do termo de erro  $\epsilon$ , ou seja,  $\sigma^2$ .
- Para obter uma estimativa para  $\sigma^2$  usamos os resíduos  $e_i = y_i - \hat{y}_i$  (note que o resíduo descreve o erro no ajuste do modelo para a  $i$ -ésima observação  $y_i$ ).
- Temos que a soma dos quadrados dos resíduos é

$$SQ_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Pode-se mostrar que  $E(SQ_E) = (n - 2)\sigma^2$ . Logo, um estimador não viesado para  $\sigma^2$  é

$$\hat{\sigma}^2 = \frac{SQ_E}{n - 2}$$

# Regressão linear simples

## Um outro parâmetro

- Note que em regressão linear simples há ainda um outro parâmetro desconhecido, que é a variância do termo de erro  $\epsilon$ , ou seja,  $\sigma^2$ .
- Para obter uma estimativa para  $\sigma^2$  usamos os resíduos  $e_i = y_i - \hat{y}_i$  (note que o resíduo descreve o erro no ajuste do modelo para a  $i$ -ésima observação  $y_i$ ).
- Temos que a soma dos quadrados dos resíduos é

$$SQ_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Pode-se mostrar que  $E(SQ_E) = (n - 2)\sigma^2$ . Logo, um estimador não viesado para  $\sigma^2$  é

$$\hat{\sigma}^2 = \frac{SQ_E}{n - 2}$$

# Regressão linear simples

## Um outro parâmetro

- Note que em regressão linear simples há ainda um outro parâmetro desconhecido, que é a variância do termo de erro  $\epsilon$ , ou seja,  $\sigma^2$ .
- Para obter uma estimativa para  $\sigma^2$  usamos os resíduos  $e_i = y_i - \hat{y}_i$  (note que o resíduo descreve o erro no ajuste do modelo para a  $i$ -ésima observação  $y_i$ ).
- Temos que a soma dos quadrados dos resíduos é

$$SQ_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Pode-se mostrar que  $E(SQ_E) = (n - 2)\sigma^2$ . Logo, um estimador não viesado para  $\sigma^2$  é

$$\hat{\sigma}^2 = \frac{SQ_E}{n - 2}$$

# Regressão linear simples

## Um outro parâmetro

- Só que calcular  $SQ_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$  pode ser bastante trabalhoso.
- Logo, pode-se mostrar que uma maneira alternativa, mais conveniente, de se obter  $SQ_E$  é

$$SQ_E = SQ_T - \hat{\beta}_1 S_{xy}$$

em que

$$SQ_T = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad (\text{Soma total dos quadrados da variável } y)$$

e

$$S_{xy} = \sum_{i=1}^n y_i x_i - n\bar{x}\bar{y} \quad (\text{Numerador de } \hat{\beta}_1)$$

# Regressão linear simples

## Um outro parâmetro

- Só que calcular  $SQ_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$  pode ser bastante trabalhoso.
- Logo, pode-se mostrar que uma maneira alternativa, mais conveniente, de se obter  $SQ_E$  é

$$SQ_E = SQ_T - \hat{\beta}_1 S_{xy}$$

em que

$$SQ_T = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad (\text{Soma total dos quadrados da variável } y)$$

e

$$S_{xy} = \sum_{i=1}^n y_i x_i - n\bar{x}\bar{y} \quad (\text{Numerador de } \hat{\beta}_1)$$

# Regressão linear simples

## Um outro parâmetro

- Só que calcular  $SQ_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$  pode ser bastante trabalhoso.
- Logo, pode-se mostrar que uma maneira alternativa, mais conveniente, de se obter  $SQ_E$  é

$$SQ_E = SQ_T - \hat{\beta}_1 S_{xy}$$

em que

$$SQ_T = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad (\text{Soma total dos quadrados da variável } y)$$

e

$$S_{xy} = \sum_{i=1}^n y_i x_i - n\bar{x}\bar{y} \quad (\text{Numerador de } \hat{\beta}_1)$$

# Regressão linear simples

## Um outro parâmetro

- Só que calcular  $SQ_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$  pode ser bastante trabalhoso.
- Logo, pode-se mostrar que uma maneira alternativa, mais conveniente, de se obter  $SQ_E$  é

$$SQ_E = SQ_T - \hat{\beta}_1 S_{xy}$$

em que

$$SQ_T = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad (\text{Soma total dos quadrados da variável } y)$$

e

$$S_{xy} = \sum_{i=1}^n y_i x_i - n\bar{x}\bar{y} \quad (\text{Numerador de } \hat{\beta}_1)$$

# Regressão linear simples

## Um outro parâmetro

- Só que calcular  $SQ_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$  pode ser bastante trabalhoso.
- Logo, pode-se mostrar que uma maneira alternativa, mais conveniente, de se obter  $SQ_E$  é

$$SQ_E = SQ_T - \hat{\beta}_1 S_{xy}$$

em que

$$SQ_T = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad (\text{Soma total dos quadrados da variável } y)$$

e

$$S_{xy} = \sum_{i=1}^n y_i x_i - n\bar{x}\bar{y} \quad (\text{Numerador de } \hat{\beta}_1)$$



## Um outro parâmetro

- Só que calcular  $SQ_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$  pode ser bastante trabalhoso.
- Logo, pode-se mostrar que uma maneira alternativa, mais conveniente, de se obter  $SQ_E$  é

$$SQ_E = SQ_T - \hat{\beta}_1 S_{xy}$$

em que

$$SQ_T = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad (\text{Soma total dos quadrados da variável } y)$$

e

$$S_{xy} = \sum_{i=1}^n y_i x_i - n\bar{x}\bar{y} \quad (\text{Numerador de } \hat{\beta}_1)$$

# Propriedades dos estimadores de mínimos quadrados de $\beta_0$ e $\beta_1$

- Pode-se mostrar que os estimadores de mínimos quadrados de  $\beta_0$  e  $\beta_1$ , ou seja,  $\hat{\beta}_0$  e  $\hat{\beta}_1$  possuem as seguintes propriedades:
- Com relação a  $\hat{\beta}_1$ :
  - ▶  $E(\hat{\beta}_1) = \beta_1$  (ou seja,  $\hat{\beta}_1$  é não viesado para  $\beta_1$ )
  - ▶  $Var(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$ , em que  $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$
- Com relação a  $\hat{\beta}_0$ :
  - ▶  $E(\hat{\beta}_0) = \beta_0$  (ou seja,  $\hat{\beta}_0$  é não viesado para  $\beta_0$ )
  - ▶  $Var(\hat{\beta}_0) = \sigma^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]$ .
- Note que nas variâncias de  $\hat{\beta}_0$  e  $\hat{\beta}_1$  aparece a variância dos erros ( $\sigma^2$ ). Logo, podemos usar  $\hat{\sigma}^2$  para fornecer estimativas das variâncias desses estimadores.

# Propriedades dos estimadores de mínimos quadrados de $\beta_0$ e $\beta_1$

- Pode-se mostrar que os estimadores de mínimos quadrados de  $\beta_0$  e  $\beta_1$ , ou seja,  $\hat{\beta}_0$  e  $\hat{\beta}_1$  possuem as seguintes propriedades:
- Com relação a  $\hat{\beta}_1$ :
  - ▶  $E(\hat{\beta}_1) = \beta_1$  (ou seja,  $\hat{\beta}_1$  é não viesado para  $\beta_1$ )
  - ▶  $Var(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$ , em que  $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$
- Com relação a  $\hat{\beta}_0$ :
  - ▶  $E(\hat{\beta}_0) = \beta_0$  (ou seja,  $\hat{\beta}_0$  é não viesado para  $\beta_0$ )
  - ▶  $Var(\hat{\beta}_0) = \sigma^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]$ .
- Note que nas variâncias de  $\hat{\beta}_0$  e  $\hat{\beta}_1$  aparece a variância dos erros ( $\sigma^2$ ). Logo, podemos usar  $\hat{\sigma}^2$  para fornecer estimativas das variâncias desses estimadores.

# Propriedades dos estimadores de mínimos quadrados de $\beta_0$ e $\beta_1$

- Pode-se mostrar que os estimadores de mínimos quadrados de  $\beta_0$  e  $\beta_1$ , ou seja,  $\hat{\beta}_0$  e  $\hat{\beta}_1$  possuem as seguintes propriedades:
- Com relação a  $\hat{\beta}_1$ :
  - ▶  $E(\hat{\beta}_1) = \beta_1$  (ou seja,  $\hat{\beta}_1$  é não viesado para  $\beta_1$ )
  - ▶  $Var(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$ , em que  $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$
- Com relação a  $\hat{\beta}_0$ :
  - ▶  $E(\hat{\beta}_0) = \beta_0$  (ou seja,  $\hat{\beta}_0$  é não viesado para  $\beta_0$ )
  - ▶  $Var(\hat{\beta}_0) = \sigma^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]$ .
- Note que nas variâncias de  $\hat{\beta}_0$  e  $\hat{\beta}_1$  aparece a variância dos erros ( $\sigma^2$ ). Logo, podemos usar  $\hat{\sigma}^2$  para fornecer estimativas das variâncias desses estimadores.

# Propriedades dos estimadores de mínimos quadrados de $\beta_0$ e $\beta_1$

- Pode-se mostrar que os estimadores de mínimos quadrados de  $\beta_0$  e  $\beta_1$ , ou seja,  $\hat{\beta}_0$  e  $\hat{\beta}_1$  possuem as seguintes propriedades:
- Com relação a  $\hat{\beta}_1$ :
  - ▶  $E(\hat{\beta}_1) = \beta_1$  (ou seja,  $\hat{\beta}_1$  é não viesado para  $\beta_1$ )
  - ▶  $Var(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$ , em que  $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$
- Com relação a  $\hat{\beta}_0$ :
  - ▶  $E(\hat{\beta}_0) = \beta_0$  (ou seja,  $\hat{\beta}_0$  é não viesado para  $\beta_0$ )
  - ▶  $Var(\hat{\beta}_0) = \sigma^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]$ .
- Note que nas variâncias de  $\hat{\beta}_0$  e  $\hat{\beta}_1$  aparece a variância dos erros ( $\sigma^2$ ). Logo, podemos usar  $\hat{\sigma}^2$  para fornecer estimativas das variâncias desses estimadores.

# Propriedades dos estimadores de mínimos quadrados de $\beta_0$ e $\beta_1$

- Pode-se mostrar que os estimadores de mínimos quadrados de  $\beta_0$  e  $\beta_1$ , ou seja,  $\hat{\beta}_0$  e  $\hat{\beta}_1$  possuem as seguintes propriedades:
- Com relação a  $\hat{\beta}_1$ :
  - ▶  $E(\hat{\beta}_1) = \beta_1$  (ou seja,  $\hat{\beta}_1$  é não viesado para  $\beta_1$ )
  - ▶  $Var(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$ , em que  $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$
- Com relação a  $\hat{\beta}_0$ :
  - ▶  $E(\hat{\beta}_0) = \beta_0$  (ou seja,  $\hat{\beta}_0$  é não viesado para  $\beta_0$ )
  - ▶  $Var(\hat{\beta}_0) = \sigma^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]$ .
- Note que nas variâncias de  $\hat{\beta}_0$  e  $\hat{\beta}_1$  aparece a variância dos erros ( $\sigma^2$ ). Logo, podemos usar  $\hat{\sigma}^2$  para fornecer estimativas das variâncias desses estimadores.

# Propriedades dos estimadores de mínimos quadrados de $\beta_0$ e $\beta_1$

- Pode-se mostrar que os estimadores de mínimos quadrados de  $\beta_0$  e  $\beta_1$ , ou seja,  $\hat{\beta}_0$  e  $\hat{\beta}_1$  possuem as seguintes propriedades:
- Com relação a  $\hat{\beta}_1$ :
  - ▶  $E(\hat{\beta}_1) = \beta_1$  (ou seja,  $\hat{\beta}_1$  é não viesado para  $\beta_1$ )
  - ▶  $Var(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$ , em que  $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$
- Com relação a  $\hat{\beta}_0$ :
  - ▶  $E(\hat{\beta}_0) = \beta_0$  (ou seja,  $\hat{\beta}_0$  é não viesado para  $\beta_0$ )
  - ▶  $Var(\hat{\beta}_0) = \sigma^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]$ .
- Note que nas variâncias de  $\hat{\beta}_0$  e  $\hat{\beta}_1$  aparece a variância dos erros ( $\sigma^2$ ). Logo, podemos usar  $\hat{\sigma}^2$  para fornecer estimativas das variâncias desses estimadores.

# Propriedades dos estimadores de mínimos quadrados de $\beta_0$ e $\beta_1$

- Pode-se mostrar que os estimadores de mínimos quadrados de  $\beta_0$  e  $\beta_1$ , ou seja,  $\hat{\beta}_0$  e  $\hat{\beta}_1$  possuem as seguintes propriedades:
- Com relação a  $\hat{\beta}_1$ :
  - ▶  $E(\hat{\beta}_1) = \beta_1$  (ou seja,  $\hat{\beta}_1$  é não viesado para  $\beta_1$ )
  - ▶  $Var(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$ , em que  $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$
- Com relação a  $\hat{\beta}_0$ :
  - ▶  $E(\hat{\beta}_0) = \beta_0$  (ou seja,  $\hat{\beta}_0$  é não viesado para  $\beta_0$ )
  - ▶  $Var(\hat{\beta}_0) = \sigma^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]$ .
- Note que nas variâncias de  $\hat{\beta}_0$  e  $\hat{\beta}_1$  aparece a variância dos erros ( $\sigma^2$ ). Logo, podemos usar  $\hat{\sigma}^2$  para fornecer estimativas das variâncias desses estimadores.



# Propriedades dos estimadores de mínimos quadrados de $\beta_0$ e $\beta_1$

- Pode-se mostrar que os estimadores de mínimos quadrados de  $\beta_0$  e  $\beta_1$ , ou seja,  $\hat{\beta}_0$  e  $\hat{\beta}_1$  possuem as seguintes propriedades:
- Com relação a  $\hat{\beta}_1$ :
  - ▶  $E(\hat{\beta}_1) = \beta_1$  (ou seja,  $\hat{\beta}_1$  é não viesado para  $\beta_1$ )
  - ▶  $Var(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$ , em que  $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$
- Com relação a  $\hat{\beta}_0$ :
  - ▶  $E(\hat{\beta}_0) = \beta_0$  (ou seja,  $\hat{\beta}_0$  é não viesado para  $\beta_0$ )
  - ▶  $Var(\hat{\beta}_0) = \sigma^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]$ .
- Note que nas variâncias de  $\hat{\beta}_0$  e  $\hat{\beta}_1$  aparece a variância dos erros ( $\sigma^2$ ). Logo, podemos usar  $\hat{\sigma}^2$  para fornecer estimativas das variâncias desses estimadores.

# Testes de hipóteses na regressão linear simples

- Uma importante parte na verificação da adequação do modelo de regressão linear simples consiste na realização de testes de hipóteses em relação aos parâmetros do modelo.
- Para testar hipóteses sobre o intercepto e a inclinação do modelo temos de fazer a suposição adicional de que a componente do erro do modelo,  $\epsilon$ , seja distribuída normalmente.
- Ou seja, supomos que os erros são normal e independentemente distribuídos com média zero e variância  $\sigma^2$ .

# Testes de hipóteses na regressão linear simples

- Uma importante parte na verificação da adequação do modelo de regressão linear simples consiste na realização de testes de hipóteses em relação aos parâmetros do modelo.
- Para testar hipóteses sobre o intercepto e a inclinação do modelo temos de fazer a suposição adicional de que a componente do erro do modelo,  $\epsilon$ , seja distribuída normalmente.
- Ou seja, supomos que os erros são normal e independentemente distribuídos com média zero e variância  $\sigma^2$ .

# Testes de hipóteses na regressão linear simples

- Uma importante parte na verificação da adequação do modelo de regressão linear simples consiste na realização de testes de hipóteses em relação aos parâmetros do modelo.
- Para testar hipóteses sobre o intercepto e a inclinação do modelo temos de fazer a suposição adicional de que a componente do erro do modelo,  $\epsilon$ , seja distribuída normalmente.
- Ou seja, supomos que os erros são normal e independentemente distribuídos com média zero e variância  $\sigma^2$ .

# Testes de hipóteses para $\beta_1$

- Suponha que queremos testar a hipótese de que a inclinação seja igual a uma constante, digamos  $\beta_{1,0}$ . Ou seja, queremos testar, ao nível de significância  $\alpha$  as hipóteses:

$$H_0 : \beta_1 = \beta_{1,0} \quad \text{contra} \quad H_1 : \beta_1 \neq \beta_{1,0}$$

- Note que uma vez que estamos supondo que  $\epsilon_i \sim N(0, \sigma^2)$ , então as observações  $Y_i$  também são  $N(\beta_0 + \beta_1 x_i, \sigma^2)$ . Como  $\hat{\beta}_1$  é uma combinação linear das variáveis normais, então  $\hat{\beta}_1$  é também  $N(\beta_1, \frac{\sigma^2}{S_{xx}})$ .
- Logo, para realizar um teste da forma acima, usamos a seguinte estatística de teste

$$T_0 = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

que tem distribuição  $t$  com  $n - 2$  graus de liberdade, sujeito a  $H_0$ .

- Logo, com um argumento análogo ao que usamos em testes de hipóteses, temos que a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \quad \text{ou} \quad t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_1$

- Suponha que queremos testar a hipótese de que a inclinação seja igual a uma constante, digamos  $\beta_{1,0}$ . Ou seja, queremos testar, ao nível de significância  $\alpha$  as hipóteses:

$$H_0 : \beta_1 = \beta_{1,0} \quad \text{contra} \quad H_1 : \beta_1 \neq \beta_{1,0}$$

- Note que uma vez que estamos supondo que  $\epsilon_i \sim N(0, \sigma^2)$ , então as observações  $Y_i$  também são  $N(\beta_0 + \beta_1 x_i, \sigma^2)$ . Como  $\hat{\beta}_1$  é uma combinação linear das variáveis normais, então  $\hat{\beta}_1$  é também  $N(\beta_1, \frac{\sigma^2}{S_{xx}})$ .
- Logo, para realizar um teste da forma acima, usamos a seguinte estatística de teste

$$T_0 = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

que tem distribuição  $t$  com  $n - 2$  graus de liberdade, sujeito a  $H_0$ .

- Logo, com um argumento análogo ao que usamos em testes de hipóteses, temos que a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \quad \text{ou} \quad t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_1$

- Suponha que queremos testar a hipótese de que a inclinação seja igual a uma constante, digamos  $\beta_{1,0}$ . Ou seja, queremos testar, ao nível de significância  $\alpha$  as hipóteses:

$$H_0 : \beta_1 = \beta_{1,0} \quad \text{contra} \quad H_1 : \beta_1 \neq \beta_{1,0}$$

- Note que uma vez que estamos supondo que  $\epsilon_i \sim N(0, \sigma^2)$ , então as observações  $Y_i$  também são  $N(\beta_0 + \beta_1 x_i, \sigma^2)$ . Como  $\hat{\beta}_1$  é uma combinação linear das variáveis normais, então  $\hat{\beta}_1$  é também  $N(\beta_1, \frac{\sigma^2}{S_{xx}})$ .
- Logo, para realizar um teste da forma acima, usamos a seguinte estatística de teste

$$T_0 = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

que tem distribuição  $t$  com  $n - 2$  graus de liberdade, sujeito a  $H_0$ .

- Logo, com um argumento análogo ao que usamos em testes de hipóteses, temos que a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \quad \text{ou} \quad t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_1$

- Suponha que queremos testar a hipótese de que a inclinação seja igual a uma constante, digamos  $\beta_{1,0}$ . Ou seja, queremos testar, ao nível de significância  $\alpha$  as hipóteses:

$$H_0 : \beta_1 = \beta_{1,0} \quad \text{contra} \quad H_1 : \beta_1 \neq \beta_{1,0}$$

- Note que uma vez que estamos supondo que  $\epsilon_i \sim N(0, \sigma^2)$ , então as observações  $Y_i$  também são  $N(\beta_0 + \beta_1 x_i, \sigma^2)$ . Como  $\hat{\beta}_1$  é uma combinação linear das variáveis normais, então  $\hat{\beta}_1$  é também  $N(\beta_1, \frac{\sigma^2}{S_{xx}})$ .
- Logo, para realizar um teste da forma acima, usamos a seguinte estatística de teste

$$T_0 = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

que tem distribuição  $t$  com  $n - 2$  graus de liberdade, sujeito a  $H_0$ .

- Logo, com um argumento análogo ao que usamos em testes de hipóteses, temos que a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \quad \text{ou} \quad t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .



# Testes de hipóteses para $\beta_1$

- Suponha que queremos testar a hipótese de que a inclinação seja igual a uma constante, digamos  $\beta_{1,0}$ . Ou seja, queremos testar, ao nível de significância  $\alpha$  as hipóteses:

$$H_0 : \beta_1 = \beta_{1,0} \quad \text{contra} \quad H_1 : \beta_1 \neq \beta_{1,0}$$

- Note que uma vez que estamos supondo que  $\epsilon_i \sim N(0, \sigma^2)$ , então as observações  $Y_i$  também são  $N(\beta_0 + \beta_1 x_i, \sigma^2)$ . Como  $\hat{\beta}_1$  é uma combinação linear das variáveis normais, então  $\hat{\beta}_1$  é também  $N(\beta_1, \frac{\sigma^2}{S_{xx}})$ .
- Logo, para realizar um teste da forma acima, usamos a seguinte estatística de teste

$$T_0 = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

que tem distribuição  $t$  com  $n - 2$  graus de liberdade, sujeito a  $H_0$ .

- Logo, com um argumento análogo ao que usamos em testes de hipóteses, temos que a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \quad \text{ou} \quad t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_1$

- Suponha que queremos testar a hipótese de que a inclinação seja igual a uma constante, digamos  $\beta_{1,0}$ . Ou seja, queremos testar, ao nível de significância  $\alpha$  as hipóteses:

$$H_0 : \beta_1 = \beta_{1,0} \quad \text{contra} \quad H_1 : \beta_1 \neq \beta_{1,0}$$

- Note que uma vez que estamos supondo que  $\epsilon_i \sim N(0, \sigma^2)$ , então as observações  $Y_i$  também são  $N(\beta_0 + \beta_1 x_i, \sigma^2)$ . Como  $\hat{\beta}_1$  é uma combinação linear das variáveis normais, então  $\hat{\beta}_1$  é também  $N(\beta_1, \frac{\sigma^2}{S_{xx}})$ .
- Logo, para realizar um teste da forma acima, usamos a seguinte estatística de teste

$$T_0 = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

que tem distribuição  $t$  com  $n - 2$  graus de liberdade, sujeito a  $H_0$ .

- Logo, com um argumento análogo ao que usamos em testes de hipóteses, temos que a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \text{ ou } t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_1$

- Suponha que queremos testar a hipótese de que a inclinação seja igual a uma constante, digamos  $\beta_{1,0}$ . Ou seja, queremos testar, ao nível de significância  $\alpha$  as hipóteses:

$$H_0 : \beta_1 = \beta_{1,0} \quad \text{contra} \quad H_1 : \beta_1 \neq \beta_{1,0}$$

- Note que uma vez que estamos supondo que  $\epsilon_i \sim N(0, \sigma^2)$ , então as observações  $Y_i$  também são  $N(\beta_0 + \beta_1 x_i, \sigma^2)$ . Como  $\hat{\beta}_1$  é uma combinação linear das variáveis normais, então  $\hat{\beta}_1$  é também  $N(\beta_1, \frac{\sigma^2}{S_{xx}})$ .
- Logo, para realizar um teste da forma acima, usamos a seguinte estatística de teste

$$T_0 = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

que tem distribuição  $t$  com  $n - 2$  graus de liberdade, sujeito a  $H_0$ .

- Logo, com um argumento análogo ao que usamos em testes de hipóteses, temos que a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \text{ ou } t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_1$

- Suponha que queremos testar a hipótese de que a inclinação seja igual a uma constante, digamos  $\beta_{1,0}$ . Ou seja, queremos testar, ao nível de significância  $\alpha$  as hipóteses:

$$H_0 : \beta_1 = \beta_{1,0} \quad \text{contra} \quad H_1 : \beta_1 \neq \beta_{1,0}$$

- Note que uma vez que estamos supondo que  $\epsilon_i \sim N(0, \sigma^2)$ , então as observações  $Y_i$  também são  $N(\beta_0 + \beta_1 x_i, \sigma^2)$ . Como  $\hat{\beta}_1$  é uma combinação linear das variáveis normais, então  $\hat{\beta}_1$  é também  $N(\beta_1, \frac{\sigma^2}{S_{xx}})$ .
- Logo, para realizar um teste da forma acima, usamos a seguinte estatística de teste

$$T_0 = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

que tem distribuição  $t$  com  $n - 2$  graus de liberdade, sujeito a  $H_0$ .

- Logo, com um argumento análogo ao que usamos em testes de hipóteses, temos que a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \text{ ou } t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_1$

- Suponha que queremos testar a hipótese de que a inclinação seja igual a uma constante, digamos  $\beta_{1,0}$ . Ou seja, queremos testar, ao nível de significância  $\alpha$  as hipóteses:

$$H_0 : \beta_1 = \beta_{1,0} \quad \text{contra} \quad H_1 : \beta_1 \neq \beta_{1,0}$$

- Note que uma vez que estamos supondo que  $\epsilon_i \sim N(0, \sigma^2)$ , então as observações  $Y_i$  também são  $N(\beta_0 + \beta_1 x_i, \sigma^2)$ . Como  $\hat{\beta}_1$  é uma combinação linear das variáveis normais, então  $\hat{\beta}_1$  é também  $N(\beta_1, \frac{\sigma^2}{S_{xx}})$ .
- Logo, para realizar um teste da forma acima, usamos a seguinte estatística de teste

$$T_0 = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

que tem distribuição  $t$  com  $n - 2$  graus de liberdade, sujeito a  $H_0$ .

- Logo, com um argumento análogo ao que usamos em testes de hipóteses, temos que a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \text{ ou } t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_1$

- Suponha que queremos testar a hipótese de que a inclinação seja igual a uma constante, digamos  $\beta_{1,0}$ . Ou seja, queremos testar, ao nível de significância  $\alpha$  as hipóteses:

$$H_0 : \beta_1 = \beta_{1,0} \quad \text{contra} \quad H_1 : \beta_1 \neq \beta_{1,0}$$

- Note que uma vez que estamos supondo que  $\epsilon_i \sim N(0, \sigma^2)$ , então as observações  $Y_i$  também são  $N(\beta_0 + \beta_1 x_i, \sigma^2)$ . Como  $\hat{\beta}_1$  é uma combinação linear das variáveis normais, então  $\hat{\beta}_1$  é também  $N(\beta_1, \frac{\sigma^2}{S_{xx}})$ .
- Logo, para realizar um teste da forma acima, usamos a seguinte estatística de teste

$$T_0 = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

que tem distribuição  $t$  com  $n - 2$  graus de liberdade, sujeito a  $H_0$ .

- Logo, com um argumento análogo ao que usamos em testes de hipóteses, temos que a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \text{ ou } t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_0$

- Um procedimento similar pode ser usado para testar hipóteses sobre o intercepto, ou seja, se queremos testar as hipóteses

$$H_0 : \beta_0 = \beta_{0,0} \quad \text{contra} \quad H_1 : \beta_0 \neq \beta_{0,0}$$

- Então usamos a estatística de teste

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- E a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \quad \text{ou} \quad t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_0$

- Um procedimento similar pode ser usado para testar hipóteses sobre o intercepto, ou seja, se queremos testar as hipóteses

$$H_0 : \beta_0 = \beta_{0,0} \quad \text{contra} \quad H_1 : \beta_0 \neq \beta_{0,0}$$

- Então usamos a estatística de teste

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- E a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \quad \text{ou} \quad t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .



# Testes de hipóteses para $\beta_0$

- Um procedimento similar pode ser usado para testar hipóteses sobre o intercepto, ou seja, se queremos testar as hipóteses

$$H_0 : \beta_0 = \beta_{0,0} \quad \text{contra} \quad H_1 : \beta_0 \neq \beta_{0,0}$$

- Então usamos a estatística de teste

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- E a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \quad \text{ou} \quad t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_0$

- Um procedimento similar pode ser usado para testar hipóteses sobre o intercepto, ou seja, se queremos testar as hipóteses

$$H_0 : \beta_0 = \beta_{0,0} \quad \text{contra} \quad H_1 : \beta_0 \neq \beta_{0,0}$$

- Então usamos a estatística de teste

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- E a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \quad \text{ou} \quad t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_0$

- Um procedimento similar pode ser usado para testar hipóteses sobre o intercepto, ou seja, se queremos testar as hipóteses

$$H_0 : \beta_0 = \beta_{0,0} \quad \text{contra} \quad H_1 : \beta_0 \neq \beta_{0,0}$$

- Então usamos a estatística de teste

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- E a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \quad \text{ou} \quad t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_0$

- Um procedimento similar pode ser usado para testar hipóteses sobre o intercepto, ou seja, se queremos testar as hipóteses

$$H_0 : \beta_0 = \beta_{0,0} \quad \text{contra} \quad H_1 : \beta_0 \neq \beta_{0,0}$$

- Então usamos a estatística de teste

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- E a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \quad \text{ou} \quad t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Testes de hipóteses para $\beta_0$

- Um procedimento similar pode ser usado para testar hipóteses sobre o intercepto, ou seja, se queremos testar as hipóteses

$$H_0 : \beta_0 = \beta_{0,0} \quad \text{contra} \quad H_1 : \beta_0 \neq \beta_{0,0}$$

- Então usamos a estatística de teste

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- E a região de rejeição desse teste é

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \quad \text{ou} \quad t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ .

# Um caso especial do testes de hipóteses para $\beta_1$

- Um caso especial e importante das hipóteses sobre  $\beta_1$  é testar as hipóteses

$$H_0 : \beta_1 = 0 \quad \text{contra} \quad H_1 : \beta_1 \neq 0$$

- Essas hipóteses se relacionam com a significância da regressão.
- Aceitar  $H_0 : \beta_1 = 0$  é equivalente a concluir que não há relação linear entre  $x$  e  $Y$ .
  - ▶ Isso pode implicar que  $x$  seja de pouco valor para explicar a variação em  $Y$ .
- Rejeitar  $H_0 : \beta_1 = 0$  implica que  $x$  é importante para explicar a variabilidade de  $Y$ .

# Um caso especial do testes de hipóteses para $\beta_1$

- Um caso especial e importante das hipóteses sobre  $\beta_1$  é testar as hipóteses

$$H_0 : \beta_1 = 0 \quad \text{contra} \quad H_1 : \beta_1 \neq 0$$

- Essas hipóteses se relacionam com a significância da regressão.
- Aceitar  $H_0 : \beta_1 = 0$  é equivalente a concluir que não há relação linear entre  $x$  e  $Y$ .
  - ▶ Isso pode implicar que  $x$  seja de pouco valor para explicar a variação em  $Y$ .
- Rejeitar  $H_0 : \beta_1 = 0$  implica que  $x$  é importante para explicar a variabilidade de  $Y$ .

# Um caso especial do testes de hipóteses para $\beta_1$

- Um caso especial e importante das hipóteses sobre  $\beta_1$  é testar as hipóteses

$$H_0 : \beta_1 = 0 \quad \text{contra} \quad H_1 : \beta_1 \neq 0$$

- Essas hipóteses se relacionam com a significância da regressão.
- Aceitar  $H_0 : \beta_1 = 0$  é equivalente a concluir que não há relação linear entre  $x$  e  $Y$ .
  - ▶ Isso pode implicar que  $x$  seja de pouco valor para explicar a variação em  $Y$ .
- Rejeitar  $H_0 : \beta_1 = 0$  implica que  $x$  é importante para explicar a variabilidade de  $Y$ .



# Um caso especial do testes de hipóteses para $\beta_1$

- Um caso especial e importante das hipóteses sobre  $\beta_1$  é testar as hipóteses

$$H_0 : \beta_1 = 0 \quad \text{contra} \quad H_1 : \beta_1 \neq 0$$

- Essas hipóteses se relacionam com a significância da regressão.
- Aceitar  $H_0 : \beta_1 = 0$  é equivalente a concluir que não há relação linear entre  $x$  e  $Y$ .
  - ▶ Isso pode implicar que  $x$  seja de pouco valor para explicar a variação em  $Y$ .
- Rejeitar  $H_0 : \beta_1 = 0$  implica que  $x$  é importante para explicar a variabilidade de  $Y$ .

# Um caso especial do testes de hipóteses para $\beta_1$

- Um caso especial e importante das hipóteses sobre  $\beta_1$  é testar as hipóteses

$$H_0 : \beta_1 = 0 \quad \text{contra} \quad H_1 : \beta_1 \neq 0$$

- Essas hipóteses se relacionam com a significância da regressão.
- Aceitar  $H_0 : \beta_1 = 0$  é equivalente a concluir que não há relação linear entre  $x$  e  $Y$ .
  - ▶ Isso pode implicar que  $x$  seja de pouco valor para explicar a variação em  $Y$ .
- Rejeitar  $H_0 : \beta_1 = 0$  implica que  $x$  é importante para explicar a variabilidade de  $Y$ .

# Um caso especial do testes de hipóteses para $\beta_1$

- Um caso especial e importante das hipóteses sobre  $\beta_1$  é testar as hipóteses

$$H_0 : \beta_1 = 0 \quad \text{contra} \quad H_1 : \beta_1 \neq 0$$

- Essas hipóteses se relacionam com a significância da regressão.
- Aceitar  $H_0 : \beta_1 = 0$  é equivalente a concluir que não há relação linear entre  $x$  e  $Y$ .
  - ▶ Isso pode implicar que  $x$  seja de pouco valor para explicar a variação em  $Y$ .
- Rejeitar  $H_0 : \beta_1 = 0$  implica que  $x$  é importante para explicar a variabilidade de  $Y$ .

## Exemplo

Exemplo: Um artigo na revista *IEEE transactions on instrumentation and measurement* ["Direct, fast, and accurate measurement of  $V_T$  and  $K$  of an MOS transistor using a  $V_T$ -sift circuit" (Vol. 40, 1991, pp. 951-955)] descreveu o uso de um modelo de regressão linear simples para expressar a corrente  $y$  (em miliamperes), como função da diferença de voltagem  $x$  (em volts). Os dados são fornecidos a seguir:

$x$	1.1	1.2	1.3	1.4	1.5	1.6	1.7	1.8	1.9	2
$y$	0.734	0.886	1.04	1.19	1.35	1.5	1.66	1.81	1.97	2.12

- (a) Desenhe um diagrama de dispersão desses dados. Um modelo de regressão linear simples parece plausível?
- (b) Ajuste um modelo de regressão linear simples a esses dados.
- (c) Teste a hipótese de que  $H_0 : \beta_0 = 0$  contra  $H_1 : \beta_0 \neq 0$ , ao nível de significância  $\alpha = 5\%$ .

## Exemplo

Exemplo: Um artigo na revista *IEEE transactions on instrumentation and measurement* ["Direct, fast, and accurate measurement of  $V_T$  and  $K$  of an MOS transistor using a  $V_T$ -sift circuit" (Vol. 40, 1991, pp. 951-955)] descreveu o uso de um modelo de regressão linear simples para expressar a corrente  $y$  (em miliamperes), como função da diferença de voltagem  $x$  (em volts). Os dados são fornecidos a seguir:

$x$	1.1	1.2	1.3	1.4	1.5	1.6	1.7	1.8	1.9	2
$y$	0.734	0.886	1.04	1.19	1.35	1.5	1.66	1.81	1.97	2.12

- (a) Desenhe um diagrama de dispersão desses dados. Um modelo de regressão linear simples parece plausível?
- (b) Ajuste um modelo de regressão linear simples a esses dados.
- (c) Teste a hipótese de que  $H_0 : \beta_0 = 0$  contra  $H_1 : \beta_0 \neq 0$ , ao nível de significância  $\alpha = 5\%$ .

## Exemplo

Exemplo: Um artigo na revista *IEEE transactions on instrumentation and measurement* ["Direct, fast, and accurate measurement of  $V_T$  and  $K$  of an MOS transistor using a  $V_T$ -sift circuit" (Vol. 40, 1991, pp. 951-955)] descreveu o uso de um modelo de regressão linear simples para expressar a corrente  $y$  (em miliamperes), como função da diferença de voltagem  $x$  (em volts). Os dados são fornecidos a seguir:

$x$	1.1	1.2	1.3	1.4	1.5	1.6	1.7	1.8	1.9	2
$y$	0.734	0.886	1.04	1.19	1.35	1.5	1.66	1.81	1.97	2.12

- (a) Desenhe um diagrama de dispersão desses dados. Um modelo de regressão linear simples parece plausível?
- (b) Ajuste um modelo de regressão linear simples a esses dados.
- (c) Teste a hipótese de que  $H_0 : \beta_0 = 0$  contra  $H_1 : \beta_0 \neq 0$ , ao nível de significância  $\alpha = 5\%$ .

## Exemplo

Exemplo: Um artigo na revista *IEEE transactions on instrumentation and measurement* ["Direct, fast, and accurate measurement of  $V_T$  and  $K$  of an MOS transistor using a  $V_T$ -sift circuit" (Vol. 40, 1991, pp. 951-955)] descreveu o uso de um modelo de regressão linear simples para expressar a corrente  $y$  (em miliamperes), como função da diferença de voltagem  $x$  (em volts). Os dados são fornecidos a seguir:

$x$	1.1	1.2	1.3	1.4	1.5	1.6	1.7	1.8	1.9	2
$y$	0.734	0.886	1.04	1.19	1.35	1.5	1.66	1.81	1.97	2.12

- (a) Desenhe um diagrama de dispersão desses dados. Um modelo de regressão linear simples parece plausível?
- (b) Ajuste um modelo de regressão linear simples a esses dados.
- (c) Teste a hipótese de que  $H_0 : \beta_0 = 0$  contra  $H_1 : \beta_0 \neq 0$ , ao nível de significância  $\alpha = 5\%$ .

## Exemplo

Exemplo: Um artigo na revista *IEEE transactions on instrumentation and measurement* ["Direct, fast, and accurate measurement of  $V_T$  and  $K$  of an MOS transistor using a  $V_T$ -sift circuit" (Vol. 40, 1991, pp. 951-955)] descreveu o uso de um modelo de regressão linear simples para expressar a corrente  $y$  (em miliamperes), como função da diferença de voltagem  $x$  (em volts). Os dados são fornecidos a seguir:

$x$	1.1	1.2	1.3	1.4	1.5	1.6	1.7	1.8	1.9	2
$y$	0.734	0.886	1.04	1.19	1.35	1.5	1.66	1.81	1.97	2.12

- (a) Desenhe um diagrama de dispersão desses dados. Um modelo de regressão linear simples parece plausível?
- (b) Ajuste um modelo de regressão linear simples a esses dados.
- (c) Teste a hipótese de que  $H_0 : \beta_0 = 0$  contra  $H_1 : \beta_0 \neq 0$ , ao nível de significância  $\alpha = 5\%$ .



## Sol. (a)




Figure 1: Dados do problema. X: Diferença de voltagem, Y: Corrente

## Sol. (b)

Recorde que para ajustar o modelo precisamos obter  $\hat{\beta}_0$  e  $\hat{\beta}_1$ .

- Temos que  $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$  e  $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$ .

- Temos ainda que

- $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1.1+1.2+1.3+1.4+1.5+1.6+1.7+1.8+1.9+2}{10} = 1.55;$

- $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{0.734+0.886+1.04+1.19+1.35+1.5+1.66+1.81+1.97+2.12}{10} = 1.426;$

- $\sum_{i=1}^n y_i x_i =$   
 $(1.1)(0.734) + (1.2)(0.886) + (1.3)(1.04) + (1.4)(1.19) + (1.5)(1.35) +$   
 $(1.6)(1.5) + (1.7)(1.66) + (1.8)(1.81) + (1.9)(1.97) + (2)(2.12) = 23.3766;$

- $\sum_{i=1}^n x_i^2 =$   
 $1.1^2 + 1.2^2 + 1.3^2 + 1.4^2 + 1.5^2 + 1.6^2 + 1.7^2 + 1.8^2 + 1.9^2 + 2^2 = 24.85.$

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{23.3766 - 10(1.55)(1.426)}{24.85 - 10(1.55)^2} \approx 1.54376$$

## Sol. (b)

Recorde que para ajustar o modelo precisamos obter  $\hat{\beta}_0$  e  $\hat{\beta}_1$ .

- Temos que  $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$  e  $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$ .

- Temos ainda que

- $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1.1+1.2+1.3+1.4+1.5+1.6+1.7+1.8+1.9+2}{10} = 1.55;$

- $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{0.734+0.886+1.04+1.19+1.35+1.5+1.66+1.81+1.97+2.12}{10} = 1.426;$

- $\sum_{i=1}^n y_i x_i =$   
 $(1.1)(0.734) + (1.2)(0.886) + (1.3)(1.04) + (1.4)(1.19) + (1.5)(1.35) +$   
 $(1.6)(1.5) + (1.7)(1.66) + (1.8)(1.81) + (1.9)(1.97) + (2)(2.12) = 23.3766;$

- $\sum_{i=1}^n x_i^2 =$   
 $1.1^2 + 1.2^2 + 1.3^2 + 1.4^2 + 1.5^2 + 1.6^2 + 1.7^2 + 1.8^2 + 1.9^2 + 2^2 = 24.85.$

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{23.3766 - 10(1.55)(1.426)}{24.85 - 10(1.55)^2} \approx 1.54376$$

## Sol. (b)

Recorde que para ajustar o modelo precisamos obter  $\hat{\beta}_0$  e  $\hat{\beta}_1$ .

- Temos que  $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$  e  $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$ .

- Temos ainda que

- ▶  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1.1+1.2+1.3+1.4+1.5+1.6+1.7+1.8+1.9+2}{10} = 1.55;$

- ▶  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{0.734+0.886+1.04+1.19+1.35+1.5+1.66+1.81+1.97+2.12}{10} = 1.426;$

- ▶  $\sum_{i=1}^n y_i x_i =$   
 $(1.1)(0.734) + (1.2)(0.886) + (1.3)(1.04) + (1.4)(1.19) + (1.5)(1.35) +$   
 $(1.6)(1.5) + (1.7)(1.66) + (1.8)(1.81) + (1.9)(1.97) + (2)(2.12) = 23.3766;$

- ▶  $\sum_{i=1}^n x_i^2 =$   
 $1.1^2 + 1.2^2 + 1.3^2 + 1.4^2 + 1.5^2 + 1.6^2 + 1.7^2 + 1.8^2 + 1.9^2 + 2^2 = 24.85.$

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{23.3766 - 10(1.55)(1.426)}{24.85 - 10(1.55)^2} \approx 1.54376$$

## Sol. (b)

Recorde que para ajustar o modelo precisamos obter  $\hat{\beta}_0$  e  $\hat{\beta}_1$ .

- Temos que  $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$  e  $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$ .

- Temos ainda que

- ▶  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1.1+1.2+1.3+1.4+1.5+1.6+1.7+1.8+1.9+2}{10} = 1.55;$

- ▶  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{0.734+0.886+1.04+1.19+1.35+1.5+1.66+1.81+1.97+2.12}{10} = 1.426;$

- ▶  $\sum_{i=1}^n y_i x_i =$   
 $(1.1)(0.734) + (1.2)(0.886) + (1.3)(1.04) + (1.4)(1.19) + (1.5)(1.35) +$   
 $(1.6)(1.5) + (1.7)(1.66) + (1.8)(1.81) + (1.9)(1.97) + (2)(2.12) = 23.3766;$

- ▶  $\sum_{i=1}^n x_i^2 =$   
 $1.1^2 + 1.2^2 + 1.3^2 + 1.4^2 + 1.5^2 + 1.6^2 + 1.7^2 + 1.8^2 + 1.9^2 + 2^2 = 24.85.$

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{23.3766 - 10(1.55)(1.426)}{24.85 - 10(1.55)^2} \approx 1.54376$$

## Sol. (b)

Recorde que para ajustar o modelo precisamos obter  $\hat{\beta}_0$  e  $\hat{\beta}_1$ .

- Temos que  $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$  e  $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$ .

- Temos ainda que

- ▶  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1.1+1.2+1.3+1.4+1.5+1.6+1.7+1.8+1.9+2}{10} = 1.55$ ;

- ▶  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{0.734+0.886+1.04+1.19+1.35+1.5+1.66+1.81+1.97+2.12}{10} = 1.426$ ;

- ▶  $\sum_{i=1}^n y_i x_i =$   
 $(1.1)(0.734) + (1.2)(0.886) + (1.3)(1.04) + (1.4)(1.19) + (1.5)(1.35) +$   
 $(1.6)(1.5) + (1.7)(1.66) + (1.8)(1.81) + (1.9)(1.97) + (2)(2.12) = 23.3766$ ;

- ▶  $\sum_{i=1}^n x_i^2 =$   
 $1.1^2 + 1.2^2 + 1.3^2 + 1.4^2 + 1.5^2 + 1.6^2 + 1.7^2 + 1.8^2 + 1.9^2 + 2^2 = 24.85$ .

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{23.3766 - 10(1.55)(1.426)}{24.85 - 10(1.55)^2} \approx 1.54376$$

## Sol. (b)

Recorde que para ajustar o modelo precisamos obter  $\hat{\beta}_0$  e  $\hat{\beta}_1$ .

- Temos que  $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$  e  $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$ .

- Temos ainda que

- ▶  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1.1+1.2+1.3+1.4+1.5+1.6+1.7+1.8+1.9+2}{10} = 1.55;$

- ▶  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{0.734+0.886+1.04+1.19+1.35+1.5+1.66+1.81+1.97+2.12}{10} = 1.426;$

- ▶  $\sum_{i=1}^n y_i x_i =$   
 $(1.1)(0.734) + (1.2)(0.886) + (1.3)(1.04) + (1.4)(1.19) + (1.5)(1.35) +$   
 $(1.6)(1.5) + (1.7)(1.66) + (1.8)(1.81) + (1.9)(1.97) + (2)(2.12) = 23.3766;$

- ▶  $\sum_{i=1}^n x_i^2 =$   
 $1.1^2 + 1.2^2 + 1.3^2 + 1.4^2 + 1.5^2 + 1.6^2 + 1.7^2 + 1.8^2 + 1.9^2 + 2^2 = 24.85.$

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{23.3766 - 10(1.55)(1.426)}{24.85 - 10(1.55)^2} \approx 1.54376$$

## Sol. (b)

Recorde que para ajustar o modelo precisamos obter  $\hat{\beta}_0$  e  $\hat{\beta}_1$ .

- Temos que  $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$  e  $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$ .

- Temos ainda que

- ▶  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1.1+1.2+1.3+1.4+1.5+1.6+1.7+1.8+1.9+2}{10} = 1.55$ ;

- ▶  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{0.734+0.886+1.04+1.19+1.35+1.5+1.66+1.81+1.97+2.12}{10} = 1.426$ ;

- ▶  $\sum_{i=1}^n y_i x_i =$   
 $(1.1)(0.734) + (1.2)(0.886) + (1.3)(1.04) + (1.4)(1.19) + (1.5)(1.35) +$   
 $(1.6)(1.5) + (1.7)(1.66) + (1.8)(1.81) + (1.9)(1.97) + (2)(2.12) = 23.3766$ ;

- ▶  $\sum_{i=1}^n x_i^2 =$   
 $1.1^2 + 1.2^2 + 1.3^2 + 1.4^2 + 1.5^2 + 1.6^2 + 1.7^2 + 1.8^2 + 1.9^2 + 2^2 = 24.85$ .

- Logo, temos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{23.3766 - 10(1.55)(1.426)}{24.85 - 10(1.55)^2} \approx 1.54376$$



- E ainda

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (1.426) - (1.54376)(1.55) \approx -0.966824.$$

- Portanto, o modelo ajustado é  $\hat{y}_i = -0.966824 + 1.54376x_i$

- E ainda

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (1.426) - (1.54376)(1.55) \approx -0.966824.$$

- Portanto, o modelo ajustado é  $\hat{y}_i = -0.966824 + 1.54376x_i$

- E ainda

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = (1.426) - (1.54376)(1.55) \approx -0.966824.$$

- Portanto, o modelo ajustado é  $\hat{y}_i = -0.966824 + 1.54376x_i$

# Modelo ajustado




Figure 2: Modelo ajustado

## Sol. (c)

- No item (c) queremos testar hipóteses com respeito ao intercepto do modelo, ou seja, queremos testar, ao nível de significância  $\alpha = 5\%$ , as hipóteses  $H_0 : \beta_0 = 0$  contra  $H_1 : \beta_0 \neq 0$ .
- Vimos que um teste de nível  $\alpha$  para  $\beta_0$  tem região de rejeição

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \text{ ou } t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ , dada por

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- Dessa forma, precisamos obter a estimativa  $\hat{\sigma}^2$ .

## Sol. (c)

- No item (c) queremos testar hipóteses com respeito ao intercepto do modelo, ou seja, queremos testar, ao nível de significância  $\alpha = 5\%$ , as hipóteses  $H_0 : \beta_0 = 0$  contra  $H_1 : \beta_0 \neq 0$ .
- Vimos que um teste de nível  $\alpha$  para  $\beta_0$  tem região de rejeição

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \text{ ou } t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ , dada por

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- Dessa forma, precisamos obter a estimativa  $\hat{\sigma}^2$ .

## Sol. (c)

- No item (c) queremos testar hipóteses com respeito ao intercepto do modelo, ou seja, queremos testar, ao nível de significância  $\alpha = 5\%$ , as hipóteses  $H_0 : \beta_0 = 0$  contra  $H_1 : \beta_0 \neq 0$ .
- Vimos que um teste de nível  $\alpha$  para  $\beta_0$  tem região de rejeição

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \text{ ou } t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ , dada por

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- Dessa forma, precisamos obter a estimativa  $\hat{\sigma}^2$ .

## Sol. (c)

- No item (c) queremos testar hipóteses com respeito ao intercepto do modelo, ou seja, queremos testar, ao nível de significância  $\alpha = 5\%$ , as hipóteses  $H_0 : \beta_0 = 0$  contra  $H_1 : \beta_0 \neq 0$ .
- Vimos que um teste de nível  $\alpha$  para  $\beta_0$  tem região de rejeição

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \text{ ou } t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ , dada por

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- Dessa forma, precisamos obter a estimativa  $\hat{\sigma}^2$ .



## Sol. (c)

- No item (c) queremos testar hipóteses com respeito ao intercepto do modelo, ou seja, queremos testar, ao nível de significância  $\alpha = 5\%$ , as hipóteses  $H_0 : \beta_0 = 0$  contra  $H_1 : \beta_0 \neq 0$ .
- Vimos que um teste de nível  $\alpha$  para  $\beta_0$  tem região de rejeição

$$A_1 = \{t_0 > t_{\frac{\alpha}{2}, n-2} \text{ ou } t_0 < -t_{\frac{\alpha}{2}, n-2}\}$$

em que  $t_0$  é o valor observado da estatística de teste  $T_0$ , dada por

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- Dessa forma, precisamos obter a estimativa  $\hat{\sigma}^2$ .

## Cont. (c)

- Vimos que  $\hat{\sigma}^2 = \frac{SQ_E}{n-2}$ , em que  $SQ_E = SQ_T - \hat{\beta}_1 S_{xy}$
- Sendo

$$SQ_T = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad \text{e} \quad S_{xy} = \sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}$$

- Como temos que  $\sum_{i=1}^n y_i^2 = (0.734)^2 + (0.886)^2 + (1.04)^2 + (1.19)^2 + (1.35)^2 + (1.5)^2 + (1.66)^2 + (1.81)^2 + (1.97)^2 + (2.12)^2 \approx 22.301$ , e já vimos que  $\bar{y} = 1.426$ , temos que

$$SQ_T = 22.301 - 10(1.426)^2 = 1.96624$$

- Já calculamos  $S_{xy}$ , ou seja, obtivemos que  $S_{xy} = 23.3766 - 10(1.55)(1.426) = 1.2736$ .
- Logo, substituindo em  $\hat{\sigma}^2 = \frac{SQ_E}{n-2}$  temos que

$$\hat{\sigma}^2 = \frac{1.96624 - 1.54376(1.2736)}{10 - 2} \approx 0.000013$$

## Cont. (c)

- Vimos que  $\hat{\sigma}^2 = \frac{SQ_E}{n-2}$ , em que  $SQ_E = SQ_T - \hat{\beta}_1 S_{xy}$
- Sendo

$$SQ_T = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad \text{e} \quad S_{xy} = \sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}$$

- Como temos que  $\sum_{i=1}^n y_i^2 = (0.734)^2 + (0.886)^2 + (1.04)^2 + (1.19)^2 + (1.35)^2 + (1.5)^2 + (1.66)^2 + (1.81)^2 + (1.97)^2 + (2.12)^2 \approx 22.301$ , e já vimos que  $\bar{y} = 1.426$ , temos que

$$SQ_T = 22.301 - 10(1.426)^2 = 1.96624$$

- Já calculamos  $S_{xy}$ , ou seja, obtivemos que  $S_{xy} = 23.3766 - 10(1.55)(1.426) = 1.2736$ .
- Logo, substituindo em  $\hat{\sigma}^2 = \frac{SQ_E}{n-2}$  temos que

$$\hat{\sigma}^2 = \frac{1.96624 - 1.54376(1.2736)}{10 - 2} \approx 0.000013$$

## Cont. (c)

- Vimos que  $\hat{\sigma}^2 = \frac{SQ_E}{n-2}$ , em que  $SQ_E = SQ_T - \hat{\beta}_1 S_{xy}$
- Sendo

$$SQ_T = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad \text{e} \quad S_{xy} = \sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}$$

- Como temos que  $\sum_{i=1}^n y_i^2 = (0.734)^2 + (0.886)^2 + (1.04)^2 + (1.19)^2 + (1.35)^2 + (1.5)^2 + (1.66)^2 + (1.81)^2 + (1.97)^2 + (2.12)^2 \approx 22.301$ , e já vimos que  $\bar{y} = 1.426$ , temos que

$$SQ_T = 22.301 - 10(1.426)^2 = 1.96624$$

- Já calculamos  $S_{xy}$ , ou seja, obtivemos que  $S_{xy} = 23.3766 - 10(1.55)(1.426) = 1.2736$ .
- Logo, substituindo em  $\hat{\sigma}^2 = \frac{SQ_E}{n-2}$  temos que

$$\hat{\sigma}^2 = \frac{1.96624 - 1.54376(1.2736)}{10 - 2} \approx 0.000013$$

## Cont. (c)

- Vimos que  $\hat{\sigma}^2 = \frac{SQ_E}{n-2}$ , em que  $SQ_E = SQ_T - \hat{\beta}_1 S_{xy}$
- Sendo

$$SQ_T = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad \text{e} \quad S_{xy} = \sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}$$

- Como temos que  $\sum_{i=1}^n y_i^2 = (0.734)^2 + (0.886)^2 + (1.04)^2 + (1.19)^2 + (1.35)^2 + (1.5)^2 + (1.66)^2 + (1.81)^2 + (1.97)^2 + (2.12)^2 \approx 22.301$ , e já vimos que  $\bar{y} = 1.426$ , temos que

$$SQ_T = 22.301 - 10(1.426)^2 = 1.96624$$

- Já calculamos  $S_{xy}$ , ou seja, obtivemos que  $S_{xy} = 23.3766 - 10(1.55)(1.426) = 1.2736$ .
- Logo, substituindo em  $\hat{\sigma}^2 = \frac{SQ_E}{n-2}$  temos que

$$\hat{\sigma}^2 = \frac{1.96624 - 1.54376(1.2736)}{10 - 2} \approx 0.000013$$

## Cont. (c)

- Vimos que  $\hat{\sigma}^2 = \frac{SQ_E}{n-2}$ , em que  $SQ_E = SQ_T - \hat{\beta}_1 S_{xy}$
- Sendo

$$SQ_T = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad \text{e} \quad S_{xy} = \sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}$$

- Como temos que  $\sum_{i=1}^n y_i^2 = (0.734)^2 + (0.886)^2 + (1.04)^2 + (1.19)^2 + (1.35)^2 + (1.5)^2 + (1.66)^2 + (1.81)^2 + (1.97)^2 + (2.12)^2 \approx 22.301$ , e já vimos que  $\bar{y} = 1.426$ , temos que

$$SQ_T = 22.301 - 10(1.426)^2 = 1.96624$$

- Já calculamos  $S_{xy}$ , ou seja, obtivemos que  $S_{xy} = 23.3766 - 10(1.55)(1.426) = 1.2736$ .
- Logo, substituindo em  $\hat{\sigma}^2 = \frac{SQ_E}{n-2}$  temos que

$$\hat{\sigma}^2 = \frac{1.96624 - 1.54376(1.2736)}{10 - 2} \approx 0.000013$$

## Cont. (c)

- Vimos que  $\hat{\sigma}^2 = \frac{SQ_E}{n-2}$ , em que  $SQ_E = SQ_T - \hat{\beta}_1 S_{xy}$
- Sendo

$$SQ_T = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad \text{e} \quad S_{xy} = \sum_{i=1}^n y_i x_i - n\bar{x}\bar{y}$$

- Como temos que  $\sum_{i=1}^n y_i^2 = (0.734)^2 + (0.886)^2 + (1.04)^2 + (1.19)^2 + (1.35)^2 + (1.5)^2 + (1.66)^2 + (1.81)^2 + (1.97)^2 + (2.12)^2 \approx 22.301$ , e já vimos que  $\bar{y} = 1.426$ , temos que

$$SQ_T = 22.301 - 10(1.426)^2 = 1.96624$$

- Já calculamos  $S_{xy}$ , ou seja, obtivemos que  $S_{xy} = 23.3766 - 10(1.55)(1.426) = 1.2736$ .
- Logo, substituindo em  $\hat{\sigma}^2 = \frac{SQ_E}{n-2}$  temos que

$$\hat{\sigma}^2 = \frac{1.96624 - 1.54376(1.2736)}{10 - 2} \approx 0.000013$$

- Logo, como a estatística de teste é

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- Então o valor observado da estatística de teste é

$$t_0 = \frac{-0.966824}{\sqrt{(0.000013) \left[ \frac{1}{10} + \frac{(1.55)^2}{0.825} \right]}} \approx -154.504$$

- Note que nós já calculamos  $S_{xx}$  no denominador de  $\hat{\beta}_1$ .
- Logo, como  $\alpha = 5\%$ , temos que  $t_{\frac{\alpha}{2}, n-2} = t_{0.025, 8} = 2.306$ .
- Dessa forma, temos que  $t_0 < -t_{\frac{\alpha}{2}, n-2}$ , uma vez que  $-154.504 < -2.306$ . Portanto, rejeitamos  $H_0$ .



- Logo, como a estatística de teste é

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- Então o valor observado da estatística de teste é

$$t_0 = \frac{-0.966824}{\sqrt{(0.000013) \left[ \frac{1}{10} + \frac{(1.55)^2}{0.825} \right]}} \approx -154.504$$

- Note que nós já calculamos  $S_{xx}$  no denominador de  $\hat{\beta}_1$ .
- Logo, como  $\alpha = 5\%$ , temos que  $t_{\frac{\alpha}{2}, n-2} = t_{0.025, 8} = 2.306$ .
- Dessa forma, temos que  $t_0 < -t_{\frac{\alpha}{2}, n-2}$ , uma vez que  $-154.504 < -2.306$ . Portanto, rejeitamos  $H_0$ .

- Logo, como a estatística de teste é

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- Então o valor observado da estatística de teste é

$$t_0 = \frac{-0.966824}{\sqrt{(0.000013) \left[ \frac{1}{10} + \frac{(1.55)^2}{0.825} \right]}} \approx -154.504$$

- Note que nós já calculamos  $S_{xx}$  no denominador de  $\hat{\beta}_1$ .
- Logo, como  $\alpha = 5\%$ , temos que  $t_{\frac{\alpha}{2}, n-2} = t_{0.025, 8} = 2.306$ .
- Dessa forma, temos que  $t_0 < -t_{\frac{\alpha}{2}, n-2}$ , uma vez que  $-154.504 < -2.306$ . Portanto, rejeitamos  $H_0$ .

- Logo, como a estatística de teste é

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- Então o valor observado da estatística de teste é

$$t_0 = \frac{-0.966824}{\sqrt{(0.000013) \left[ \frac{1}{10} + \frac{(1.55)^2}{0.825} \right]}} \approx -154.504$$

- Note que nós já calculamos  $S_{xx}$  no denominador de  $\hat{\beta}_1$ .
- Logo, como  $\alpha = 5\%$ , temos que  $t_{\frac{\alpha}{2}, n-2} = t_{0.025, 8} = 2.306$ .
- Dessa forma, temos que  $t_0 < -t_{\frac{\alpha}{2}, n-2}$ , uma vez que  $-154.504 < -2.306$ . Portanto, rejeitamos  $H_0$ .

- Logo, como a estatística de teste é

$$T_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

- Então o valor observado da estatística de teste é

$$t_0 = \frac{-0.966824}{\sqrt{(0.000013) \left[ \frac{1}{10} + \frac{(1.55)^2}{0.825} \right]}} \approx -154.504$$

- Note que nós já calculamos  $S_{xx}$  no denominador de  $\hat{\beta}_1$ .
- Logo, como  $\alpha = 5\%$ , temos que  $t_{\frac{\alpha}{2}, n-2} = t_{0.025, 8} = 2.306$ .
- Dessa forma, temos que  $t_0 < -t_{\frac{\alpha}{2}, n-2}$ , uma vez que  $-154.504 < -2.306$ . Portanto, rejeitamos  $H_0$ .

# IC para o intercepto e a inclinação

- Podemos ainda obter estimativas de intervalo de confiança para os parâmetros  $\beta_0$  e  $\beta_1$  do modelo de regressão linear simples.
- Assumindo mais uma vez que os erros no modelo de regressão são normal e independentemente distribuídos, então as variáveis aleatórias

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}} \quad \text{e} \quad \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

são ambas distribuídas como uma  $t$  com  $n-2$  graus de liberdade.

- Logo, podemos usar esses fatos para obter IC para  $\beta_0$  e  $\beta_1$ , procedendo de forma análoga ao que estudamos em IC.

# IC para o intercepto e a inclinação

- Podemos ainda obter estimativas de intervalo de confiança para os parâmetros  $\beta_0$  e  $\beta_1$  do modelo de regressão linear simples.
- Assumindo mais uma vez que os erros no modelo de regressão são normal e independentemente distribuídos, então as variáveis aleatórias

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}} \quad \text{e} \quad \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

são ambas distribuídas como uma  $t$  com  $n-2$  graus de liberdade.

- Logo, podemos usar esses fatos para obter IC para  $\beta_0$  e  $\beta_1$ , procedendo de forma análoga ao que estudamos em IC.

# IC para o intercepto e a inclinação

- Podemos ainda obter estimativas de intervalo de confiança para os parâmetros  $\beta_0$  e  $\beta_1$  do modelo de regressão linear simples.
- Assumindo mais uma vez que os erros no modelo de regressão são normal e independentemente distribuídos, então as variáveis aleatórias

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}} \quad \text{e} \quad \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

são ambas distribuídas como uma  $t$  com  $n-2$  graus de liberdade.

- Logo, podemos usar esses fatos para obter IC para  $\beta_0$  e  $\beta_1$ , procedendo de forma análoga ao que estudamos em IC.

# IC para o intercepto e a inclinação

- Podemos ainda obter estimativas de intervalo de confiança para os parâmetros  $\beta_0$  e  $\beta_1$  do modelo de regressão linear simples.
- Assumindo mais uma vez que os erros no modelo de regressão são normal e independentemente distribuídos, então as variáveis aleatórias

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}} \quad \text{e} \quad \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}}$$

são ambas distribuídas como uma  $t$  com  $n-2$  graus de liberdade.

- Logo, podemos usar esses fatos para obter IC para  $\beta_0$  e  $\beta_1$ , procedendo de forma análoga ao que estudamos em IC.



# IC para o intercepto e a inclinação

- Logo, temos que um IC com  $100(1 - \alpha)\%$  para  $\beta_1$  é

$$\hat{\beta}_1 - t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}$$

- De maneira similar, temos que um IC com  $100(1 - \alpha)\%$  para  $\beta_0$  é

$$\hat{\beta}_0 - t_{\alpha/2, n-2} \sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]} \leq \beta_0 \leq \hat{\beta}_0 + t_{\alpha/2, n-2} \sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}$$

# IC para o intercepto e a inclinação

- Logo, temos que um IC com  $100(1 - \alpha)\%$  para  $\beta_1$  é

$$\hat{\beta}_1 - t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}$$

- De maneira similar, temos que um IC com  $100(1 - \alpha)\%$  para  $\beta_0$  é

$$\hat{\beta}_0 - t_{\alpha/2, n-2} \sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]} \leq \beta_0 \leq \hat{\beta}_0 + t_{\alpha/2, n-2} \sqrt{\hat{\sigma}^2 \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}$$

# Exemplo

- Por exemplo, se no exemplo anterior quisermos obter um IC com 95% de confiança para a inclinação ( $\beta_1$ ).

Então sabemos que o intervalo é da forma

$$\hat{\beta}_1 - t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}$$

- Usando as quantidades já calculadas no exercício, temos que um IC com 95% de confiança para  $\beta_1$  é

$$1.54376 - 2.306 \sqrt{\frac{0.000013}{0.825}} \leq \beta_1 \leq 1.54376 + 2.306 \sqrt{\frac{0.000013}{0.825}}$$

ou seja

$$[1.53461, 1.55291].$$

# Exemplo

- Por exemplo, se no exemplo anterior quisermos obter um IC com 95% de confiança para a inclinação ( $\beta_1$ ).

Então sabemos que o intervalo é da forma

$$\hat{\beta}_1 - t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}$$

- Usando as quantidades já calculadas no exercício, temos que um IC com 95% de confiança para  $\beta_1$  é

$$1.54376 - 2.306 \sqrt{\frac{0.000013}{0.825}} \leq \beta_1 \leq 1.54376 + 2.306 \sqrt{\frac{0.000013}{0.825}}$$

ou seja

$$[1.53461, 1.55291].$$

# Exemplo

- Por exemplo, se no exemplo anterior quisermos obter um IC com 95% de confiança para a inclinação ( $\beta_1$ ).

Então sabemos que o intervalo é da forma

$$\hat{\beta}_1 - t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}$$

- Usando as quantidades já calculadas no exercício, temos que um IC com 95% de confiança para  $\beta_1$  é

$$1.54376 - 2.306 \sqrt{\frac{0.000013}{0.825}} \leq \beta_1 \leq 1.54376 + 2.306 \sqrt{\frac{0.000013}{0.825}}$$

ou seja

$$[1.53461, 1.55291].$$

# Exemplo

- Por exemplo, se no exemplo anterior quisermos obter um IC com 95% de confiança para a inclinação ( $\beta_1$ ).

Então sabemos que o intervalo é da forma

$$\hat{\beta}_1 - t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}$$

- Usando as quantidades já calculadas no exercício, temos que um IC com 95% de confiança para  $\beta_1$  é

$$1.54376 - 2.306 \sqrt{\frac{0.000013}{0.825}} \leq \beta_1 \leq 1.54376 + 2.306 \sqrt{\frac{0.000013}{0.825}}$$

ou seja

$$[1.53461, 1.55291].$$

# Exemplo

- Por exemplo, se no exemplo anterior quisermos obter um IC com 95% de confiança para a inclinação ( $\beta_1$ ).

Então sabemos que o intervalo é da forma

$$\hat{\beta}_1 - t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}$$

- Usando as quantidades já calculadas no exercício, temos que um IC com 95% de confiança para  $\beta_1$  é

$$1.54376 - 2.306 \sqrt{\frac{0.000013}{0.825}} \leq \beta_1 \leq 1.54376 + 2.306 \sqrt{\frac{0.000013}{0.825}}$$

ou seja

$$[1.53461, 1.55291].$$

# Exemplo

- Por exemplo, se no exemplo anterior quisermos obter um IC com 95% de confiança para a inclinação ( $\beta_1$ ).

Então sabemos que o intervalo é da forma

$$\hat{\beta}_1 - t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}$$

- Usando as quantidades já calculadas no exercício, temos que um IC com 95% de confiança para  $\beta_1$  é

$$1.54376 - 2.306 \sqrt{\frac{0.000013}{0.825}} \leq \beta_1 \leq 1.54376 + 2.306 \sqrt{\frac{0.000013}{0.825}}$$

ou seja

$$[1.53461, 1.55291].$$